

Estudio del impacto de las altas temperaturas en la mortalidad diaria en España

Máster Universitario en Modelización e
Investigación Matemática, Estadística y
Computación



Universidad
Zaragoza

Alonso Pueyo Gómez
Trabajo de fin de máster
Universidad de Zaragoza
Tutora: Jaione Etxeberria

1 de septiembre de 2025

Resumen

Índice general

Resumen	III
1. Introducción	1
2. Marco Teórico	3
2.1. Regresión de Poisson	3
2.2. Modelos de retardo distribuido (dlm)	3
2.3. Modelos de retardo distribuido no lineales (dlnm)	4
2.4. Método de estimación de los modelos mediante el paquete <i>dlnm</i>	6
3. Ilustración de los modelos <i>dlnm</i> con datos de mortalidad diaria y temperaturas en España	9
3.1. Fuente de datos	9
3.2. Análisis del exceso de mortalidad atribuible a la temperatura en España	10
3.3. Análisis del exceso de mortalidad atribuible a la temperatura por provincias	23
3.3.1. Análisis comparativo entre Lugo y Huelva	25
3.4. Análisis del exceso de mortalidad atribuible a la temperatura en Navarra	26
4. Conclusiones	37
4.1. Material Suplementario	37
Bibliografía	39

Capítulo 1

Introducción

El cambio climático es un problema que preocupa a la sociedad desde hace varios años. Cada vez se registran estaciones más calurosas, con olas de calor más frecuentes e intensas, lo que repercute directamente en la salud de la población. Algunos grupos son especialmente vulnerables a estos efectos, como es el caso de las personas mayores. Diversos estudios han evidenciado la relación entre la exposición a altas temperaturas y el aumento de la mortalidad. El trabajo de Linares y Díaz (2008) [2] abordó la relación entre temperatura y mortalidad utilizando una metodología basada en modelos ARIMA y regresión de Poisson. Posteriormente, en 2010, Gasparrini, junto a Armstrong y Kenward [3], introdujo un nuevo enfoque metodológico que se utilizará a lo largo de este trabajo, presentándolo mediante un ejemplo aplicado a la ciudad de Nueva York. Entre 2011 y 2013, Gasparrini y Armstrong publicaron varios artículos [4, 5] en los que detallaron la librería desarrollada en RStudio, diseñada para implementar los modelos propuestos en su trabajo anterior. Esta herramienta ha facilitado nuevas investigaciones en el campo, como la realizada por Achebak, Devolder y Ballester (2018) [1], quienes aplicaron estos modelos para estudiar la mortalidad asociada al calor en España. En el año 2004, el Ministerio de Sanidad del Gobierno de España desarrolló el sistema de monitorización MoMo (https://momo.isciii.es/panel_momo/), que tiene el objetivo de identificar desviaciones de mortalidad diaria observada respecto a lo esperado según hechos pasados. Esta será la fuente principal de los datos.

Cuando se está estudiando la relación entre un efecto y sus consecuencias, se pueden emplear los modelos *dlnm* (Distributed Lag Models, en inglés) [3]. Resultan muy útiles cuando se está estudiando la estructura de retardo de efectos lineales. Cuando no existe tal linealidad, poseen limitaciones. Una solución consiste en relajar los supuestos y extenderlos a unos modelos más complejos, los *dlnm*. Por ejemplo, la relación que existe entre la exposición a una temperatura extremadamente alta y la mortalidad diaria no es lineal. El efecto que el exceso de temperatura provoca tras una exposición prolongada no tiene por qué presentarse de forma inmediata. Al contrario, los efectos suceden con cierto retardo, tardando varios días después de la exposición en aparecer. Es por ello que van a ser útiles los modelos que tienen en cuenta tanto los efectos inmediatos como los retardados de la temperatura sobre la mortalidad, como los *dlnm* (Distributed Lag Non-Linear Models) [3]. Lo que hacen es definir una dimensión temporal adicional a través de lo que se conoce como base cruzada, un espacio bidimensional de funciones que describe tanto la forma de la relación como la dimensión del retardo, y que determina la estructura temporal del efecto estudiado, que en el caso de este trabajo, es la mortalidad que se atribuye a la exposición a una alta temperatura.

El objetivo principal de este trabajo es analizar la mortalidad atribuible al calor extremo en diferentes grupos de edad y regiones de España, con el fin de identificar qué poblaciones presentan una mayor vulnerabilidad. Esta información resulta esencial para orientar futuras políticas de salud pública y planes de prevención ante olas de calor.

El TFM se organiza de la siguiente manera: en la sección 2 se presenta el marco teórico y la descripción de los modelos utilizados, así como la librería empleada. La sección 3 describe los datos y el análisis exploratorio realizado. En la sección 4 se exponen los resultados obtenidos a partir de la aplicación de los modelos y sus correspondientes predicciones. Finalmente, en la sección 5 se discuten las principales conclusiones y líneas futuras de investigación.

Capítulo 2

Marco Teórico

Este capítulo presenta el marco metodológico que sustenta el análisis desarrollado en este trabajo, comenzando con los modelos lineales generalizados (*glm*) y avanzando hacia los modelos de retardo distribuido no lineales (*dlnm*), que serán la base del estudio.

2.1. Regresión de Poisson

Sea Y_t el número de defunciones observadas en el día t , para $t = 1, \dots, n$. Dado que se trata de datos de conteo, se modelizan mediante una regresión de Poisson dentro del marco de los modelos lineales generalizados (*glm*), utilizando una función de enlace logarítmica:

$$\log(\mu_t) = \alpha + \sum_{j=1}^J s_j(x_{tj}; \beta_j) + \sum_{k=1}^K \gamma_k u_{tk}, \quad (2.1)$$

donde:

- $\mu_t = E(Y_t)$ es el número esperado de muertes en el día t .
- $s_j(x_{tj}; \beta_j)$ son funciones no paramétricas que permiten el suavizado de la curva (como los splines), y por tanto establecen relaciones no lineales entre las covariables x_{tj} y la variable respuesta.
- u_{tk} son variables explicativas lineales (tales como el día de la semana, la tendencia o la estacionalidad).
- γ_k son los coeficientes asociados a los predictores lineales.

La función de enlace logarítmica asegura que las predicciones del número esperado de muertes sean positivas.

2.2. Modelos de retardo distribuido (*dlnm*)

La exposición a temperaturas extremas no genera efectos inmediatos, sino que estos pueden manifestarse con varios días de retraso. Para modelizar este comportamiento, se recurre a los modelos de retardo distribuido (*dlnm*), que permiten distribuir el efecto de una exposición a lo largo de varios días.

Definimos un vector de exposiciones pasadas para el día t como:

$$q_t = (x_t, x_{t-1}, \dots, x_{t-L})^T \quad (2.2)$$

donde x_{t-l} es la temperatura observada l días antes (desfase) y L es el máximo número de días de retardo considerados. Un modelo *dlnm* simple puede expresarse como:

$$\eta_t = \sum_{l=0}^L \delta_l x_{t-l} \quad (2.3)$$

donde δ_l representa el efecto de la temperatura con un retardo de l días, y η_t es el predictor lineal del modelo, que corresponde a la transformación logarítmica de la media esperada μ_t de la variable respuesta Y_t , el número de defunciones diarias.

Sin embargo, este enfoque puede sufrir de colinealidad entre las variables x_{t-l} , ya que las temperaturas en días consecutivos tienden a estar altamente correlacionadas. Para contrarrestar este problema, se introducen restricciones sobre los coeficientes δ_l , modelándolos como funciones suaves mediante splines o polinomios.

De manera general, los modelos *dlnm* se formulan como sigue. Sobre una base se especifican los efectos distribuidos a lo largo de los retardos. En notación matricial, los efectos retardados se definen así:

$$s(x_t; \beta) = q_t^T C \beta \quad (2.4)$$

donde C es la matriz de variables base que se obtienen al aplicar las funciones base a los retardos, y β es el vector de parámetros que no se conocen.

En el modelo general de regresión lineal generalizada con función de enlace logarítmica, la relación entre q_t y η_t se establece mediante funciones base que capturan tanto la no linealidad como los efectos retardados. Estas funciones se combinan para formar un predictor que describe el efecto total de la temperatura en el tiempo t . Así, se llega a la expresión:

$$\eta_t = \alpha + r_t^T C \beta + \sum_{k=1}^K \gamma_k u_{tk} \quad (2.5)$$

donde r_t es la transformación de q_t a través de las funciones base y las variables u_{tk} son otros predictores con efecto lineal.

Dependiendo de cómo esté definida la matriz C , estamos hablando de un tipo de *dlnm* u otro. Si C es la matriz identidad, entonces se trata del modelo sin restricciones que define (2.3).

2.3. Modelos de retardo distribuido no lineales (dlnm)

A continuación, se presenta el modelo general empleado en este proyecto. Está diseñado como un modelo jerárquico que estudia las muertes diarias producidas por un exceso de calor. Decimos que sigue una jerarquía porque se definen unos elementos iniciales, que luego se combinan en un objeto predictor. En particular, se siguen los siguientes pasos. Primero se define la dimensión de la exposición, que en nuestro caso es la temperatura. Se define cómo responde la variable de la mortalidad frente a los diferentes valores de la temperatura. Después, se precisa cómo el riesgo de fallecer se distribuye a lo largo del tiempo. Esta es la dimensión del retardo,

donde se modela cómo varía el efecto conforme van pasando los días tras la exposición. Finalmente, las dos dimensiones anteriores se combinan de forma jerárquica generando una matriz de diseño, la base cruzada, que funciona como predictor en el modelo. Se trata de un espacio bidimensional de funciones que describen al mismo tiempo la forma de la relación entre la exposición y la respuesta, y los efectos de retardo distribuidos. Una base cruzada se elige mediante la selección de dos conjuntos de funciones de base, uno para la exposición, en nuestro caso la temperatura, y otro para el retardo. Estos se combinarán para generar lo que se conoce como funciones de base cruzada.

La principal limitación de los *dlnm* es la suposición de linealidad entre la exposición y la respuesta. Sin embargo, en el caso de la temperatura, la relación con la mortalidad no es lineal. Por ello, se emplean los modelos de retardo distribuidos no lineales (*dlnm*) propuestos por Gasparrini et al. (2010) [3], que permiten modelar simultáneamente la forma no lineal de la exposición y su distribución en el tiempo.

En los *dlnm*, el efecto total de la temperatura sobre la mortalidad en el día t se expresa como la suma de los efectos de las temperaturas de días anteriores, es decir:

$$\eta_t = \sum_{l=0}^L f(x_{t-l}, l) \quad (2.6)$$

donde $f(x, l)$ es una función bivariada que representa el efecto de la temperatura x con un retardo de l días. Esta función se modela como la combinación de dos funciones base, una para la temperatura y otra para el retardo. Se escribe como:

$$f(x, l) = \sum_{i=1}^I \sum_{j=1}^J \beta_{ij} \cdot B_i(x) \cdot C_j(l) \quad (2.7)$$

donde:

- $B_i(x)$ son las funciones base que representan la forma de la relación en el eje de la temperatura.
- $C_j(l)$ son las funciones base que describen la distribución del efecto en el eje de los retardos.
- β_{ij} son los parámetros a estimar.
- I y J son los números de funciones base en cada dimensión.

Esta formulación permite capturar de manera flexible la relación entre la exposición a temperaturas extremas y la mortalidad, incluyendo patrones de retardo complejos y respuestas no lineales, lo que la convierte en una herramienta fundamental para evaluar el impacto sanitario del cambio climático.

Definiendo la matriz C como en la sección anterior, un modelo *dlnm* se especifica de manera general como:

$$s(x_t; \beta) = r_t^T C \beta = \sum_{i=1}^I \sum_{j=1}^J r_{ti}^T c_j \beta_{ij}, \quad (2.8)$$

donde r_t es el vector de las componentes de la temperatura transformadas según las funciones de base.

2.4. Método de estimación de los modelos mediante el paquete *dlnm*

Los parámetros del modelo se estiman mediante el método de máxima verosimilitud, propio de los modelos lineales generalizados. En particular, para una regresión de Poisson con función de enlace logarítmico, se maximiza la función de verosimilitud definida por la distribución de Poisson de los conteos observados.

Sea Y_t el número de defunciones en el día t , y $\mu_t = E(Y_t)$ la media condicionada a las covariables y a la exposición retardada. El modelo se expresa como:

$$\log(\mu_t) = \alpha + X_t\beta$$

donde X_t es la matriz de diseño construida a partir de las bases cruzadas y otras covariables, y β el vector de parámetros que se desean estimar. Así, la función de verosimilitud es:

$$L(\beta) = \prod_{t=1}^n \frac{e^{-\mu_t} \mu_t^{Y_t}}{Y_t!}$$

Maximizando el logaritmo de esta función se obtienen las estimaciones de β .

Cuando se han realizado varios modelos diferentes y se quiere seleccionar el que mejor se ajusta a los parámetros del problema, se calcula el valor del Criterio de Información de Akaike (AIC) o el Criterio de Información Bayesiano (BIC). Ambas son medidas estadísticas útiles para la evaluación del equilibrio entre el ajuste y la complejidad del modelo. Un valor menor indica un mejor ajuste. Se calculan como sigue:

$$AIC = -2L(\beta) + 2k$$

$$BIC = -2L(\beta) + k \cdot \log(n)$$

siendo $L(\beta)$ la función de verosimilitud anterior, k el número de parámetros del problema, y n el número de observaciones.

Cuando se presenta un modelo de Poisson sobredisperso (quasi-Poisson), donde $E(X) = \mu$ y $Var(X) = \phi\mu$, con $\phi > 1$ el parámetro de sobredispersión, se han de modificar los criterios anteriores, que ahora se calculan:

$$QAIC = -2L(\beta) + 2\phi k$$

$$QBIC = -2L(\beta) + \phi k \log(n)$$

El parámetro de sobredispersión de un modelo se obtiene como la relación entre la desviación residual y los grados de libertad.

Para implementar los modelos descritos en el trabajo utilizaremos el paquete *dlnm* en R, desarrollado por Antonio Gasparrini y colaboradores [4, 5, 6]. Este paquete permite construir y ajustar modelos de regresión con bases cruzadas para analizar efectos no lineales y con retardos

distribuidos en series temporales, principalmente en el contexto de regresiones de Poisson para datos de conteos.

El paquete facilita la creación de bases de funciones para la variable de exposición y para los retardos, y las combina en lo que se denomina una base cruzada, que modela simultáneamente la no linealidad y el efecto retardado. Para ello, las principales funciones que se utilizan son:

- **onebasis()**: genera una base de funciones para una única dimensión (exposición o retardo). Es empleada para construir manualmente bases cruzadas o para modelos con relación lineal y efectos retardados (*dlnm*).
- **crossbasis()**: construye la base cruzada combinando las bases de exposición y retardo, usada para ajustar modelos *dlnm*.
- **crosspred()**: calcula predicciones y efectos estimados a partir del modelo ajustado con la base cruzada.
- **crossreduce()**: resume el efecto bidimensional en una sola dimensión, facilitando la interpretación del efecto acumulado sobre la exposición o el retardo.

Estimación del modelo. El modelo se ajusta mediante regresión generalizada con función de enlace logarítmico y distribución de Poisson para modelar conteos, como las defunciones diarias. Las funciones **glm()** o **gam()** de R sirven para estimar los coeficientes β de las bases cruzadas mediante máxima verosimilitud, obteniendo así los efectos de la exposición y los retardos sobre la variable respuesta.

La estimación incorpora los términos suavizados definidos por las bases y la estructura temporal de los retardos, y los parámetros se ajustan para maximizar la probabilidad de observar los datos bajo el modelo.

Visualización. El paquete también ofrece funciones para visualizar la relación entre la exposición y los retardos mediante superficies tridimensionales, curvas de efecto acumulado o mapas de calor, entre otros, facilitando la interpretación del impacto de la exposición sobre la respuesta a lo largo del tiempo.

En resumen, el paquete *dlnm* ofrece una implementación flexible y eficiente para ajustar modelos estadísticos complejos que permiten estudiar los efectos retardados y no lineales en epidemiología ambiental y otros campos relacionados.

Capítulo 3

Ilustración de los modelos *dlnm* con datos de mortalidad diaria y temperaturas en España

3.1. Fuente de datos

Fuentes de información. Para el desarrollo de este Trabajo Fin de Máster se han utilizado datos procedentes del Sistema de Monitorización de la Mortalidad Diaria (MoMo), accesible en https://momo.isciii.es/panel_momo/#section-momo. MoMo es un sistema de vigilancia implementado por la Unidad de Vigilancia de la Mortalidad Diaria del Centro Nacional de Epidemiología (CNE) del Instituto de Salud Carlos III, en el marco del Plan Nacional de Actuaciones Preventivas de los Efectos del Exceso de Temperaturas sobre la Salud (Plan Calor). Desde 2022, este sistema recopila información sobre defunciones diarias por todas las causas a partir de los registros civiles informatizados del Ministerio de Justicia, abarcando 4.128 municipios que representan aproximadamente el 93 % de la población española.

Además de los datos de mortalidad, actualizados diariamente, MoMo incluye el ámbito geográfico (provincia, comunidad autónoma o nacional), su nombre y código, el sexo y grupo de edad quinquenal de los fallecidos (con sus respectivos códigos), la fecha de defunción, el número de defunciones observadas y esperadas (estas últimas sin ajuste por temperatura) junto con sus respectivos intervalos de confianza, y el número de defunciones atribuibles al exceso o defecto de temperatura. Para el trabajo, seleccionaremos solo el ámbito provincial.

MoMo también calcula lo que se conoce como índice Kairós, que alerta acerca del riesgo de mortalidad asociado a un exceso o a un defecto de la temperatura. Tiene tres niveles. El primero indica que no hay riesgo, el segundo que existe riesgo moderado y el tercero que el riesgo es alto.

Las fuentes de datos que utiliza MoMo son:

- Los datos de defunciones diarias de los últimos 10 años, salvo el 2020 debido a la pandemia, obtenidos del Instituto Nacional de Estadística (INE) hasta una cierta fecha, y desde entonces del Ministerio de Justicia.
- Las temperaturas según la Agencia Estatal de Meteorología (AEMET) a nivel provincial.
- La población por grupo de edad, sexo y provincia, del INE.

El modelo que emplea MoMo para calcular la predicción de excesos de mortalidad atribuibles a la temperatura es un modelo aditivo generalizado (GAM) de Poisson. Las variables empleadas para ajustarlo son:

- Un spline cúbico por provincia para modelar la tendencia.
- Un spline cíclico por provincia para la estacionalidad anual de la mortalidad.
- El ATO con efecto aleatorizado entre las provincias, mediante modelos mixtos.
- El F-ATO con efecto aleatorizado entre las provincias, mediante modelos mixtos.
- La tasa de defunción se ajusta como 'offset'.

El ATO (Accumulated Thermal Overcharge) es una variable sintética que mide el efecto del exceso de temperatura máxima. Cada provincia posee una temperatura máxima crítica a partir de la que se observa una mayor mortalidad. La formulación que emplea MoMo es la siguiente:

$$ATO_d = \sqrt{\sum_{i=1}^7 ATO_{d-i} \cdot 0,8^{(i-1)}}$$

Análogamente, el F-ATO (Accumulated Thermal Overcharge for cold) es una variable sintética que mide el efecto del exceso de temperatura mínima. Se construye como el ATO pero tomando temperaturas mínimas.

Los datos relativos a la temperatura se obtuvieron del portal de la AEMET (Agencia Estatal de Meteorología) conocido como AEMET OpenData (<https://opendata.aemet.es/centrodedescargas/inicio>). Se trata de un API REST (Application Programming Interface. REpresentational State Transfer) que permite descargar de forma gratuita datos de las estaciones meteorológicas españolas. Las fechas de los datos descargados suman un total de 10 años, desde el 1 de enero del 2015 al 31 de diciembre del 2024. Por defecto, se incluyen datos de todas las estaciones meteorológicas, y para evitar tener sobrecarga de información, se eligió únicamente una estación por provincia. Los nombres de las estaciones seleccionadas se incluyen en el anexo. Una vez se tienen ambas bases de datos, se unifican en una sola según la fecha y el nombre de la provincia.

3.2. Análisis del exceso de mortalidad atribuible a la temperatura en España

En este primer análisis vamos a estudiar la relación entre la mortalidad y el exceso o defecto de la temperatura a nivel nacional. Se empleará la totalidad de los datos que están disponibles, sin importar la provincia de la que procedan.

El primer paso es realizar un análisis descriptivo. Se pretende ver si existen muchos datos faltantes o cómo se distribuyen a lo largo del tiempo. La base de datos consta de una totalidad de 4709112 observaciones de 19 variables. Cambiamos la naturaleza de las variables relativas a la temperatura (*tmed*, *tmin*, *tmax*) a numérica, y las relativas a los grupos de población (*cod_sexo*,

nombre_sexo, *cod_gedad*, *nombre_gedad*) a factor. Tras estos cambios, se derivan las siguientes observaciones:

- Hay un total de 27671 observaciones faltantes en la variable de defunciones observadas. De las variables que indican la temperatura media, la mínima y la máxima hay 1509720, 1509408 y 1509024 datos faltantes, respectivamente. Dentro de un análisis más profundo, es posible darse cuenta de que los datos pertenecientes a la temperatura que no existen se tratan de ciertos periodos de tiempo de los que algunas estaciones meteorológicas no tienen información. Por ejemplo, la estación de Murcia Aeropuerto solamente tiene datos a partir del día 29 de mayo del 2021, o la estación de Madrid Aeropuerto, a la que le faltan muchos datos entre el año 2018 y el 2020. Sin embargo, debido a la gran cantidad de observaciones que se tiene, esto no será un problema a la hora de hacer el análisis nacional.
- El número de observaciones que existen para cada grupo de población, tanto de edad como de sexo, es el mismo. Se presentan un total de 1569704 datos para cada subgrupo de la variable que separa la población según el sexo, y 588639 para cada subgrupo de edad. Esto es debido a que cada fila de la base de datos se trata de un día por grupo de edad, sexo y lugar.
- La variable *defunciones_observadas* tiene una media con un valor de 5.515, mientras que la mediana solo vale 2.010, bastante menor. De manera semejante ocurre con las variables *defunciones_estimadas_base*, *defunciones_estimadas_base_q01*, *defunciones_estimadas_base_q99*, *defunciones_atrib_exc_temp* y *defunciones_atrib_def_temp*. Esto ocurre por la distribución de los datos. Muchos días, las defunciones observadas, o las que se atribuyen a la temperatura, en muchos grupos de población, toman el valor 0. Por otra parte, cuando se presenta una ola de calor o de frío, por ejemplo, el número de defunciones aumenta, dando lugar a la distribución desigual que se observa.
- El valor máximo que alcanza la variable *defunciones_observadas* es 817.270. Este valor tan alto se alcanzó en Madrid el 27 de marzo del 2020. No obstante, ninguna de estas muertes se asocia con la temperatura. Todas ellas fueron a causa de la pandemia del COVID-19 que se sufrió. Los datos de las defunciones que ocurrieron ese año tienen valores más altos de lo normal a causa de ello.
- Los valores de la media y la mediana para las variables *tmed*, *tmin* y *tmax* son bastante parecidos (16.20 es la media y 16.33 la mediana de *tmed*, 10.80 y 10.73 la media y la mediana de *tmin* y 21.50 y 21.92 los respectivos valores asociados a *tmax*). Al contrario de lo que ocurría con las defunciones, esto indica que la distribución de la temperatura es simétrica. Existen días con calor y también con frío en la misma medida.

A continuación vamos a realizar el apartado de la modelización. En primer lugar, evaluaremos los modelos que fueron realizados por otros autores en trabajos semejantes y lo aplicaremos a nuestro caso particular.

En el trabajo de Gasparrini, Armstrong y Kenward [3], que mencionamos en la introducción, y donde se explica el funcionamiento de los modelos *dlnm*, hay un ejemplo de aplicación sobre el efecto de la temperatura en la mortalidad en la ciudad de Nueva York. En él se menciona que se elige un modelo con splines cúbicos naturales para describir la relación en cada




Figura 3.1: Distribución de los datos de temperatura

dimensión, con nudos igualmente espaciados para la temperatura con el fin de dar flexibilidad a los extremos, y con intervalos iguales en la escala logarítmica para los retardos, para flexibilizar la primera parte de la curva del retardo distribuido, que se espera más variable. Además, se toma un retardo máximo de 30 días, y los grados de libertad se eligen según los criterios de información de Akaike y bayesianos modificados.

Por otro lado, en el trabajo de Achebak, Devolder y Ballester [1], donde recordemos que se estudia la mortalidad relacionada con el calor en España, se modela la curva relativa a la temperatura con un B-spline cúbico natural, con un nudo en el percentil 15 de la distribución de la temperatura diaria, y para la curva de los retardos se emplea otro B-spline cúbico natural con una intersección y dos nudos igualmente espaciados en la escala logarítmica. El retardo máximo que se considera es de 10 días.

Por último nos vamos a fijar en el proyecto realizado por Rutten, Espinasse, Duarte, Neyens y Faes [10]. En él se estudia las asociaciones retardadas y no lineales entre la contaminación del aire y los casos del virus COVID-19 en Bélgica. También se utiliza un *dlnm*, donde se emplea un spline natural con 2 nudos igualmente espaciados y 3 grados de libertad para la dimensión de la exposición, y un nudo y un intercepto con 3 grados de libertad para la dimensión de los retardos.

Nos damos cuenta con estas observaciones que los splines cúbicos son adecuados para nuestro análisis. Esto se debe a su flexibilidad, que permite modelizar bien las curvas suaves, como son las que se esperan que resulten al aplicar un modelo *dlnm*.

Recordemos brevemente lo que es una función spline cúbica. Dados $n + 1$ puntos distintos $t_0 < t_1 < \dots < t_n$ que son una partición del intervalo $[t_0, t_n]$, un spline cúbico (de grado 3) con nudos en $t_0, t_1, \dots, t_n$ es un polinomio a trozos de grado a lo sumo 3 continuo en $[t_0, t_n]$, y con derivadas continuas hasta orden 2. Además, se dice que un spline cúbico es natural si satisface que su segunda derivada en los extremos, es decir, en los puntos t_0 y t_n es nula. Las funciones B-spline son la base de los splines generales. Se tratan de funciones no negativas que se anulan en toda la recta real excepto en intervalos contiguos $[t_i, t_{i+1}]$ tal y como afirma González en su trabajo sobre splines [11].

Redondeamos la variable de las defunciones observadas para evitar errores, y definimos la variable *dow* (día de la semana) que incluiremos en el modelo. Notemos que no disponemos de muchas de las variables que son empleadas en trabajos similares, tales como el ozono o el nivel de monóxido de carbono en la atmósfera, entre otros. Esto puede limitar la utilidad de los modelos que vamos a realizar.

Debido a la gran cantidad de observaciones que tiene la base de datos, la parte de modelización requiere un alto coste de tiempo computacional. Dado que tendremos que hacer una gran cantidad de bases cruzadas y modelos, procederemos seleccionando una muestra más pequeña y aleatoria de los datos. Además, para no perder la componente estacional de la temperatura, la submuestra que tomemos será estratificada. De esta manera aseguramos tomar la misma cantidad de días fríos y días cálidos.

Tras tomar la muestra aleatoria y estratificada de tamaño un 3.33 % respecto a la cantidad de datos originales, lo primero que se realiza es la comprobación. Analizamos las variables y notamos que los grupos de población se dividen de igual manera, como ocurría originalmente, aunque ahora no es exactamente el mismo número de datos (por ejemplo, hay 34456 observaciones correspondientes a hombres, 34309 a mujeres, y 34468 pertenecientes al grupo de todos). La distribución de las defunciones observadas sigue siendo bastante desigual, donde muchos días no muere nadie. Por último, tal y como se buscaba, se tienen tanto días fríos como días cálidos en la misma medida.

Para comenzar la modelización, se realiza una primera aproximación donde se decide tomar un retardo máximo de 30 días, y en la base cruzada se utilizan B-splines con 3 grados de libertad para la temperatura, y splines naturales con el mismo número de grados de libertad para la dimensión del retardo. En el caso del modelo, la variable explicada es la de defunciones observadas, que es estudiada por la base cruzada que se acaba de definir, el día de la semana y el spline natural de la fecha de defunción, con 70 grados de libertad (7 por cada año de datos que se tienen). Recordemos que se trata de un modelo de regresión de quasi-Poisson, ya que existe sobredispersión de los datos. Centramos la predicción en el valor de 20°C, y los gráficos obtenidos se pueden ver en la imagen 3.2.

El Riesgo Relativo (RR) que se suele emplear en los gráficos se trata de una medida que compara el riesgo de un evento, que en nuestro caso es fallecer debido a las temperaturas extremas, en un grupo expuesto a ese factor, frente a un grupo de referencia que no está expuesto. En nuestro estudio, se está comparando el riesgo de la población en días con temperaturas extremas frente a días con temperaturas suaves. Por ello, el valor que hemos empleado para centrar la predicción era de 20°C.

Si nos fijamos en los gráficos, se observa que el RR aumenta conforme sube la temperatura, que suele ser lo normal. Sin embargo, parece que en días fríos el riesgo se reduce considerablemente. Esto no tiene demasiado sentido. Recordemos que la base de datos que estamos empleando contiene información acerca de muchos grupos de población distintos de muchos lugares de España bastante diferentes entre sí, ya que las temperaturas en una provincia del norte serán más frías que en una provincia del sur. Esto es lo que puede hacer que se obtengan esos resultados, y se trata de un factor a tener en cuenta.

A continuación, vamos a realizar un análisis de sensibilidad en el que se estudiarán diferentes modelos con distintos grados de libertad tanto para la temperatura como para el retardo, además de probar tanto con splines naturales como con B-splines. El método que se va a emplear para elegir el mejor modelo de todos es el Criterio de Información de Akaike modificado




Figura 3.2: Gráficos del modelo con B-spline para la temperatura y spline natural para el retardo, ambos con 3 grados de libertad (submuestra).

para modelos con sobredispersión (QAIC). Recordemos que se calculaba como:

$$QAIC = -2L(\beta) + 2\phi k$$

donde L es la función de verosimilitud, ϕ el parámetro de sobredispersión y k el número de parámetros. Se obtendrán valores muy altos, dado el gran tamaño de los datos.

Tras el análisis de sensibilidad, se ha obtenido que los modelos que tienen un menor valor del QAIC son:

- Un modelo en el que se emplean B-splines tanto para la temperatura como para el retardo, empleando 5 grados de libertad para el primero y 7 para el segundo. El valor del QAIC obtenido es de 1425842.
- Otro modelo que usa un spline natural con 3 grados de libertad para la temperatura, y un B-spline con 7 grados de libertad para el retardo. Tiene un QAIC de 1425939.

Hay que tener en cuenta que el QAIC trata de ajustar y penalizar según el número de parámetros. En modelos tan grandes como el que estamos estudiando, puede tender a un sobreajuste de los datos. Precisamente eso es lo que se desprende de ver que los mejores modelos son los que tienen grados de libertad tan altos para la dimensión del retardo. No obstante, vamos a visualizar los gráficos que se obtienen. (3.3)

En la figura 3.3 se puede ver en ambos casos el sobreajuste de los datos. Esto se manifiesta en los altibajos que tiene la superficie tridimensional, sobretodo en los extremos de la temperatura. Si el modelo estuviera bien ajustado, la superficie sería más plana, con menos baches. Los gráficos de efecto acumulado también lo muestran. El de la parte superior de la figura experimenta constantes subidas y bajadas, aparte de que en los extremos, donde en teoría el riesgo




Figura 3.3: Arriba: Gráficos del modelo con B-splines para ambas dimensiones y 5 y 7 grados de libertad para la variable y el retardo, respectivamente (submuestra). Abajo: Gráficos del modelo con un spline natural con 3 grados de libertad para la temperatura y un B-spline con 7 para el retardo (submuestra).




Figura 3.4: Arriba: Gráficos del modelo con B-splines y 5 grados de libertad para ambas dimensiones (submuestra). Abajo: Gráficos del modelo con un spline natural con 3 grados de libertad para la temperatura y un B-spline con 5 para el retardo (submuestra).

aumenta, descendiendo bastante por debajo del 1. Notemos que los intervalos de confianza (en gris) también son muy amplios, y no aportan nada de información.

Es por todas las causas anteriores por las que se ha decidido probar de nuevo estos modelos pero reduciendo los grados de libertad con el fin de reducir el sobreajuste mencionado. En particular, reducimos los grados de libertad correspondientes al retardo hasta 5, mientras se dejan fijos los relativos a la temperatura. Volvemos a comparar los gráficos logrados. (3.4)

En la figura 3.4 se observa una ligera mejoría respecto a los modelos de la figura anterior. En general, las superficies se ven algo más suavizadas, los valores del Riesgo Relativo en los extremos han subido un poco y los intervalos de confianza se han reducido, sobretodo en la parte de las altas temperaturas, aunque siguen siendo bastante amplios.

A partir de aquí seleccionamos el modelo de arriba, que parece mejor, y estudiamos lo que ocurre si reducimos los grados de libertad todavía más, hasta 4. Los gráficos resultantes se ven en la figura 3.5.

Se visualiza una superficie más suavizada que las anteriores. Parece que el mayor pico del Riesgo Relativo para bajas temperaturas ocurre con un retardo de entre 5 y 7 días, mientras que para temperaturas altas hay un mayor riesgo en los primeros días de retardo. Por otra parte,




Figura 3.5: Gráficos del modelo con B-splines y 4 grados de libertad para la temperatura y para el retardo (submuestra).




Figura 3.6: Gráficos del modelo con B-splines y 4 grados de libertad para la temperatura y para el retardo aplicado a todos los datos.

el gráfico de efecto acumulado muestra que con temperaturas bajas el riesgo de fallecer es muchísimo menor, comparado con el riesgo de fallecer con 20°C. El intervalo de confianza en esta parte no es muy amplio, y se mantiene por debajo del 1. En relación con el calor, el RR llega hasta algo más de 1.5, pese a que el intervalo de confianza es muy amplio.

Recordemos que se trata de un gráfico de efecto acumulado y que, por lo tanto, tiene en cuenta lo que ocurre durante los 30 días de retardo máximo que se han introducido en la base cruzada. Eso también incluye que, a lo mejor, después de 3 semanas, el riesgo de fallecer respecto a una temperatura normal tras haber estado expuesto al frío decrece en gran medida.

Ya se ha llegado a un modelo que parece adecuado respecto a nuestros datos. A continuación, planteamos el mismo modelo para la base de datos que se presentaba inicialmente, sin tomar una submuestra más pequeña.

Los gráficos del modelo al que se ha llegado finalmente aplicado a todos los datos disponibles se pueden ver en la figura 3.6.

Lo más destacable es que, bajo temperaturas frías, el RR decrece mucho, hasta casi tocar




Figura 3.7: Cortes de la superficie cuando el retardo (Lag) es de 0, 3, 5 y 11 días, y la temperatura (Var) es de 0, 5, 30 y 35°C.

el 0, lo que se ve tanto en la superficie tridimensional como en el gráfico de efecto acumulado. Esto puede deberse a que no hay demasiados datos donde la temperatura media sea más baja de 10, y las que existen, no cuentan apenas con defunciones. Otra observación a tener en cuenta es que los intervalos de confianza del gráfico de efecto acumulado son muy estrechos. En la parte del frío no se aprecia.

Podemos afirmar que este modelo, para temperaturas altas, aumenta el RR y se observa un retardo casi inmediato, es decir, los efectos provocados por estar expuesto al calor se manifiestan durante los 5 primeros días después de dicha exposición. Por otra parte, pese a que el valor del RR sea tan bajo cuando las temperaturas son mínimas, esto no quiere decir que el modelo sea malo, o no sea útil. Al contrario, lo que ocurre es que cuando se ha sido expuesto a un día muy frío, los efectos causados tardan más días en aparecer que los días más calurosos. Es por ello que la curva del gráfico acumulado toma esa forma. Finalmente, nos decantamos por utilizar este modelo durante el resto de la sección.

Ahora, se van a realizar cortes en la superficie en ciertos puntos (en el retardo 0, 3, 5 y 11, y cuando la temperatura vale 0, 5, 30 y 35°C) con la finalidad de visualizar lo que ocurre en esos casos particulares. Se puede ver en la figura 3.7.

Para los primeros 5 días de retardo se observa que el RR en temperaturas altas es mayor que 1 y para temperaturas bajas es bastante menor. Sin embargo, en el gráfico correspondiente al día 11 de retardo, ya se muestra que en temperaturas cálidas el RR ha decrecido y es mayor

que 1 cuando las temperaturas son frías. Esto nos quiere decir que los síntomas procedentes de una exposición al calor se manifiestan en los 5 primeros días después del suceso. Al contrario ocurre con la exposición al frío, donde los síntomas aparecerían una semana más tarde.

A las mismas conclusiones se llega observando los gráficos de la derecha. Cuando la temperatura es de 0°C, el RR es mayor que 1 entre los días 8 y 21 de retardo, indicando que los efectos no aparecen de forma inmediata. Si la temperatura es más caliente, con 35°C, el mayor RR se alcanza en los primeros días desde la exposición, y decreciendo a partir de ahí.

Por consiguiente, la conclusión a la que se llega es que los efectos del calor ocurren, como tarde, una semana después de la exposición y a partir de ese entonces la probabilidad de que ocurran decrece considerablemente. Los efectos del frío ocurren de manera más tardía, a partir de la segunda semana, y también durante la tercera. Después, es menos probable que aparezcan los efectos perversos.

Para terminar este análisis a nivel estatal, dividiremos a la población en subgrupos según su edad, y estudiaremos con el modelo anterior cómo afecta la temperatura a cada uno de ellos. Los subgrupos que tomaremos son los siguientes: el de niños entre los 0 y los 14 años, el de personas entre 15 y 44 años, entre los 45 y los 64, los 65 y los 74, los 75 y los 84, los mayores de 85 años, y el de los mayores de 65.

Ya se ha comprobado en el análisis descriptivo inicial que el número de defunciones que existen en cada grupo va aumentando a medida que sube la edad. Se espera que en todos los casos se obtengan resultados similares.

Se pueden visualizar las predicciones resultantes para cada grupo de población según la edad desde la figura 3.8 hasta la 3.14. Se observan dibujos similares en todos los casos. Pero existen detalles que los distinguen. En general, en todas las superficies se nota mayor planitud en temperaturas cálidas, con forma de U. Los mayores valores del RR en este caso se obtienen en los extremos, especialmente en los primeros valores del retardo, probando nuevamente que los efectos provocados por exposiciones a altas temperaturas son casi inminentes y ocurren en los primeros días tras la exposición, independientemente de la edad del individuo. En la otra parte, con temperaturas bajas, en todos los subgrupos se visualiza la forma de una onda. Se tiene un valor del RR que empieza en el 0 en el instante siguiente al de la exposición. A partir de entonces va subiendo ese valor hasta llegar a un pico que se alcanza aproximadamente alrededor del día 5 y 7 después de la exposición, demostrando que los efectos provocados por el frío ocurren días más tarde. Después, va descendiendo hasta que los últimos días del retardo máximo de 30 días ese valor sube.

El hecho de que el valor del RR aumente durante los últimos días de retardo es debido a que el modelo no controla suficientemente bien un valor tan alto del retardo máximo, ni tampoco lo que ocurre en las esquinas, lo que explicaría que el RR en temperaturas bajas en el retardo 0 sea nulo, y no comience en un valor más alto. Esta es una limitación del modelo que se tiene que tener en cuenta.

Los objetos a fijarse a continuación son los gráficos de efecto acumulado de cada grupo. Hasta ahora no se ha podido ver mucha diferencia entre ellos. La principal diferencia que se observa es el gran valor del RR que se alcanza cuando la temperatura es muy alta. Dicho valor aumenta conforme los grupos de población tienen más edad. Esto vuelve a suceder debido a la mala aproximación por parte del modelo de lo que sucede en los extremos. Otra observación que se puede hacer es que los intervalos de confianza, el área gris, va decreciendo en cuanto se llega




Figura 3.8: Gráficos correspondientes al subgrupo de población que tiene entre 0 y 14 años.




Figura 3.9: Gráficos correspondientes al subgrupo de población que tiene entre 15 y 44 años.

a los grupos más mayores, especialmente para temperaturas altas, donde además el intervalo de confianza en el grupo de niños entre 0 y 14 años, y el de entre 15 y 44 años es bastante amplio. Esto no es causa de un defecto del modelo, sino que se tienen pocas observaciones de defunciones en los grupos de menor edad, como comentamos en el análisis inicial.

Quitando las notas anteriores, el patrón del gráfico es similar para cada grupo. El mayor RR en temperaturas frías se alcanza alrededor de los 9 y los 10 grados. Con 20 grados el riesgo vale 1 porque es el valor de referencia. Más tarde, el RR vuelve a aumentar considerablemente entre los 28 y los 30 grados.

Como cierre final a este análisis, hay que considerar que el modelo seleccionado no es perfecto. Como ya se ha comentado, tiene problemas para predecir lo que ocurrirá en valores extremos de la temperatura y el retardo. Sin embargo, esto no significa que se puedan obtener conclusiones. Que el número de defunciones sea más bajo conforme la edad es menor ya indica de por sí que los grupos jóvenes tienen más tolerancia al calor y al frío que los grupos más mayores, dada su salud. Sin embargo, si se ha sido expuesto a días muy calurosos o muy fríos, todos los grupos, independientemente de la edad, sufren las mismas consecuencias. Los efectos




Figura 3.10: Gráficos correspondientes al subgrupo de población que tiene entre 45 y 64 años.




Figura 3.11: Gráficos correspondientes al subgrupo de población que tiene entre 65 y 74 años.




Figura 3.12: Gráficos correspondientes al subgrupo de población que tiene entre 75 y 84 años.




Figura 3.13: Gráficos correspondientes al subgrupo de población que tiene más de 85 años.




Figura 3.14: Gráficos correspondientes al subgrupo de población que tiene más de 65 años.

que provoca el calor ocurren durante los 5 primeros días desde la exposición, mientras que los efectos provocados por el frío tardan unos 5 días más en aparecer, es decir, entre el día 5 y el 10 desde la exposición. Los límites de temperatura bajo los que se puede considerar que hay riesgo de sufrir alguna consecuencia son por debajo de los 10 grados, o a partir de los 30.

3.3. Análisis del exceso de mortalidad atribuible a la temperatura por provincias

Mostraremos a continuación un análisis más desagregado, por provincias. Para su realización, se empleará el método de las Aproximaciones de Laplace Anidadas Integradas (INLA, integrated Nested Laplace Approximations, en inglés) [12]. El método INLA es determinista y sirve para realizar inferencia Bayesiana. Es más rápido y exacto que los métodos de Montecarlo basados en cadenas de Markov (MCMC) que se suelen emplear. Tal y como afirman Quijal-Zamorano et al. (2025) [12], de esta manera se reducen significativamente los costes computacionales y el tiempo requerido al modelizar.

El método INLA es útil para los LGMs (Modelos Gaussianos Latentes), que incluyen muchos modelos que son usados típicamente, como los modelos lineales generalizados. Lo que se hace es utilizar la aproximación de integrales de Laplace en densidades cercanas a la gaussiana con el fin de encontrar la distribución posterior marginal de cada variable del modelo. Si esto no es posible, en el caso de los LGM, se puede reformular el problema en otros subproblemas en los que sí se puede aplicar la aproximación de Laplace.

Existe una librería de R conocida como *INLA*. En ella se encuentra la función *inla()* que realiza el análisis por este método.

Una de las ventajas que tiene es la capacidad de estudiar modelos con retardo y con componente espacial, esto es, qué áreas colindantes tendrán efectos similares. Este tipo de modelos son los conocidos como SB-DLNM (Spatial Bayesian Distributed Lag Non-linear Models). Fueron presentados por Quijal-Zamorano et al. (2024) [14]. Se trata de un método que estima los efectos retardados en el tiempo a corto plazo provocados por exposiciones medioambientales en áreas pequeñas, teniendo en cuenta también su estructura espacial y geográfica, y cómo se afectan unos a otros.

Para el estudio del tema de esta sección se empleó R-INLA en un modelo SB-DLNM con un diseño de caso-cruce. Este diseño es útil y ampliamente usado para el estudio del impacto

diario de factores medioambientales en la salud humana. Consiste en utilizar como identificador un estrato (stratum, en inglés), que compara varias observaciones entre sí mismas en diferentes etapas de tiempo. Estudia si un evento ocurre debido a una exposición particular comparándola el día que ocurre con lo que pasa los días cercanos, conocidos como días de control. Esta es una manera de controlar la estacionalidad y la tendencia de los datos a nivel anual, sin recurrir a modelizar grandes series temporales.

En particular, para este trabajo, estratificamos los datos según la provincia, el año, el mes y el día de la semana. De esta manera, se están comparando las temperaturas y las defunciones diarias de una misma provincia con lo que ha ocurrido en el mismo día de la semana, mes y año. Cada estrato consta de varios días de control. Se excluyen aquellos estratos que no contienen ninguna muerte. Ejecutándolo de esta manera, ya se tiene en cuenta el efecto provocado por el día de la semana, que recordemos que se tuvo que incluir como variable explicativa en los modelos de la sección anterior.

Dada una provincia, se definió el conjunto de sus vecinos como aquellas otras provincias adyacentes, con las que comparte frontera. En las secciones anteriores se seleccionó como base cruzada para el modelo la que emplea B-splines con 4 grados de libertad tanto para la dimensión de la temperatura como la del retardo. Sin embargo, debido a la cantidad de provincias, datos y la complejidad de los modelos, se requería un elevado coste de tiempo y cálculo computacional, y al final no se obtuvieron resultados. Finalmente, se decidió aplicar un modelo más sencillo. En particular, en cada provincia se empleó un spline natural con 2 grados de libertad para ambas dimensiones, resultando en modelos de 4 parámetros, más sencillos que los de 16 que se intentaron implementar en un principio.

Se utilizó el método R-INLA, considerablemente más rápido que usar WinBUGS, que era lo que se solía emplear, y el modelo tardó en ejecutarse aproximadamente 27 minutos. Se calcularon los valores del RR para cada combinación entre la temperatura y el retardo de cada provincia. Tras centrar el valor del RR de cada lugar, en la figura 3.8 se muestra la distribución espacial del RR en el percentil 99 de temperatura. Lo que se hace es comparar, dentro de cada provincia, lo que ocurre cuando la temperatura se aleja de la temperatura óptima que se tiene como referencia, que definimos como la mediana de las temperaturas en cada sitio. Así, una provincia con un color más frío indica un exceso de la mortalidad atribuible a la temperatura bajo, y al contrario ocurrirá en provincias con colores cálidos. No se incluyen las ciudades autónomas de Ceuta y Melilla.

Lo primero que se observa en la leyenda es que los valores del RR son muy cercanos a 1 en cada lugar. Esto es debido a la simplicidad del modelo que se ha tenido que implementar para obtener los resultados. Pese a ello, sí que se visualiza un patrón entre las provincias. Las que presentan un color menos cálido, y un RR menor que 1 se concentran en Navarra, La Rioja, el sur del País Vasco y la parte sureste de Castilla y León, siendo Soria, Segovia y Ávila las que tienen un valor menor. La provincia que tiene el menor riesgo es Lugo. Por otro lado, las provincias del este y del sur de la península tienen más RR, aumentando el valor conforme más al sur se sitúan. La estructura espacial y la influencia de las provincias con aquellas con las que comparten frontera también se observa en Extremadura y el oeste de Andalucía donde se alcanza un mayor exceso de mortalidad por temperatura. Las provincias con los valores más altos son Huelva, Cáceres y Palencia. Tanto las islas Canarias como las Baleares no tienen ningún vecino que les afecte, pero las primeras tienen un color rojizo, y las segundas más azul.

Conociendo las limitaciones del modelo empleado, en el que no se pudo incluir más grados de libertad para otorgar una mayor flexibilidad, se puede apreciar la estructura espacial que se




Figura 3.15: Mapa de España por provincias con los valores del RR

buscaba al emplear un SB-DLNM. Además, cuanto más al sur nos situemos, hay más exceso de mortalidad por temperatura.

3.3.1. Análisis comparativo entre Lugo y Huelva

En esta parte del trabajo se va a comparar lo que ocurre en dos provincias distintas. Estas son Lugo y Huelva. Se han elegido así porque según el mapa de la figura 3.15 la primera tiene el menor valor del RR de todo el país, y la segunda uno de los más mayores. Se recuerda que pese al distinguido color, el RR de todas las provincias es próximo a 1, debido a cómo se han realizado los modelos y sus limitaciones. Se hará un pequeño análisis descriptivo de los datos de cada provincia con el fin de visualizar las primeras diferencias, y después se realizará la parte de la modelización con la posterior predicción y los consiguientes gráficos.

Se tienen una totalidad de 88032 observaciones de cada una de ambas provincias. La media de las defunciones observadas en Lugo es 3.413, y la mediana es 1.020. En Huelva, la media es 2.948 y la mediana vale 2.010. Lo más común en ambos casos es encontrarse días en los que no ha habido defunciones en determinados grupos de población. Destacamos que en Lugo el valor de la media es mayor que en Huelva, mientras que con la mediana es al revés, y es mayor en Huelva que en Lugo. Esto significa que en la provincia gallega hay más días en los que no fallece ninguna persona, pero los días en los que sí lo hacen, el número de fallecidos es más grande, afectando a la dispersión de los datos. En total, en los 10 años que se están estudiando, el número de defunciones totales observadas en Lugo es 102431, mientras que en Huelva se han contabilizado 91020. Dividiendo estos números según el grupo de población por edad, se dan los números que se ven en el cuadro 3.1.

Observamos que en la provincia andaluza se tienen más defunciones en todos los grupos, exceptuando en el de más de 85 años. Todo lo mencionado anteriormente nos muestra que en Huelva es más normal que existan defunciones en cada uno de los grupos y que fallecen a lo largo del año. Mientras tanto, en Lugo el grupo del que más personas mueren, con diferencia, es el de los más mayores, y fallecen más concentrados en un periodo de tiempo dado.

	0-14	15-44	45-64	65-74	75-84	+85
Lugo	130	1111	8209	10537	24603	57891
Huelva	298	2011	11893	13658	26133	37008

Cuadro 3.1: Tabla comparativa del número de defunciones observadas de Lugo y Huelva por grupos de edad.

Estudiando ahora las temperaturas diarias medias, mínimas y máximas en ambas, también se observan diferencias. En Lugo, la media y la mediana de las temperaturas medias diarias valen 12.94 y 12.85, respectivamente. Para las temperaturas mínimas, se tiene 7.36 para la media y 7.6 para la mediana, y para las máximas, sus valores son 18.51 para la media y 18.10 la mediana. Por otra parte, en Huelva, para las temperaturas medias diarias se tiene una media de 19.11 grados y una mediana de 18.80. Para las mínimas, 13.11 es su media y 13.40 es su mediana. Para las máximas, 25.11 la media y 24.50 la mediana.

En ambos casos se nota que la dispersión de los datos es semejante. Existen tanto días calurosos como días fríos, sin que existan demasiados días únicos con tiempo demasiado extremo como para modificar la media de los datos. Notamos también que los días en Lugo son más fríos que los de Huelva. La media de las temperaturas máximas en Lugo es ligeramente menor que el promedio de las temperaturas medias diarias en Huelva. La mínima de un día de la provincia andaluza equivale a la media de un día en Lugo. Esto también tiene un efecto en la mortalidad de cada sitio. La gente que viva en el norte será más propensa a tolerar los días fríos y sufrirán más los días de calor. Al contrario ocurre en el sur, donde la gente se acostumbra a los días cálidos y no tanto a los más frescos.

Ya se han comparado los datos de ambos sitios y ya se han notado las primeras diferencias climáticas y de mortalidad. A cada una de estas bases de datos se le va a aplicar a continuación un modelo de retardo distribuido en el que la base cruzada está compuesta por B-splines con 4 grados de libertad para la dimensión de la temperatura y la del retardo. Las variables explicativas del modelo van a seguir siendo la base cruzada definida, el día de la semana y el spline natural para la fecha, con 7 grados de libertad por año estudiado. Tras calcular todo ello se hace la predicción y los gráficos correspondientes, obteniendo las superficies y gráficos de efecto acumulado que se pueden ver en la figura 3.16. Dados los valores de las temperaturas, se han puesto 15 grados de temperatura como valor central para la predicción de Lugo, y 20 grados para la de Huelva.

Se observa...

3.4. Análisis del exceso de mortalidad atribuible a la temperatura en Navarra

En esta sección se va a realizar un análisis similar a lo de las secciones anteriores, pero centrado en la provincia de Navarra. Se seleccionarán todos los datos de MoMo desde el 2015 al 2024, ambos incluidos, pertenecientes a Navarra. Se procederá de manera semejante al análisis







Figura 3.16: Gráficos del modelo cuya base está formada por B-splines con 4 grados de libertad para ambas dimensiones aplicado a la provincia de Lugo (arriba) y a la de Huelva (abajo).

que se hizo de toda España. En primer lugar un análisis descriptivo para conocer más profundamente los datos de los que se disponen. Después, se buscará el modelo que mejor se aproxime y se estudiarán sus predicciones de forma general primero, y por subgrupos de población después.

Tras hacer el filtrado de los datos, se disponen de 88032 observaciones referentes a la región de Navarra. La información de las temperaturas máximas, medias y mínimas de cada día son sacadas de la estación meteorológica del aeropuerto de Pamplona. Por otra parte, la información de las defunciones observadas de cada grupo en cada día pertenecen a toda la región en general.

Hacemos el análisis descriptivo de los datos, del que se desprenden estas observaciones. Como ya conocíamos del estudio de los datos de todo el país, cada fila de la base de datos se corresponde con las defunciones observadas cada día para cada grupo de población según su sexo y su edad. Así, se tienen 29344 observaciones de hombres, mujeres, y ambos, y 11044 datos de cada grupo de edad. Fijándonos en la variable de las defunciones observadas, la mediana de los datos vale 2.040, mientras que la media es 3.951, casi el doble. Por tanto, las defunciones no están igualmente distribuidas. Muchos días no se han observado fallecimientos en algunos de los grupos, mientras que otros días sí. El máximo se alcanza el día que se notificaron hasta 56 muertes en Navarra. La mediana de las temperaturas medias toma el valor de 13.20, y la media es 13.63. La mediana de las temperaturas mínimas es 7.600 y la media 7.576. La mediana de las temperaturas máximas es 19.10 y la media es 19.69. En todas estas variables ambos valores son parecidos, luego están igualmente distribuidas en el tiempo. Para finalizar este análisis veamos el número de defunciones observadas que se corresponden con cada grupo de población según la edad, y como ya se esperaba, el número aumenta conforme la edad es mayor. Para el grupo conformado por niños de entre 0 y 14 años se han notificado, a lo largo de los 10 años, solo 400 defunciones en Navarra. Del grupo de las personas que tienen entre 15 y 44 años hay 1990 fallecimientos, y esta número sigue aumentando con la edad, llegando 61721 muertes en el grupo de más de 85 años. A la hora de hacer el análisis por subgrupos de edad, la falta de observaciones en los grupos más jóvenes supondrá un problema para el modelo para ajustar los datos.

Se ha comprobado que los datos están bien seleccionados. Las observaciones realizadas son las mismas que se hicieron en el estudio de toda España. A continuación realizaremos la parte de la modelización. Vamos a ajustar primero los datos que se tienen con el modelo obtenido en el análisis estatal y con el que se estudió lo que ocurría a nivel provincial. Recordemos que la base cruzada elegida tomaba B-splines con 4 grados de libertad tanto para la dimensión de la temperatura como para la del retardo. El retardo máximo tomado era de 30 días, y el modelo era un modelo generalizado de quasipoisson que estudiaba las defunciones observadas tomando como variables explicativas la base cruzada definida antes, el día de la semana y el spline natural de la fecha de defunción, con 7 grados de libertad por año estudiado. Al hacer la predicción, se toma el valor de 20 grados como valor central. Se aplica esto únicamente a los datos de Navarra y se obtienen los gráficos que se observan en la figura 3.17.

A primera vista, la superficie obtenida parece no ajustarse demasiado bien a los datos, debido a las constantes subidas y bajadas del terreno. Sin embargo, fijándonos en el eje correspondiente al valor del RR, vemos que realmente tampoco se despega del 1, puesto que los límites que se han dibujado son 0.95 y 1.05. Esto se debe a la falta de datos. Cuando se estaba estudiando España en general, se disponían de millones de datos entre todas las provincias. Reduciendo el estudio solamente a Navarra, el número ha decrecido hasta menos de 100000 observaciones. Si vemos el gráfico de efecto acumulado, el RR aumenta en los extremos, cuando la temperatura




Figura 3.17: Gráficos correspondientes al modelo cuya base utiliza B-splines con 4 grados de libertad para ambas dimensiones.

baja de 0 grados, o sube de 25, y alcanza el pico más bajo cuando la temperatura ronda los 5 grados. Recordemos que este gráfico muestra el efecto de las exposiciones a lo largo de los 30 días de retardo máximo que se han incluido en la base cruzada. Además, notamos también que los intervalos de confianza calculados son amplios.

En el análisis de España se disponía de un mayor número de datos, pero también de todo tipo de regiones, que incluían zonas con distintos climas, más cálidos por el sur, y más fríos en el norte. Por ello, el modelo que se consideraba apto antes puede no resultar igual de útil para unos datos más centralizados, pertenecientes a un espacio mucho menor. Procederemos a continuación a hacer un nuevo análisis de sensibilidad, estudiando el QAIC de los modelos, para encontrar aquel que se adapte de mejor manera a lo que se tiene.

Los resultados de dicho análisis han sido que el mejor modelo es aquel cuya base contiene B-splines con 4 grados de libertad para ambas dimensiones, y que ya se ha probado. Valores del QAIC semejantes se logran al cambiar los B-splines por splines naturales, o variando entre los 3 y los 4 grados de libertad. Sin embargo, dada la poca variabilidad que existe, se ha optado finalmente por el modelo anterior.

Como anotación, nos damos cuenta de que el QAIC optaba por modelos con mayor número de grados de libertad cuando hablábamos de nivel estatal. A nivel provincial, en Navarra, ocurre lo contrario y el QAIC sale menor cuantos menos grados de libertad haya.

Visualizaremos ahora distintos cortes realizados a la superficie para estudiar lo que ocurre bajo ciertos valores de la temperatura y del retardo. Los resultados se ven en la figura 3.18.

Notamos que cuando el retardo es nulo, en el momento inmediatamente posterior a la exposición, el valor del RR para temperaturas bajas se sitúa entre 0.9 y 1. Dicho valor bajo esas mismas temperaturas va aumentando conforme el retardo va subiendo. Entre el retardo 5 y 11, el RR ya es mayor que 1. Por otra parte, la curva correspondiente a la parte del calor se va aplanando cuanto mayor sea el retardo.




Figura 3.18: Gráficos de efecto que muestran la evolución del RR en los retardos 0, 3, 5 y 11 (columna izquierda), y en los valores 0, 5, 28 y 31 de la temperatura (columna derecha).




Figura 3.19: Gráficos correspondientes al subgrupo de población de Navarra que tiene entre 0 y 14 años.

Observando ahora lo que ocurre con los gráficos bajo ciertos valores de la temperatura, se observa que cuando la temperatura es de 0 o 5 grados, el RR aumenta y se sitúa por encima del 1 entre el retardo 5 y el 12, aproximadamente, llegando a alcanzar el pico en el retardo 9. Por otro lado, bajo altas temperaturas, el RR alcanza su mayor valor los primeros 3 o 4 días de retardo. Con 28 grados, el RR es ligeramente mayor que 1, pero va aumentando respecto a una mayor subida de la temperatura. Con 31 grados, se observa una mayor pendiente durante los primeros días.

De aquí se desprende que los efectos provocados por las altas temperaturas ocurren de una manera más inmediata, durante los primeros 4 días desde la exposición, reduciendo su impacto según pasan los días. Los efectos provocados por el frío tardan más en manifestarse. Los primeros días después de la exposición no son peligrosos, pero el riesgo aumenta a partir del quinto día. Después de la segunda semana tras haber estado expuesto, el RR es 1, y no existe diferencia entre haber sufrido un día con una temperatura extrema o no.

A continuación, terminaremos este estudio con un análisis según los subgrupos de edad. Se ha aplicado el modelo anterior para cada uno de los grupos de población. Como ya se mencionó en párrafos anteriores, la falta de defunciones en los más jóvenes lleva a una mala aproximación por parte del modelo, y al tratar de hacer una predicción, resultan gráficos raros e incoherentes. Esto se pueden visualizar desde la figura 3.19 a la 3.25. Solamente podemos considerar útiles los gráficos relativos al grupo de personas de más de 65 años y al de mayores de 85 años. Estos son los dos grupos de los que se han contabilizado un mayor número de defunciones, con 106250 observaciones para el de más de 65, y 61721 muertes del de más de 85.

Los gráficos de efecto acumulado de estos dos grupos (3.24 y 3.25) presentan evoluciones similares. El mayor valor del RR se alcanza en los extremos, por debajo de los 0 grados y por encima de los 27 de temperatura media. Entre los 11 y los 23 grados se ve una curva muy plana, cercana a un RR igual a 1. Entre los 0 y los 13, aproximadamente, el RR decae bajo




Figura 3.20: Gráficos correspondientes al subgrupo de población de Navarra que tiene entre 15 y 44 años.




Figura 3.21: Gráficos correspondientes al subgrupo de población de Navarra que tiene entre 45 y 64 años.




Figura 3.22: Gráficos correspondientes al subgrupo de población de Navarra que tiene entre 65 y 74 años.




Figura 3.23: Gráficos correspondientes al subgrupo de población de Navarra que tiene entre 75 y 84 años.




Figura 3.24: Gráficos correspondientes al subgrupo de población de Navarra que tiene más de 85 años.




Figura 3.25: Gráficos correspondientes al subgrupo de población de Navarra que tiene más de 65 años.

el 1. Recordemos que se está mostrando el efecto acumulado tras una exposición a una cierta temperatura a lo largo de los días de retardo incluidos. Por ello, esto nuevamente muestra que los efectos de una exposición al frío tardan más en manifestarse que aquellos provocados por días calurosos.

Lo anterior también se puede deducir de las superficies de ambos grupos. Son bastante planas. Para el calor, el RR aumenta más los primeros días de retardo, y para el frío, se llega a un pico unos días de retardo más tarde.

Capítulo 4

Conclusiones

Antes de comenzar a hablar sobre las conclusiones del trabajo, hagamos un breve resumen de lo que se ha tratado a lo largo de este. En primer lugar se presentó y se habló de los modelos de retardo distribuido, de su método de estimación y de su aplicación en el software R. Después, se introdujo el conjunto de los datos que se iban a estudiar y se procedió a analizar el exceso de mortalidad atribuible a la temperatura a nivel estatal, en toda España en su conjunto. Se hicieron varias pruebas y análisis para llegar al modelo que parecía mejor y más adecuado.

Posteriormente, ese análisis del exceso de mortalidad se trasladó a nivel provincial. Para ello se empleó el novedoso método de aplicar el método R-INLA a un modelo SB-DLNM. Tras estratificar y preparar los datos, y ejecutar el modelo, se plasmaron los resultados en un mapa de España dividido por provincias y coloreado según el valor del riesgo relativo. Se comparó una provincia cálida con una fría analizando los datos de mortalidad.

Por último, se realizó un análisis de mortalidad atribuible a la temperatura únicamente en la región de Navarra por el mismo método.

Se ha conseguido probar que los modelos no lineales de retardo distribuido son una poderosa herramienta si se quiere estudiar un resultado a lo largo del tiempo provocado por un determinado factor, y que no se produce de manera inminente. Sin embargo, también se ha podido comprobar la necesidad que existe de poseer muchos y buenos datos. Cuando se estaba realizando el estudio nacional, se disponía de una base de datos con millones de observaciones entre todas las provincias. A la hora de elegir el modelo, el QAIC tendía a premiar aquellos con un mayor número de grados de libertad. Por otra parte, en el análisis provincial de Navarra, donde se disponían de menos de 100000 datos, los modelos que parecían mejores eran aquellos más sencillos. El resultado gráfico obtenido en ambos casos variaba mucho. En el caso de España, las observaciones se veían de una manera más clara que en el caso de Navarra.

Otro aspecto a tener en cuenta y que se podría mejorar en un proyecto futuro son las variables necesarias para explicar el modelo. Vimos que en otros trabajos parecidos (Gasparrini et al. (2010) [3]) se incluyen más variables explicativas en el modelo, tales como factores medioambientales, entre otros, que son datos de los que no disponíamos en este trabajo. Esa es la causa de que la modelización realizada posea un amplio margen de mejora, y de que se hayan obtenido gráficos y superficies extraños en ciertos puntos, como por ejemplo en las esquinas, es decir, bajo temperaturas muy altas o muy bajas, o en los primeros y últimos días de retardo, donde al modelo le resulta complicado aproximar los datos. Pese a ello, se ha sido capaz de obtener un resultado. Tanto a nivel estatal como provincial, los efectos provocados por una exposición a una temperatura muy calurosa ocurren durante los 5 primeros días de retardo desde la exposición. Los efectos provocados por una temperatura muy fría tardan más en manifestarse, más

o menos entre el día 7 y 15 de retardo. Las temperaturas umbrales a partir de las cuales se ha visto que aumenta considerablemente el riesgo de fallecimiento son los 5 y los 35 grados. Un día en el que la temperatura se sitúe entre esos dos valores se considera sin riesgo.

A la hora de hacer el análisis por subgrupos de población en función de la edad, se ha visto que los hechos del párrafo anterior ocurren para cualquier persona, independientemente de la edad. Sin embargo, sí que se demostró que los grupos más mayores tienen un mayor riesgo de fallecer debido a las temperaturas. Se considera que hay que incrementar la seguridad y el cuidado a partir de los 65 años. Cuando se realizó este tipo de análisis para España en su totalidad, no hubo ningún problema al realizar la modelización y los gráficos correspondientes dada la gran cantidad de datos de cada grupo de los que se disponía, pero realizando el mismo análisis para la provincia de Navarra, no se pudo obtener nada en claro de los resultados logrados para los grupos de menor edad. Esto pasó porque no había prácticamente registros de muertes en la base de datos para estos subgrupos. Finalmente, la conclusión es que conforme se tiene más edad, más fallecimientos hay, y por tanto, más muertes atribuibles al exceso de temperatura.

Se dedicó una sección entera de la ilustración para analizar el exceso de mortalidad atribuible a la temperatura en las diferentes provincias de España. Aplicar el método R-INLA a un modelo SB-DLNM es algo que a día de hoy apenas se ha empleado. En proyectos semejantes (Quijal-Zamorano et al. (2025) [12]) se ilustra que un modelo igual, con más de 70 regiones y 12 parámetros, al que se aplicó la misma metodología tardó apenas unos minutos en ser resuelto con un ordenador muy potente. En nuestro trabajo, tras varios intentos, se trató de resolver un modelo con 50 provincias y 16 parámetros con el fin de explicar la componente espacial en su totalidad, pero finalmente no se pudo debido al alto coste de tiempo y cálculo computacional requerido. En cambio, para lograr algún resultado se simplificó el modelo reduciendo el número de grados de libertad a 2 en la dimensión de la temperatura y en la del retardo, luego obteniéndose 4 parámetros en total. En este caso tardó 27 minutos en ejecutarse completamente.

Dado que no se pudo ejecutar el modelo completo, los valores del riesgo relativo obtenidos son todos muy próximos al 1. Al colorear el mapa de España por provincias según estos números se visualizaba la estructura espacial formada. Las provincias del sur y las más próximas al mar Mediterráneo presentaban riesgos relativos altos. Por otro lado, la parte más norte y al oeste del país se veían más frías, y por ende con un menor riesgo relativo. Se comparó la provincia con el menor valor del RR obtenido, Lugo, con otra con uno de los valores del RR más grandes, Huelva. Ocurre lo mismo que con Navarra, dada la escasez de los datos y de las variables explicativas del modelo, los gráficos obtenidos eran planos y semejantes. Se concluyó que no existía una diferencia demasiado grande entre ellas, lo que está provocado por la simplicidad con la que se tuvo que hacer el modelo SB-DLNM.

Para finalizar, recalcar que en muchas partes del trabajo se ha tenido que optar por simplificar los modelos y la manera de realizar el estudio debido a diversos factores. Aun así, pese a la aparente simplicidad, se han logrado ciertos resultados útiles, como los valores de las temperaturas a partir de los cuales hay que empezar a tener cuidado, o con cuántos días de retardo aparecen los síntomas de una exposición al frío o al calor. En este proyecto también se han utilizado métodos novedosos para tener en cuenta el efecto espacial que tienen las provincias entre ellas. Esto prueba la utilidad y la potencia de los métodos y los modelos empleados, que solo se pueden mejorar en proyectos futuros con las variables y los datos, y sus cantidades, adecuadas.

4.1. Material Suplementario

El código de R empleado durante el trabajo para obtener todos los resultados se encuentra en el repositorio de GitHub: https://github.com/AlonsoPueyo/TFM_Alonso_Pueyo

Bibliografía

- [1] ACHEBAK H, DEVOLDER D, BALLESTER J (2018), *Heat-related mortality trends under recent climate warming in Spain: A 36-year observational study*. *PLoS Med*15(7): e1002617, <https://doi.org/10.1371/journal.pmed.1002617>
- [2] LINARES, C., DÍAZ, J. (2008), *Temperaturas extremadamente elevadas y su impacto sobre la mortalidad diaria según diferentes grupos de edad*. *Gaceta Sanitaria*, 22(2), 115-119.
- [3] GASPARRINI, A., ARMSTRONG, B. AND KENWARD, M.G. (2010), *Distributed lag non-linear models*. *Statist. Med.*, 29: 2224-2234, <https://doi.org/10.1002/sim.3940>
- [4] GASPARRINI A. (2011), *Distributed Lag Linear and Non-Linear Models in R: The Package dlnm*. *Journal of statistical software*, 43(8), 1–20.
- [5] GASPARRINI, A., ARMSTRONG, B. (2013), *Distributed lag non-linear models in R: the package dlnm*. *London School of Hygiene and Tropical Medicine, UK. dlnm version*, 1(7), 05-16.
- [6] GASPARRINI, A., ARMSTRONG, B., GASPARRINI, M. A. (2013), *Package ‘dlnm’*. 2017-01-16)[2017-10-05] <http://cran.r-project.org/web/packages/dlnm/dlnm.pdf>
- [7] BODEGAS DÍEZ, A. (2022), *Modelos Espaciales y Espaciotemporales en Disease Mapping*, UPV/EHU, MÁSTER UNIVERSITARIO EN MODELIZACIÓN E INVESTIGACIÓN MATEMÁTICA, ESTADÍSTICA Y COMPUTACIÓN, LEIOA
- [8] GOYENA BAROJA, H. (2021), *Predicciones a corto plazo en series temporales de alta frecuencia*, UNIVERSIDAD PÚBLICA DE NAVARRA, MÁSTER UNIVERSITARIO EN MODELIZACIÓN E INVESTIGACIÓN MATEMÁTICA, ESTADÍSTICA Y COMPUTACIÓN
- [9] BERGARA MARTÍNEZ, M. (2024), *Validación de modelos predictivos espacio-temporales de la incidencia y mortalidad por cáncer*, UPV/EHU, MÁSTER UNIVERSITARIO EN MODELIZACIÓN E INVESTIGACIÓN MATEMÁTICA, ESTADÍSTICA Y COMPUTACIÓN, LEIOA
- [10] RUTTEN, S., ESPINASSE, M., DUARTE, E., NEYENS, T., FAES, C. (2025), *On the lagged non-linear association between air pollution and COVID-19 cases in Belgium*. *Spatial and Spatio-temporal Epidemiology*, 52, 100709.
- [11] GONZÁLEZ DÍAZ, E. (2017), *Funciones Spline*, UNIVERSIDAD DE LA LAGUNA, GRADO EN MATEMÁTICAS, LA LAGUNA

- [12] QUIJAL-ZAMORANO, M., MARTINEZ-BENEITO, M. A., BALLESTER, J., MARÍ-DELL'OLMO, M. (2025), *Spatial Bayesian distributed lag non-linear models with R-INLA*. *International Journal of Epidemiology*, 54(4), dyaf120
- [13] RUE, H., RIEBLER, A., SØRBYE, S. H., ILLIAN, J. B., SIMPSON, D. P., LINDGREN, F. K. (2017), *Bayesian computing with INLA: a review*. *Annual Review of Statistics and Its Application*, 4(1), 395-421
- [14] QUIJAL-ZAMORANO, M., MARTINEZ-BENEITO, M. A., BALLESTER, J., MARÍ-DELL'OLMO, M. (2024), *Spatial Bayesian distributed lag non-linear models (SB-DLNM) for small-area exposure-lag-response epidemiological modelling*. *International journal of epidemiology*, 53(3), dyae061
- [15] WU, Y., LI, S., GUO, Y. (2021), *Space-time-stratified case-crossover design in environmental epidemiology study*. *Health Data Science*, 2021, 9870798