

Estudio del impacto de las altas temperaturas en la mortalidad diaria en España

Máster Universitario en Modelización e
Investigación Matemática, Estadística y
Computación



Universidad
Zaragoza

Alonso Pueyo Gómez
Trabajo de fin de máster
Universidad de Zaragoza
Tutora: Jaione Etxeberria

26 de agosto de 2025

Resumen

Índice general

Resumen	III
1. Introducción	1
2. Marco Teórico	3
2.1. Regresión de Poisson	3
2.2. Modelos de retardo distribuido (dlm)	3
2.3. Modelos de retardo distribuido no lineales (dlnm)	4
2.4. Método de estimación de los modelos mediante el paquete <i>dlnm</i>	6
3. Ilustración de los modelos <i>dlnm</i> con datos de mortalidad diaria y temperaturas en España	9
3.1. Fuente de datos	9
3.2. Análisis del exceso de mortalidad atribuible a la temperatura en España	10
3.3. Análisis del exceso de mortalidad atribuible a la temperatura por provincias	19
3.4. Análisis del exceso de mortalidad atribuible a la temperatura en Navarra	21
3.5. Modelización	24
4. Conclusiones	29
4.1. Material Suplementario	29
Bibliografía	31

Capítulo 1

Introducción

El cambio climático es un problema que preocupa a la sociedad desde hace varios años. Cada vez se registran estaciones más calurosas, con olas de calor más frecuentes e intensas, lo que repercute directamente en la salud de la población. Algunos grupos son especialmente vulnerables a estos efectos, como es el caso de las personas mayores. Diversos estudios han evidenciado la relación entre la exposición a altas temperaturas y el aumento de la mortalidad. El trabajo de Linares y Díaz (2008) [2] abordó la relación entre temperatura y mortalidad utilizando una metodología basada en modelos ARIMA y regresión de Poisson. Posteriormente, en 2010, Gasparrini, junto a Armstrong y Kenward [3], introdujo un nuevo enfoque metodológico que se utilizará a lo largo de este trabajo, presentándolo mediante un ejemplo aplicado a la ciudad de Nueva York. Entre 2011 y 2013, Gasparrini y Armstrong publicaron varios artículos [4, 5] en los que detallaron la librería desarrollada en RStudio, diseñada para implementar los modelos propuestos en su trabajo anterior. Esta herramienta ha facilitado nuevas investigaciones en el campo, como la realizada por Achebak, Devolder y Ballester (2018) [1], quienes aplicaron estos modelos para estudiar la mortalidad asociada al calor en España. En el año 2004, el Ministerio de Sanidad del Gobierno de España desarrolló el sistema de monitorización MoMo (https://momo.isciii.es/panel_momo/), que tiene el objetivo de identificar desviaciones de mortalidad diaria observada respecto a lo esperado según hechos pasados. Esta será la fuente principal de los datos.

Cuando se está estudiando la relación entre un efecto y sus consecuencias, se pueden emplear los modelos *dlnm* (Distributed Lag Models, en inglés) [3]. Resultan muy útiles cuando se está estudiando la estructura de retardo de efectos lineales. Cuando no existe tal linealidad, poseen limitaciones. Una solución consiste en relajar los supuestos y extenderlos a unos modelos más complejos, los *dlnm*. Por ejemplo, la relación que existe entre la exposición a una temperatura extremadamente alta y la mortalidad diaria no es lineal. El efecto que el exceso de temperatura provoca tras una exposición prolongada no tiene por qué presentarse de forma inmediata. Al contrario, los efectos suceden con cierto retardo, tardando varios días después de la exposición en aparecer. Es por ello que van a ser útiles los modelos que tienen en cuenta tanto los efectos inmediatos como los retardados de la temperatura sobre la mortalidad, como los *dlnm* (Distributed Lag Non-Linear Models) [3]. Lo que hacen es definir una dimensión temporal adicional a través de lo que se conoce como base cruzada, un espacio bidimensional de funciones que describe tanto la forma de la relación como la dimensión del retardo, y que determina la estructura temporal del efecto estudiado, que en el caso de este trabajo, es la mortalidad que se atribuye a la exposición a una alta temperatura.

El objetivo principal de este trabajo es analizar la mortalidad atribuible al calor extremo en diferentes grupos de edad y regiones de España, con el fin de identificar qué poblaciones presentan una mayor vulnerabilidad. Esta información resulta esencial para orientar futuras políticas de salud pública y planes de prevención ante olas de calor.

El TFM se organiza de la siguiente manera: en la sección 2 se presenta el marco teórico y la descripción de los modelos utilizados, así como la librería empleada. La sección 3 describe los datos y el análisis exploratorio realizado. En la sección 4 se exponen los resultados obtenidos a partir de la aplicación de los modelos y sus correspondientes predicciones. Finalmente, en la sección 5 se discuten las principales conclusiones y líneas futuras de investigación.

Capítulo 2

Marco Teórico

Este capítulo presenta el marco metodológico que sustenta el análisis desarrollado en este trabajo, comenzando con los modelos lineales generalizados (*glm*) y avanzando hacia los modelos de retardo distribuido no lineales (*dlnm*), que serán la base del estudio.

2.1. Regresión de Poisson

Sea Y_t el número de defunciones observadas en el día t , para $t = 1, \dots, n$. Dado que se trata de datos de conteo, se modelizan mediante una regresión de Poisson dentro del marco de los modelos lineales generalizados (*glm*), utilizando una función de enlace logarítmica:

$$\log(\mu_t) = \alpha + \sum_{j=1}^J s_j(x_{tj}; \beta_j) + \sum_{k=1}^K \gamma_k u_{tk}, \quad (2.1)$$

donde:

- $\mu_t = E(Y_t)$ es el número esperado de muertes en el día t .
- $s_j(x_{tj}; \beta_j)$ son funciones no paramétricas que permiten el suavizado de la curva (como los splines), y por tanto establecen relaciones no lineales entre las covariables x_{tj} y la variable respuesta.
- u_{tk} son variables explicativas lineales (tales como el día de la semana, la tendencia o la estacionalidad).
- γ_k son los coeficientes asociados a los predictores lineales.

La función de enlace logarítmica asegura que las predicciones del número esperado de muertes sean positivas.

2.2. Modelos de retardo distribuido (*dlnm*)

La exposición a temperaturas extremas no genera efectos inmediatos, sino que estos pueden manifestarse con varios días de retraso. Para modelizar este comportamiento, se recurre a los modelos de retardo distribuido (*dlnm*), que permiten distribuir el efecto de una exposición a lo largo de varios días.

Definimos un vector de exposiciones pasadas para el día t como:

$$q_t = (x_t, x_{t-1}, \dots, x_{t-L})^T \quad (2.2)$$

donde x_{t-l} es la temperatura observada l días antes (desfase) y L es el máximo número de días de retardo considerados. Un modelo *dlnm* simple puede expresarse como:

$$\eta_t = \sum_{l=0}^L \delta_l x_{t-l} \quad (2.3)$$

donde δ_l representa el efecto de la temperatura con un retardo de l días, y η_t es el predictor lineal del modelo, que corresponde a la transformación logarítmica de la media esperada μ_t de la variable respuesta Y_t , el número de defunciones diarias.

Sin embargo, este enfoque puede sufrir de colinealidad entre las variables x_{t-l} , ya que las temperaturas en días consecutivos tienden a estar altamente correlacionadas. Para contrarrestar este problema, se introducen restricciones sobre los coeficientes δ_l , modelándolos como funciones suaves mediante splines o polinomios.

De manera general, los modelos *dlnm* se formulan como sigue. Sobre una base se especifican los efectos distribuidos a lo largo de los retardos. En notación matricial, los efectos retardados se definen así:

$$s(x_t; \beta) = q_t^T C \beta \quad (2.4)$$

donde C es la matriz de variables base que se obtienen al aplicar las funciones base a los retardos, y β es el vector de parámetros que no se conocen.

En el modelo general de regresión lineal generalizada con función de enlace logarítmica, la relación entre q_t y η_t se establece mediante funciones base que capturan tanto la no linealidad como los efectos retardados. Estas funciones se combinan para formar un predictor que describe el efecto total de la temperatura en el tiempo t . Así, se llega a la expresión:

$$\eta_t = \alpha + r_t^T C \beta + \sum_{k=1}^K \gamma_k u_{tk} \quad (2.5)$$

donde r_t es la transformación de q_t a través de las funciones base y las variables u_{tk} son otros predictores con efecto lineal.

Dependiendo de cómo esté definida la matriz C , estamos hablando de un tipo de *dlnm* u otro. Si C es la matriz identidad, entonces se trata del modelo sin restricciones que define (2.3).

2.3. Modelos de retardo distribuido no lineales (dlnm)

A continuación, se presenta el modelo general empleado en este proyecto. Está diseñado como un modelo jerárquico que estudia las muertes diarias producidas por un exceso de calor. Decimos que sigue una jerarquía porque se definen unos elementos iniciales, que luego se combinan en un objeto predictor. En particular, se siguen los siguientes pasos. Primero se define la dimensión de la exposición, que en nuestro caso es la temperatura. Se define cómo responde la variable de la mortalidad frente a los diferentes valores de la temperatura. Después, se precisa cómo el riesgo de fallecer se distribuye a lo largo del tiempo. Esta es la dimensión del retardo,

donde se modela cómo varía el efecto conforme van pasando los días tras la exposición. Finalmente, las dos dimensiones anteriores se combinan de forma jerárquica generando una matriz de diseño, la base cruzada, que funciona como predictor en el modelo. Se trata de un espacio bidimensional de funciones que describen al mismo tiempo la forma de la relación entre la exposición y la respuesta, y los efectos de retardo distribuidos. Una base cruzada se elige mediante la selección de dos conjuntos de funciones de base, uno para la exposición, en nuestro caso la temperatura, y otro para el retardo. Estos se combinarán para generar lo que se conoce como funciones de base cruzada.

La principal limitación de los *dlnm* es la suposición de linealidad entre la exposición y la respuesta. Sin embargo, en el caso de la temperatura, la relación con la mortalidad no es lineal. Por ello, se emplean los modelos de retardo distribuidos no lineales (*dlnm*) propuestos por Gasparrini et al. (2010) [3], que permiten modelar simultáneamente la forma no lineal de la exposición y su distribución en el tiempo.

En los *dlnm*, el efecto total de la temperatura sobre la mortalidad en el día t se expresa como la suma de los efectos de las temperaturas de días anteriores, es decir:

$$\eta_t = \sum_{l=0}^L f(x_{t-l}, l) \quad (2.6)$$

donde $f(x, l)$ es una función bivariada que representa el efecto de la temperatura x con un retardo de l días. Esta función se modela como la combinación de dos funciones base, una para la temperatura y otra para el retardo. Se escribe como:

$$f(x, l) = \sum_{i=1}^I \sum_{j=1}^J \beta_{ij} \cdot B_i(x) \cdot C_j(l) \quad (2.7)$$

donde:

- $B_i(x)$ son las funciones base que representan la forma de la relación en el eje de la temperatura.
- $C_j(l)$ son las funciones base que describen la distribución del efecto en el eje de los retardos.
- β_{ij} son los parámetros a estimar.
- I y J son los números de funciones base en cada dimensión.

Esta formulación permite capturar de manera flexible la relación entre la exposición a temperaturas extremas y la mortalidad, incluyendo patrones de retardo complejos y respuestas no lineales, lo que la convierte en una herramienta fundamental para evaluar el impacto sanitario del cambio climático.

Definiendo la matriz C como en la sección anterior, un modelo *dlnm* se especifica de manera general como:

$$s(x_t; \beta) = r_t^T C \beta = \sum_{i=1}^I \sum_{j=1}^J r_{ti}^T c_j \beta_{ij}, \quad (2.8)$$

donde r_t es el vector de las componentes de la temperatura transformadas según las funciones de base.

2.4. Método de estimación de los modelos mediante el paquete *dlnm*

Los parámetros del modelo se estiman mediante el método de máxima verosimilitud, propio de los modelos lineales generalizados. En particular, para una regresión de Poisson con función de enlace logarítmico, se maximiza la función de verosimilitud definida por la distribución de Poisson de los conteos observados.

Sea Y_t el número de defunciones en el día t , y $\mu_t = E(Y_t)$ la media condicionada a las covariables y a la exposición retardada. El modelo se expresa como:

$$\log(\mu_t) = \alpha + X_t\beta$$

donde X_t es la matriz de diseño construida a partir de las bases cruzadas y otras covariables, y β el vector de parámetros que se desean estimar. Así, la función de verosimilitud es:

$$L(\beta) = \prod_{t=1}^n \frac{e^{-\mu_t} \mu_t^{Y_t}}{Y_t!}$$

Maximizando el logaritmo de esta función se obtienen las estimaciones de β .

Cuando se han realizado varios modelos diferentes y se quiere seleccionar el que mejor se ajusta a los parámetros del problema, se calcula el valor del Criterio de Información de Akaike (AIC) o el Criterio de Información Bayesiano (BIC). Ambas son medidas estadísticas útiles para la evaluación del equilibrio entre el ajuste y la complejidad del modelo. Un valor menor indica un mejor ajuste. Se calculan como sigue:

$$AIC = -2L(\beta) + 2k$$

$$BIC = -2L(\beta) + k \cdot \log(n)$$

siendo $L(\beta)$ la función de verosimilitud anterior, k el número de parámetros del problema, y n el número de observaciones.

Cuando se presenta un modelo de Poisson sobredisperso (quasi-Poisson), donde $E(X) = \mu$ y $Var(X) = \phi\mu$, con $\phi > 1$ el parámetro de sobredispersión, se han de modificar los criterios anteriores, que ahora se calculan:

$$QAIC = -2L(\beta) + 2\phi k$$

$$QBIC = -2L(\beta) + \phi k \log(n)$$

El parámetro de sobredispersión de un modelo se obtiene como la relación entre la desviación residual y los grados de libertad.

Para implementar los modelos descritos en el trabajo utilizaremos el paquete *dlnm* en R, desarrollado por Antonio Gasparrini y colaboradores [4, 5, 6]. Este paquete permite construir y ajustar modelos de regresión con bases cruzadas para analizar efectos no lineales y con retardos

distribuidos en series temporales, principalmente en el contexto de regresiones de Poisson para datos de conteos.

El paquete facilita la creación de bases de funciones para la variable de exposición y para los retardos, y las combina en lo que se denomina una base cruzada, que modela simultáneamente la no linealidad y el efecto retardado. Para ello, las principales funciones que se utilizan son:

- **onebasis()**: genera una base de funciones para una única dimensión (exposición o retardo). Es empleada para construir manualmente bases cruzadas o para modelos con relación lineal y efectos retardados (*dlnm*).
- **crossbasis()**: construye la base cruzada combinando las bases de exposición y retardo, usada para ajustar modelos *dlnm*.
- **crosspred()**: calcula predicciones y efectos estimados a partir del modelo ajustado con la base cruzada.
- **crossreduce()**: resume el efecto bidimensional en una sola dimensión, facilitando la interpretación del efecto acumulado sobre la exposición o el retardo.

Estimación del modelo. El modelo se ajusta mediante regresión generalizada con función de enlace logarítmico y distribución de Poisson para modelar conteos, como las defunciones diarias. Las funciones **glm()** o **gam()** de R sirven para estimar los coeficientes β de las bases cruzadas mediante máxima verosimilitud, obteniendo así los efectos de la exposición y los retardos sobre la variable respuesta.

La estimación incorpora los términos suavizados definidos por las bases y la estructura temporal de los retardos, y los parámetros se ajustan para maximizar la probabilidad de observar los datos bajo el modelo.

Visualización. El paquete también ofrece funciones para visualizar la relación entre la exposición y los retardos mediante superficies tridimensionales, curvas de efecto acumulado o mapas de calor, entre otros, facilitando la interpretación del impacto de la exposición sobre la respuesta a lo largo del tiempo.

En resumen, el paquete *dlnm* ofrece una implementación flexible y eficiente para ajustar modelos estadísticos complejos que permiten estudiar los efectos retardados y no lineales en epidemiología ambiental y otros campos relacionados.

Capítulo 3

Ilustración de los modelos *dlnm* con datos de mortalidad diaria y temperaturas en España

3.1. Fuente de datos

Fuentes de información. Para el desarrollo de este Trabajo Fin de Máster se han utilizado datos procedentes del Sistema de Monitorización de la Mortalidad Diaria (MoMo), accesible en https://momo.isciii.es/panel_momo/#section-momo. MoMo es un sistema de vigilancia implementado por la Unidad de Vigilancia de la Mortalidad Diaria del Centro Nacional de Epidemiología (CNE) del Instituto de Salud Carlos III, en el marco del Plan Nacional de Actuaciones Preventivas de los Efectos del Exceso de Temperaturas sobre la Salud (Plan Calor). Desde 2022, este sistema recopila información sobre defunciones diarias por todas las causas a partir de los registros civiles informatizados del Ministerio de Justicia, abarcando 4.128 municipios que representan aproximadamente el 93 % de la población española.

Además de los datos de mortalidad, actualizados diariamente, MoMo incluye el ámbito geográfico (provincia, comunidad autónoma o nacional), su nombre y código, el sexo y grupo de edad quinquenal de los fallecidos (con sus respectivos códigos), la fecha de defunción, el número de defunciones observadas y esperadas (estas últimas sin ajuste por temperatura) junto con sus respectivos intervalos de confianza, y el número de defunciones atribuibles al exceso o defecto de temperatura. Para el trabajo, seleccionaremos solo el ámbito provincial.

MoMo también calcula lo que se conoce como índice Kairós, que alerta acerca del riesgo de mortalidad asociado a un exceso o a un defecto de la temperatura. Tiene tres niveles. El primero indica que no hay riesgo, el segundo que existe riesgo moderado y el tercero que el riesgo es alto.

Las fuentes de datos que utiliza MoMo son:

- Los datos de defunciones diarias de los últimos 10 años, salvo el 2020 debido a la pandemia, obtenidos del Instituto Nacional de Estadística (INE) hasta una cierta fecha, y desde entonces del Ministerio de Justicia.
- Las temperaturas según la Agencia Estatal de Meteorología (AEMET) a nivel provincial.
- La población por grupo de edad, sexo y provincia, del INE.

El modelo que emplea MoMo para calcular la predicción de excesos de mortalidad atribuibles a la temperatura es un modelo aditivo generalizado (GAM) de Poisson. Las variables empleadas para ajustarlo son:

- Un spline cúbico por provincia para modelar la tendencia.
- Un spline cíclico por provincia para la estacionalidad anual de la mortalidad.
- El ATO con efecto aleatorizado entre las provincias, mediante modelos mixtos.
- El F-ATO con efecto aleatorizado entre las provincias, mediante modelos mixtos.
- La tasa de defunción se ajusta como 'offset'.

El ATO (Accumulated Thermal Overcharge) es una variable sintética que mide el efecto del exceso de temperatura máxima. Cada provincia posee una temperatura máxima crítica a partir de la que se observa una mayor mortalidad. La formulación que emplea MoMo es la siguiente:

$$ATO_d = \sqrt{\sum_{i=1}^7 ATO_{d-i} \cdot 0,8^{(i-1)}}$$

Análogamente, el F-ATO (Accumulated Thermal Overcharge for cold) es una variable sintética que mide el efecto del exceso de temperatura mínima. Se construye como el ATO pero tomando temperaturas mínimas.

Los datos relativos a la temperatura se obtuvieron del portal de la AEMET (Agencia Estatal de Meteorología) conocido como AEMET OpenData (<https://opendata.aemet.es/centrodedescargas/inicio>). Se trata de un API REST (Application Programming Interface. REpresentational State Transfer) que permite descargar de forma gratuita datos de las estaciones meteorológicas españolas. Las fechas de los datos descargados suman un total de 10 años, desde el 1 de enero del 2015 al 31 de diciembre del 2024. Por defecto, se incluyen datos de todas las estaciones meteorológicas, y para evitar tener sobrecarga de información, se eligió únicamente una estación por provincia. Los nombres de las estaciones seleccionadas se incluyen en el anexo. Una vez se tienen ambas bases de datos, se unifican en una sola según la fecha y el nombre de la provincia.

3.2. Análisis del exceso de mortalidad atribuible a la temperatura en España

En este primer análisis vamos a estudiar la relación entre la mortalidad y el exceso o defecto de la temperatura a nivel nacional. Se empleará la totalidad de los datos que están disponibles, sin importar la provincia de la que procedan.

El primer paso es realizar un análisis descriptivo. Se pretende ver si existen muchos datos faltantes o cómo se distribuyen a lo largo del tiempo. La base de datos consta de una totalidad de 4709112 observaciones de 19 variables. Cambiamos la naturaleza de las variables relativas a la temperatura (*tmed*, *tmin*, *tmax*) a numérica, y las relativas a los grupos de población (*cod_sexo*,

nombre_sexo, *cod_gedad*, *nombre_gedad*) a factor. Tras estos cambios, se derivan las siguientes observaciones:

- Hay un total de 27671 observaciones faltantes en la variable de defunciones observadas. De las variables que indican la temperatura media, la mínima y la máxima hay 1509720, 1509408 y 1509024 datos faltantes, respectivamente. Dentro de un análisis más profundo, es posible darse cuenta de que los datos pertenecientes a la temperatura que no existen se tratan de ciertos periodos de tiempo de los que algunas estaciones meteorológicas no tienen información. Por ejemplo, la estación de Murcia Aeropuerto solamente tiene datos a partir del día 29 de mayo del 2021, o la estación de Madrid Aeropuerto, a la que le faltan muchos datos entre el año 2018 y el 2020. Sin embargo, debido a la gran cantidad de observaciones que se tiene, esto no será un problema a la hora de hacer el análisis nacional.
- El número de observaciones que existen para cada grupo de población, tanto de edad como de sexo, es el mismo. Se presentan un total de 1569704 datos para cada subgrupo de la variable que separa la población según el sexo, y 588639 para cada subgrupo de edad. Esto es debido a que cada fila de la base de datos se trata de un día por grupo de edad, sexo y lugar.
- La variable *defunciones_observadas* tiene una media con un valor de 5.515, mientras que la mediana solo vale 2.010, bastante menor. De manera semejante ocurre con las variables *defunciones_estimadas_base*, *defunciones_estimadas_base_q01*, *defunciones_estimadas_base_q99*, *defunciones_atrib_exc_temp* y *defunciones_atrib_def_temp*. Esto ocurre por la distribución de los datos. Muchos días, las defunciones observadas, o las que se atribuyen a la temperatura, en muchos grupos de población, toman el valor 0. Por otra parte, cuando se presenta una ola de calor o de frío, por ejemplo, el número de defunciones aumenta, dando lugar a la distribución desigual que se observa.
- El valor máximo que alcanza la variable *defunciones_observadas* es 817.270. Este valor tan alto se alcanzó en Madrid el 27 de marzo del 2020. No obstante, ninguna de estas muertes se asocia con la temperatura. Todas ellas fueron a causa de la pandemia del COVID-19 que se sufrió. Los datos de las defunciones que ocurrieron ese año tienen valores más altos de lo normal a causa de ello.
- Los valores de la media y la mediana para las variables *tmed*, *tmin* y *tmax* son bastante parecidos (16.20 es la media y 16.33 la mediana de *tmed*, 10.80 y 10.73 la media y la mediana de *tmin* y 21.50 y 21.92 los respectivos valores asociados a *tmax*). Al contrario de lo que ocurría con las defunciones, esto indica que la distribución de la temperatura es simétrica. Existen días con calor y también con frío en la misma medida.

A continuación vamos a realizar el apartado de la modelización. En primer lugar, evaluaremos los modelos que fueron realizados por otros autores en trabajos semejantes y lo aplicaremos a nuestro caso particular.

En el trabajo de Gasparrini, Armstrong y Kenward [3], que mencionamos en la introducción, y donde se explica el funcionamiento de los modelos *dlnm*, hay un ejemplo de aplicación sobre el efecto de la temperatura en la mortalidad en la ciudad de Nueva York. En él se menciona que se elige un modelo con splines cúbicos naturales para describir la relación en cada




Figura 3.1: Distribución de los datos de temperatura

dimensión, con nudos igualmente espaciados para la temperatura con el fin de dar flexibilidad a los extremos, y con intervalos iguales en la escala logarítmica para los retardos, para flexibilizar la primera parte de la curva del retardo distribuido, que se espera más variable. Además, se toma un retardo máximo de 30 días, y los grados de libertad se eligen según los criterios de información de Akaike y bayesianos modificados.

Por otro lado, en el trabajo de Achekak, Devolder y Ballester [1], donde recordemos que se estudia la mortalidad relacionada con el calor en España, se modela la curva relativa a la temperatura con un B-spline cúbico natural, con un nudo en el percentil 15 de la distribución de la temperatura diaria, y para la curva de los retardos se emplea otro B-spline cúbico natural con una intersección y dos nudos igualmente espaciados en la escala logarítmica. El retardo máximo que se considera es de 10 días.

Por último nos vamos a fijar en el proyecto realizado por Rutten, Espinasse, Duarte, Neyens y Faes [10]. En él se estudia las asociaciones retardadas y no lineales entre la contaminación del aire y los casos del virus COVID-19 en Bélgica. También se utiliza un *dlnm*, donde se emplea un spline natural con 2 nudos igualmente espaciados y 3 grados de libertad para la dimensión de la exposición, y un nudo y un intercepto con 3 grados de libertad para la dimensión de los retardos.

Nos damos cuenta con estas observaciones que los splines cúbicos son adecuados para nuestro análisis. Esto se debe a su flexibilidad, que permite modelizar bien las curvas suaves, como son las que se esperan que resulten al aplicar un modelo *dlnm*.

Recordemos brevemente lo que es una función spline cúbica. Dados $n + 1$ puntos distintos $t_0 < t_1 < \dots < t_n$ que son una partición del intervalo $[t_0, t_n]$, un spline cúbico (de grado 3) con nudos en $t_0, t_1, \dots, t_n$ es un polinomio a trozos de grado a lo sumo 3 continuo en $[t_0, t_n]$, y con derivadas continuas hasta orden 2. Además, se dice que un spline cúbico es natural si satisface que su segunda derivada en los extremos, es decir, en los puntos t_0 y t_n es nula. Las funciones B-spline son la base de los splines generales. Se tratan de funciones no negativas que se anulan en toda la recta real excepto en intervalos contiguos $[t_i, t_{i+1}]$ tal y como afirma González en su trabajo sobre splines [11].

Redondeamos la variable de las defunciones observadas para evitar errores, y definimos la variable *dow* (día de la semana) que incluiremos en el modelo. Notemos que no disponemos de muchas de las variables que son empleadas en trabajos similares, tales como el ozono o el nivel de monóxido de carbono en la atmósfera, entre otros. Esto puede limitar la utilidad de los modelos que vamos a realizar.

Debido a la gran cantidad de observaciones que tiene la base de datos, la parte de modelización requiere un alto coste de tiempo computacional. Dado que tendremos que hacer una gran cantidad de bases cruzadas y modelos, procederemos seleccionando una muestra más pequeña y aleatoria de los datos. Además, para no perder la componente estacional de la temperatura, la submuestra que tomemos será estratificada. De esta manera aseguramos tomar la misma cantidad de días fríos y días cálidos.

Tras tomar la muestra aleatoria y estratificada de tamaño un 3.33 % respecto a la cantidad de datos originales, lo primero que se realiza es la comprobación. Analizamos las variables y notamos que los grupos de población se dividen de igual manera, como ocurría originalmente, aunque ahora no es exactamente el mismo número de datos (por ejemplo, hay 34456 observaciones correspondientes a hombres, 34309 a mujeres, y 34468 pertenecientes al grupo de todos). La distribución de las defunciones observadas sigue siendo bastante desigual, donde muchos días no muere nadie. Por último, tal y como se buscaba, se tienen tanto días fríos como días cálidos en la misma medida.

Para comenzar la modelización, se realiza una primera aproximación donde se decide tomar un retardo máximo de 30 días, y en la base cruzada se utilizan B-splines con 3 grados de libertad para la temperatura, y splines naturales con el mismo número de grados de libertad para la dimensión del retardo. En el caso del modelo, la variable explicada es la de defunciones observadas, que es estudiada por la base cruzada que se acaba de definir, el día de la semana y el spline natural de la fecha de defunción, con 70 grados de libertad (7 por cada año de datos que se tienen). Recordemos que se trata de un modelo de regresión de quasi-Poisson, ya que existe sobredispersión de los datos. Centramos la predicción en el valor de 20°C, y los gráficos obtenidos se pueden ver en la imagen 3.2.

El Riesgo Relativo (RR) que se suele emplear en los gráficos se trata de una medida que compara el riesgo de un evento, que en nuestro caso es fallecer debido a las temperaturas extremas, en un grupo expuesto a ese factor, frente a un grupo de referencia que no está expuesto. En nuestro estudio, se está comparando el riesgo de la población en días con temperaturas extremas frente a días con temperaturas suaves. Por ello, el valor que hemos empleado para centrar la predicción era de 20°C.

Si nos fijamos en los gráficos, se observa que el RR aumenta conforme sube la temperatura, que suele ser lo normal. Sin embargo, parece que en días fríos el riesgo se reduce considerablemente. Esto no tiene demasiado sentido. Recordemos que la base de datos que estamos empleando contiene información acerca de muchos grupos de población distintos de muchos lugares de España bastante diferentes entre sí, ya que las temperaturas en una provincia del norte serán más frías que en una provincia del sur. Esto es lo que puede hacer que se obtengan esos resultados, y se trata de un factor a tener en cuenta.

A continuación, vamos a realizar un análisis de sensibilidad en el que se estudiarán diferentes modelos con distintos grados de libertad tanto para la temperatura como para el retardo, además de probar tanto con splines naturales como con B-splines. El método que se va a emplear para elegir el mejor modelo de todos es el Criterio de Información de Akaike modificado




Figura 3.2: Gráficos del modelo con B-spline para la temperatura y spline natural para el retardo, ambos con 3 grados de libertad (submuestra).

para modelos con sobredispersión (QAIC). Recordemos que se calculaba como:

$$QAIC = -2L(\beta) + 2\phi k$$

donde L es la función de verosimilitud, ϕ el parámetro de sobredispersión y k el número de parámetros. Se obtendrán valores muy altos, dado el gran tamaño de los datos.

Tras el análisis de sensibilidad, se ha obtenido que los modelos que tienen un menor valor del QAIC son:

- Un modelo en el que se emplean B-splines tanto para la temperatura como para el retardo, empleando 5 grados de libertad para el primero y 7 para el segundo. El valor del QAIC obtenido es de 1425842.
- Otro modelo que usa un spline natural con 3 grados de libertad para la temperatura, y un B-spline con 7 grados de libertad para el retardo. Tiene un QAIC de 1425939.

Hay que tener en cuenta que el QAIC trata de ajustar y penalizar según el número de parámetros. En modelos tan grandes como el que estamos estudiando, puede tender a un sobreajuste de los datos. Precisamente eso es lo que se desprende de ver que los mejores modelos son los que tienen grados de libertad tan altos para la dimensión del retardo. No obstante, vamos a visualizar los gráficos que se obtienen. (3.3)

En la figura 3.3 se puede ver en ambos casos el sobreajuste de los datos. Esto se manifiesta en los altibajos que tiene la superficie tridimensional, sobretudo en los extremos de la temperatura. Si el modelo estuviera bien ajustado, la superficie sería más plana, con menos baches. Los gráficos de efecto acumulado también lo muestran. El de la parte superior de la figura experimenta constantes subidas y bajadas, aparte de que en los extremos, donde en teoría el riesgo




Figura 3.3: Arriba: Gráficos del modelo con B-splines para ambas dimensiones y 5 y 7 grados de libertad para la variable y el retardo, respectivamente (submuestra). Abajo: Gráficos del modelo con un spline natural con 3 grados de libertad para la temperatura y un B-spline con 7 para el retardo (submuestra).




Figura 3.4: Arriba: Gráficos del modelo con B-splines y 5 grados de libertad para ambas dimensiones (submuestra). Abajo: Gráficos del modelo con un spline natural con 3 grados de libertad para la temperatura y un B-spline con 5 para el retardo (submuestra).

aumenta, descendiendo bastante por debajo del 1. Notemos que los intervalos de confianza (en gris) también son muy amplios, y no aportan nada de información.

Es por todas las causas anteriores por las que se ha decidido probar de nuevo estos modelos pero reduciendo los grados de libertad con el fin de reducir el sobreajuste mencionado. En particular, reducimos los grados de libertad correspondientes al retardo hasta 5, mientras se dejan fijos los relativos a la temperatura. Volvemos a comparar los gráficos logrados. (3.4)

En la figura 3.4 se observa una ligera mejoría respecto a los modelos de la figura anterior. En general, las superficies se ven algo más suavizadas, los valores del Riesgo Relativo en los extremos han subido un poco y los intervalos de confianza se han reducido, sobretodo en la parte de las altas temperaturas, aunque siguen siendo bastante amplios.

A partir de aquí seleccionamos el modelo de arriba, que parece mejor, y estudiamos lo que ocurre si reducimos los grados de libertad todavía más, hasta 4. Los gráficos resultantes se ven en la figura 3.5.

Se visualiza una superficie más suavizada que las anteriores. Parece que el mayor pico del Riesgo Relativo para bajas temperaturas ocurre con un retardo de entre 5 y 7 días, mientras que para temperaturas altas hay un mayor riesgo en los primeros días de retardo. Por otra parte,




Figura 3.5: Gráficos del modelo con B-splines y 4 grados de libertad para la temperatura y para el retardo (submuestra).




Figura 3.6: Gráficos del modelo con B-splines y 4 grados de libertad para la temperatura y para el retardo aplicado a todos los datos.

el gráfico de efecto acumulado muestra que con temperaturas bajas el riesgo de fallecer es muchísimo menor, comparado con el riesgo de fallecer con 20°C. El intervalo de confianza en esta parte no es muy amplio, y se mantiene por debajo del 1. En relación con el calor, el RR llega hasta algo más de 1.5, pese a que el intervalo de confianza es muy amplio.

Recordemos que se trata de un gráfico de efecto acumulado y que, por lo tanto, tiene en cuenta lo que ocurre durante los 30 días de retardo máximo que se han introducido en la base cruzada. Eso también incluye que, a lo mejor, después de 3 semanas, el riesgo de fallecer respecto a una temperatura normal tras haber estado expuesto al frío decrece en gran medida.

Ya se ha llegado a un modelo que parece adecuado respecto a nuestros datos. A continuación, planteamos el mismo modelo para la base de datos que se presentaba inicialmente, sin tomar una submuestra más pequeña.

Los gráficos del modelo al que se ha llegado finalmente aplicado a todos los datos disponibles se pueden ver en la figura 3.6.

Lo más destacable es que, bajo temperaturas frías, el RR decrece mucho, hasta casi tocar




Figura 3.7: Cortes de la superficie cuando el retardo (Lag) es de 0, 3, 5 y 11 días, y la temperatura (Var) es de 0, 5, 30 y 35°C.

el 0, lo que se ve tanto en la superficie tridimensional como en el gráfico de efecto acumulado. Esto puede deberse a que no hay demasiados datos donde la temperatura media sea más baja de 10, y las que existen, no cuentan apenas con defunciones. Otra observación a tener en cuenta es que los intervalos de confianza del gráfico de efecto acumulado son muy estrechos. En la parte del frío no se aprecia.

Podemos afirmar que este modelo es bueno para temperaturas altas. El RR aumenta y se observa un retardo casi inmediato, es decir, los efectos provocados por estar expuesto al calor se manifiestan durante los 5 primeros días después de dicha exposición. Sin embargo, notamos muchos defectos cuando las temperaturas son bajas. Sin embargo, seguiremos quedándonos con este, teniendo en cuenta las limitaciones que presenta.

Ahora, se van a realizar cortes en la superficie en ciertos puntos (en el retardo 0, 3, 5 y 11, y cuando la temperatura vale 0, 5, 30 y 35°C) con la finalidad de visualizar lo que ocurre en esos casos particulares. Se puede ver en la figura 3.7.

Para los primeros 5 días de retardo se observa que el RR en temperaturas altas es mayor que 1 y para temperaturas bajas es bastante menor. Sin embargo, en el gráfico correspondiente al día 11 de retardo, ya se muestra que en temperaturas cálidas el RR ha decrecido y es mayor que 1 cuando las temperaturas son frías. Esto nos quiere decir que los síntomas procedentes de una exposición al calor se manifiestan en los 5 primeros días después del suceso. Al contrario ocurre con la exposición al frío, donde los síntomas aparecerían una semana más tarde.

A las mismas conclusiones se llega observando los gráficos de la derecha. Cuando la temperatura es de 0°C, el RR es mayor que 1 entre los días 8 y 21 de retardo, indicando que los efectos no aparecen de forma inmediata. Si la temperatura es más caliente, con 35°C, el mayor RR se alcanza en los primeros días desde la exposición, y decreciendo a partir de ahí.

Por consiguiente, la conclusión a la que se llega es que los efectos del calor ocurren, como tarde, una semana después de la exposición y a partir de ese entonces la probabilidad de que ocurran decrece considerablemente. Los efectos del frío ocurren de manera más tardía, a partir de la segunda semana, y también durante la tercera. Después, es menos probable que aparezcan los efectos perversos.

Para terminar este análisis a nivel estatal, dividiremos a la población en subgrupos según su edad, y estudiaremos con el modelo anterior cómo afecta la temperatura a cada uno de ellos. Los subgrupos en los que los dividiremos son....

3.3. Análisis del exceso de mortalidad atribuible a la temperatura por provincias

Mostraremos a continuación un análisis más desagregado, por provincias. Para su realización, se empleará el método de las Aproximaciones de Laplace Anidadas Integradas (INLA, integrated Nested Laplace Approximations, en inglés) [12]. El método INLA es determinista y sirve para realizar inferencia Bayesiana. Es más rápido y exacto que los métodos de Montecarlo basados en cadenas de Markov (MCMC) que se suelen emplear. Tal y como afirman Quijal-Zamorano et al. (2025) [12], de esta manera se reducen significativamente los costes computacionales y el tiempo requerido al modelizar.

El método INLA es útil para los LGMs (Modelos Gaussianos Latentes), que incluyen muchos modelos que son usados típicamente, como los modelos lineales generalizados. Lo que se hace es utilizar la aproximación de integrales de Laplace en densidades cercanas a la gaussiana con el fin de encontrar la distribución posterior marginal de cada variable del modelo. Si esto no es posible, en el caso de los LGM, se puede reformular el problema en otros subproblemas en los que sí se puede aplicar la aproximación de Laplace.

Existe una librería de R conocida como *INLA*. En ella se encuentra la función *inla()* que realiza el análisis por este método.

Una de las ventajas que tiene es la capacidad de estudiar modelos con retardo y con componente espacial, esto es, qué áreas colindantes tendrán efectos similares. Este tipo de modelos son los conocidos como SB-DLNM (Spatial Bayesian Distributed Lag Non-linear Models). Fueron presentados por Quijal-Zamorano et al. (2024) [14]. Se trata de un método que estima los efectos retardados en el tiempo a corto plazo provocados por exposiciones medioambientales en áreas pequeñas, teniendo en cuenta también su estructura espacial y geográfica, y cómo se afectan unos a otros.

Para el estudio del tema de esta sección se empleó R-INLA en un modelo SB-DLNM con un diseño de caso-cruce. Este diseño es útil y ampliamente usado para el estudio del impacto diario de factores medioambientales en la salud humana. Consiste en utilizar como identificador un estrato (stratum, en inglés), que compara varias observaciones entre sí mismas en diferentes etapas de tiempo. Estudia si un evento ocurre debido a una exposición particular comparándola el día que ocurre con lo que pasa los días cercanos, conocidos como días de control. Esta es una manera de controlar la estacionalidad y la tendencia de los datos a nivel anual, sin recurrir a modelizar grandes series temporales.

En particular, para este trabajo, estratificamos los datos según la provincia, el año, el mes y el día de la semana. De esta manera, se están comparando las temperaturas y las defunciones diarias de una misma provincia con lo que ha ocurrido en el mismo día de la semana, mes y año. Cada estrato consta de varios días de control. Se excluyen aquellos estratos que no contienen ninguna muerte. Ejecutándolo de esta manera, ya se tiene en cuenta el efecto provocado por el día de la semana, que recordemos que se tuvo que incluir como variable explicativa en los modelos de la sección anterior.

Dada una provincia, se definió el conjunto de sus vecinos como aquellas otras provincias adyacentes, con las que comparte frontera. En las secciones anteriores se seleccionó como base cruzada para el modelo la que emplea B-splines con 4 grados de libertad tanto para la dimensión de la temperatura como la del retardo. Sin embargo, debido a la cantidad de provincias, datos y la complejidad de los modelos, se requería un elevado coste de tiempo y cálculo computacional, y al final no se obtuvieron resultados. Finalmente, se decidió aplicar un modelo más sencillo. En particular, en cada provincia se empleó un spline natural con 2 grados de libertad para ambas dimensiones, resultando en modelos de 4 parámetros, más sencillos que los de 16 que se intentaron implementar en un principio.

Se utilizó el método R-INLA, considerablemente más rápido que usar WinBUGS, que era lo que se solía emplear, y el modelo tardó en ejecutarse aproximadamente 27 minutos. Se calcularon los valores del RR para cada combinación entre la temperatura y el retardo de cada provincia. Tras centrar el valor del RR de cada lugar, en la figura 3.8 se muestra la distribución espacial del RR en el percentil 99 de temperatura. Lo que se hace es comparar, dentro de cada provincia, lo que ocurre cuando la temperatura se aleja de la temperatura óptima que se tiene como referencia, que definimos como la mediana de las temperaturas en cada sitio. Así, una provincia con un color más frío indica un exceso de la mortalidad atribuible a la temperatura bajo, y al contrario ocurrirá en provincias con colores cálidos. No se incluyen las ciudades autónomas de Ceuta y Melilla.

Lo primero que se observa en la leyenda es que los valores del RR son muy cercanos a 1 en cada lugar. Esto es debido a la simplicidad del modelo que se ha tenido que implementar para obtener los resultados. Pese a ello, sí que se visualiza un patrón entre las provincias. Las que presentan un color menos cálido, y un RR menor que 1 se concentran en Navarra, La Rioja, el sur del País Vasco y la parte sureste de Castilla y León, siendo Soria, Segovia y Ávila las




Figura 3.8: Mapa de España por provincias con los valores del RR

que tienen un valor menor. La provincia que tiene el menor riesgo es Lugo. Por otro lado, las provincias del este y del sur de la península tienen más RR, aumentando el valor conforme más al sur se sitúan. La estructura espacial y la influencia de las provincias con aquellas con las que comparten frontera también se observa en Extremadura y el oeste de Andalucía donde se alcanza un mayor exceso de mortalidad por temperatura. Las provincias con los valores más altos son Huelva, Cáceres y Palencia. Tanto las islas Canarias como las Baleares no tienen ningún vecino que les afecte, pero las primeras tienen un color rojizo, y las segundas más azul.

Conociendo las limitaciones del modelo empleado, en el que no se pudo incluir más grados de libertad para otorgar una mayor flexibilidad, todavía se llega a apreciar la estructura espacial que se buscaba al emplear un SB-DLNM. Además, cuanto más al sur nos situemos, hay más exceso de mortalidad por temperatura.

3.4. Análisis del exceso de mortalidad atribuible a la temperatura en Navarra

En esta sección se va a realizar un análisis similar a lo de las secciones anteriores, pero centrado en la provincia de Navarra. Obtendremos los datos de todas las regiones que la conforman

Notar que estos datos no contienen las temperaturas diarias, así que se consiguen de otras fuentes. En particular, para la región de Navarra, los datos fueron extraídos de la página web de Meteo Navarra [<https://meteo.navarra.es/>]. De aquí se obtuvieron, aparte de la fecha, los valores de las temperaturas máximas, mínimas y medias de cada día, desde el 1 de enero del 2015 hasta el 31 de diciembre del 2024, ambos incluidos. En concreto, los datos son de la

T_max	T_media	T_min
Min. : -1.38	Min. : -2.76	Min. : -5.280
1st Qu.: 12.59	1st Qu.: 8.47	1st Qu.: 4.550
Median : 18.25	Median : 13.19	Median : 8.900
Mean : 18.89	Mean : 13.63	Mean : 9.004
3rd Qu.: 25.04	3rd Qu.: 18.80	3rd Qu.: 13.560
Max. : 40.45	Max. : 31.38	Max. : 24.350

Figura 3.9: Resumen de los datos de temperatura

estación automática de Pamplona GN. Esta estación no incluye los valores del 2021, y es por ello que los datos de ese año fueron sacados de la estación manual Pamplona MAN.

Después de leer todos los datos, evaluamos la existencia de observaciones faltantes, y nos damos cuenta de que los datos de la temperatura media del año 2020 no están. Por tanto, después de pasar todas las columnas de la base de datos a variables numéricas, calculamos la temperatura media de cada uno de esos días como el promedio de la temperatura máxima y mínima que hizo. Aún así, notamos que hay una totalidad de 7 días de los cuales no conocemos ninguno de sus valores. Para terminar, unificamos la base de datos de MoMo y la de Meteo Navarra en una sola. Para ello, de la primera solo seleccionamos aquellas observaciones relativas a Navarra, es decir, filtramos las que tengan un código INE igual a 31. Después, hacemos que las columnas de fechas sean de tipo 'Date', y las juntamos en una sola base de datos.

A continuación, procedemos a analizar los datos que se tienen. Veremos si las temperaturas y las defunciones observadas se distribuyen de manera lógica, o cuántas observaciones se tienen para cada grupo de población, entre otras cosas. Para comenzar, las variables de la base de datos que se refieren a los grupos de edad y los del sexo, se pasan a tipo factor para obtener todos los subgrupos. Después, realizamos un resumen de los datos, donde se observa que se dividen de igual manera entre todos los grupos de edad y de sexo, es decir, que de las 89040 observaciones, hay 29680 hombres, mujeres y pertenecientes al subgrupo de 'todos', y 11130 para cada subgrupo de edad. Esto ocurre debido a que los datos de MoMo están estructurados de manera que cada fila es un día por cada grupo de edad y de sexo. Es por ello que a veces hay defunciones nulas, donde no se ha observado ninguna muerte para un grupo de un día en concreto.

Si continuamos analizando los datos, ahora nos fijamos en los valores de las temperaturas, tanto la máxima como la mínima y la media. Observamos sobretudo la media y la mediana de cada variable. Que no haya mucha diferencia entre las dos nos indica lo bien distribuidos que se encuentran los datos relativos a la temperatura. La mayoría se encuentran entorno al centro, y cada vez hay menos observaciones conforme vamos alcanzando los extremos. Lo normal son días con temperaturas medias, mientras que también hay días con temperaturas extremas, pero en menor cantidad. No existe ningún dato demasiado alto ni demasiado bajo que altere la media. De hecho, esto lo podemos visualizar con los siguientes histogramas:

Vamos a realizar la misma observación pero con la variable relativa a las defunciones observadas. Esta vez, se ve esto: Nótese que ahora la diferencia es abismal. El valor mínimo es 0, de los días que no se ha contabilizado ninguna muerte. Por el contrario, el valor máximo alcanza 56.17. Por otra parte, el valor de la media es casi el doble que el de la mediana. Esto significa que los datos se acumulan cerca del 0, y que los días con más defunciones son menos comunes.




Figura 3.10: Histogramas de frecuencias de temperaturas

```
defunciones_observadas
Min.    : 0.000
1st Qu.: 0.000
Median : 2.040
Mean    : 3.959
3rd Qu.: 6.130
Max.    :56.170
```

Figura 3.11: Resumen de la variable de defunciones observadas




Figura 3.12: Histograma de frecuencia de las defunciones observadas

+65	+85	0-14	15-44	45-64	65-74	75-84	all
107708.21	62612.43	403.72	2010.13	12302.83	15298.40	29776.21	122381.66

Figura 3.13: Número de defunciones observadas para cada subgrupo de edad

El histograma confirma esto:

Por último, para terminar este análisis, dado que pretendemos estudiar lo que ocurre en los distintos grupos de edad, vemos el número de defunciones correspondientes a cada uno, lo que ya nos dará una primera idea. La fila de arriba corresponde a los distintos grupos, y la de abajo se trata de la suma de todas las defunciones observadas para cada grupo. Notar que a medida que va aumentando la edad, más defunciones se observan. Para el grupo de niños entre 0 y 14 años apenas hay 400 muertes, mientras que los grupos que más mortalidad tienen son los que tienen a partir de 65 años.

3.5. Modelización

En esta sección se presentará el estudio de los modelos que se han empleado para el análisis de la mortalidad atribuible al exceso de calor. En primer lugar, se estudiará el tipo de modelos que han utilizado otros autores en otros trabajos semejantes, para basarnos en ellos a la hora de hacer el primer modelo, y una vez adaptado al problema relativo a este proyecto, se hará una evaluación de lo que sucede.

En el trabajo de Gasparrini, Armstrong y Kenward [3], que mencionamos en la introducción, y donde se explica el funcionamiento de los modelos *dlnm*, hay un ejemplo de aplicación sobre el efecto de la temperatura en la mortalidad en la ciudad de Nueva York. En él se menciona que se elige un modelo con splines cúbicos naturales para describir la relación en cada

dimensión, con nudos igualmente espaciados para la temperatura con el fin de dar flexibilidad a los extremos, y con intervalos iguales en la escala logarítmica para los retardos, para flexibilizar la primera parte de la curva del retardo distribuido, que se espera más variable. Además, se toma un retardo máximo de 30 días, y los grados de libertad se eligen según los criterios de información de Akaike y bayesianos modificados.

Por otro lado, en el trabajo de Achebak, Devolder y Ballester [1], donde recordemos que se estudia la mortalidad relacionada con el calor en España, se modela la curva relativa a la temperatura con un B-spline cúbico natural, con un nudo en el percentil 15 de la distribución de la temperatura diaria, y para la curva de los retardos se emplea otro B-spline cúbico natural con una intersección y dos nudos igualmente espaciados en la escala logarítmica. El retardo máximo que se considera es de 10 días.

Por último nos vamos a fijar en el proyecto realizado por Rutten, Espinasse, Duarte, Neyens y Faes [10]. En él se estudia las asociaciones retardadas y no lineales entre la contaminación del aire y los casos del virus COVID-19 en Bélgica. También se utiliza un *dlnm*, donde se emplea un spline natural con 2 nudos igualmente espaciados y 3 grados de libertad para la dimensión de la exposición, y un nudo y un intercepto con 3 grados de libertad para la dimensión de los retardos.

Nos damos cuenta con estas observaciones que los splines cúbicos son adecuados para nuestro análisis. Esto se debe a su flexibilidad, que permite modelizar bien las curvas suaves, como son las que se esperan que resulten al aplicar un modelo *dlnm*.

Recordemos brevemente lo que es una función spline cúbica. Dados $n + 1$ puntos distintos $t_0 < t_1 < \dots < t_n$ que son una partición del intervalo $[t_0, t_n]$, un spline cúbico (de grado 3) con nodos en $t_0, t_1, \dots, t_n$ es un polinomio a trozos de grado a lo sumo 3 continuo en $[t_0, t_n]$, y con derivadas continuas hasta orden 2. Además, se dice que un spline cúbico es natural si satisface que su segunda derivada en los extremos, es decir, en los puntos t_0 y t_n es nula. Las funciones B-spline son la base de los splines generales. Se tratan de funciones no negativas que se anulan en toda la recta real excepto en intervalos contiguos $[t_i, t_{i+1}]$ tal y como afirma González en su trabajo sobre splines [11].

Después de dedicar unas líneas a comprender lo que otros autores han hecho para abordar el problema y de definir teóricamente lo que se va a emplear, pasaremos a plantear nuestro modelo. Lo primero que se tiene que realizar es hallar las funciones base que mejor describan la dimensión de la temperatura y la de los retardos. Ya me hemos mencionado anteriormente que, debido a las curvas suaves que se describen, una buena aproximación se realiza con funciones spline o B-spline. Los grados de libertad los vamos a calcular mediante la evaluación del QAIC, el criterio de información de Akaike modificado para modelos sobredispersos como el nuestro. Como ya veremos, se obtendrán valores del QAIC muy grandes. Esto es totalmente normal debido a la gran cantidad de observaciones se tienen.

Hacemos un análisis de sensibilidad donde creamos varios modelos usando splines (tanto naturales como B-splines) para la temperatura y el retardo con distintos valores para los grados de libertad de cada uno, y estudiamos los valores QAIC. Seleccionaremos el de menor valor. Como es necesario calcular la verosimilitud, para evitar errores, redondeamos los valores de la variable correspondiente a las defunciones observadas. Otra observación que tenemos que hacer es que en el modelo de regresión solo estamos incluyendo a la base cruzada creada anteriormente como variable explicativa. Más adelante compararemos lo que ocurre si se introduce




Figura 3.14: Gráficos de predicciones del modelo con 3 grados de libertad para cada dimensión. A la izquierda la superficie y a la derecha el gráfico de efecto acumulado

alguna variable más.

Después de formar distintas bases cruzadas, crear los modelos y calcular su QAIC, llegamos a la conclusión de que, según este criterio, la mejor forma de modelizar las defunciones según la temperatura y los retardos es emplear un B-spline con 3 grados de libertad para la dimensión de la temperatura y un spline natural también con 3 grados de libertad para el retardo. De esta manera se ha alcanzado el menor valor del QAIC, que es igual a 690782.2. Le aplicamos la función de predicción y se obtiene lo siguiente:

En la izquierda se tiene el gráfico tridimensional, la superficie que denota el valor de RR para cada valor de la temperatura y de retardo. El eje de RR muestra el riesgo relativo de mortalidad en cada momento. Un valor mayor que 1 indica que aumenta el riesgo de muerte, mientras que un valor menor que 1 significa lo contrario. El gráfico de la derecha es el gráfico de efecto acumulado, que dibuja una línea que indica la influencia de la temperatura en la mortalidad en los días posteriores a la exposición.

Nos damos cuenta que para los valores más centrales no hay ningún inconveniente, ya que temperaturas suaves entre los 15 y los 25 grados Celsius no son perjudiciales para la salud, ni provocan muertes. Por el contrario, a medida que nos acercamos a las esquinas y a los extremos, el valor del riesgo relativo se dispara.

Observemos que, según Gasparrini et al. (2010), cuando se realiza el modelo de regresión, aparte de incluir la base cruzada como variable explicativa, se añaden otras variables tales como el día de la semana o el promedio de ozono y monóxido de carbono en la atmósfera cada día. De esta manera se puede modelizar efectos que poseen las series temporales. En particular, se incluye un spline cúbico con 7 grados de libertad por cada año analizado con el fin de describir la tendencia a largo plazo y la estacionalidad.

En nuestro caso, carecemos de alguna de estas variables, pero puede resultar útil incluir en el modelo el spline cúbico que se menciona en el párrafo anterior. Así, volveremos a hacer el análisis de sensibilidad y a analizar los valores del QAIC con la diferencia de incluir en el modelo de regresión un spline cúbico natural con 70 grados de libertad (7 por cada uno de los




Figura 3.15: Gráficos de predicciones del nuevo modelo al que se ha incluido un spline natural cúbico para la fecha en el modelo de regresión

10 años de los que tenemos observaciones).

Bajo este cambio, se tiene que el mejor modelo va a seguir siendo el que tenga un B-spline para la temperatura y un spline natural para el retardo, ambos con 3 grados de libertad. Esta vez el valor del QAIC que se ha obtenido es 686365.2, que es menor que el que habíamos logrado antes. En general, en todos los casos se ha llegado a un valor del QAIC menor, lo que ya quiere sugerir que este modelo es mejor que el anterior. Dibujamos a continuación los gráficos:

Se observan claras diferencias. Para empezar, en la superficie, las esquinas que muestran lo que ocurre con una temperatura cercana al 0 se han suavizado. Lo mismo ocurre con el gráfico de efecto acumulado, que afirma que con temperaturas frías, el riesgo a fallecer es menor.

Notamos que el modelo puede ser objeto de mejora. Como ya hemos mencionado anteriormente, por falta de disponibilidad, no se han podido incluir más variables en el modelo de regresión como la contaminación o la humedad. Posiblemente esto hubiera hecho que en los gráficos se vieran otras cosas, como un mayor riesgo relativo unos días después de una exposición a una alta temperatura, y no inmediatamente en el retardo 0.

Capítulo 4

Conclusiones

4.1. Material Suplementario

El código de R empleado durante el trabajo para obtener todos los resultados se encuentra en el repositorio de GitHub: https://github.com/AlonsoPueyo/TFM_Alonso_Pueyo

Bibliografía

- [1] ACHEBAK H, DEVOLDER D, BALLESTER J (2018), *Heat-related mortality trends under recent climate warming in Spain: A 36-year observational study*. *PLoS Med*15(7): e1002617, <https://doi.org/10.1371/journal.pmed.1002617>
- [2] LINARES, C., DÍAZ, J. (2008), *Temperaturas extremadamente elevadas y su impacto sobre la mortalidad diaria según diferentes grupos de edad*. *Gaceta Sanitaria*, 22(2), 115-119.
- [3] GASPARRINI, A., ARMSTRONG, B. AND KENWARD, M.G. (2010), *Distributed lag non-linear models*. *Statist. Med.*, 29: 2224-2234, <https://doi.org/10.1002/sim.3940>
- [4] GASPARRINI A. (2011), *Distributed Lag Linear and Non-Linear Models in R: The Package dlnm*. *Journal of statistical software*, 43(8), 1–20.
- [5] GASPARRINI, A., ARMSTRONG, B. (2013), *Distributed lag non-linear models in R: the package dlnm*. *London School of Hygiene and Tropical Medicine, UK. dlnm version*, 1(7), 05-16.
- [6] GASPARRINI, A., ARMSTRONG, B., GASPARRINI, M. A. (2013), *Package ‘dlnm’*. 2017-01-16)[2017-10-05] <http://cran.r-project.org/web/packages/dlnm/dlnm.pdf>
- [7] BODEGAS DÍEZ, A. (2022), *Modelos Espaciales y Espaciotemporales en Disease Mapping*, UPV/EHU, MÁSTER UNIVERSITARIO EN MODELIZACIÓN E INVESTIGACIÓN MATEMÁTICA, ESTADÍSTICA Y COMPUTACIÓN, LEIOA
- [8] GOYENA BAROJA, H. (2021), *Predicciones a corto plazo en series temporales de alta frecuencia*, UNIVERSIDAD PÚBLICA DE NAVARRA, MÁSTER UNIVERSITARIO EN MODELIZACIÓN E INVESTIGACIÓN MATEMÁTICA, ESTADÍSTICA Y COMPUTACIÓN
- [9] BERGARA MARTÍNEZ, M. (2024), *Validación de modelos predictivos espaciotemporales de la incidencia y mortalidad por cáncer*, UPV/EHU, MÁSTER UNIVERSITARIO EN MODELIZACIÓN E INVESTIGACIÓN MATEMÁTICA, ESTADÍSTICA Y COMPUTACIÓN, LEIOA
- [10] RUTTEN, S., ESPINASSE, M., DUARTE, E., NEYENS, T., FAES, C. (2025), *On the lagged non-linear association between air pollution and COVID-19 cases in Belgium*. *Spatial and Spatio-temporal Epidemiology*, 52, 100709.
- [11] GONZÁLEZ DÍAZ, E. (2017), *Funciones Spline*, UNIVERSIDAD DE LA LAGUNA, GRADO EN MATEMÁTICAS, LA LAGUNA

- [12] QUIJAL-ZAMORANO, M., MARTINEZ-BENEITO, M. A., BALLESTER, J., MARÍ-DELL'OLMO, M. (2025), *Spatial Bayesian distributed lag non-linear models with R-INLA. International Journal of Epidemiology*, 54(4), dyaf120
- [13] RUE, H., RIEBLER, A., SØRBYE, S. H., ILLIAN, J. B., SIMPSON, D. P., LINDGREN, F. K. (2017), *Bayesian computing with INLA: a review. Annual Review of Statistics and Its Application*, 4(1), 395-421
- [14] QUIJAL-ZAMORANO, M., MARTINEZ-BENEITO, M. A., BALLESTER, J., MARÍ-DELL'OLMO, M. (2024), *Spatial Bayesian distributed lag non-linear models (SB-DLNM) for small-area exposure-lag-response epidemiological modelling. International journal of epidemiology*, 53(3), dyae061
- [15] WU, Y., LI, S., GUO, Y. (2021), *Space-time-stratified case-crossover design in environmental epidemiology study. Health Data Science*, 2021, 9870798