

Estudio del impacto de las altas temperaturas en la mortalidad diaria en España

Máster Universitario en Modelización e
Investigación Matemática, Estadística y
Computación



Universidad
Zaragoza

Alonso Pueyo Gómez
Trabajo de Fin de Máster
Universidad de Zaragoza
Tutora: Jaione Etxeberria

19 de noviembre de 2025

Resumen

El presente Trabajo Fin de Máster analiza la relación entre la mortalidad diaria y la exposición a temperaturas extremas en España durante el periodo 2023–2024, con un enfoque nacional y por provincias. El objetivo principal es identificar las temperaturas umbral a partir de las cuales el riesgo de fallecimiento aumenta significativamente y explorar cómo este riesgo varía espacialmente entre provincias.

Para ello, se aplican modelos de retardo distribuido no lineales (DLNM) y su extensión espacial (SB-DLNM), que permiten capturar tanto los efectos diferidos de la temperatura sobre la mortalidad como la dependencia entre regiones. Se incluyen análisis por subgrupos de edad para evaluar la vulnerabilidad de poblaciones específicas y se comparan los años 2023 y 2024 para identificar patrones estacionales.

Los datos utilizados comprenden defunciones diarias por provincia y grupo de edad, obtenidas de la aplicación MoMo, junto con temperaturas medias, mínimas y máximas procedentes de la AEMET. Todos los análisis se implementan en R, utilizando los paquetes *dlnm* e *INLA*, garantizando una modelización flexible que permite visualizar los efectos de temperaturas extremas tanto a nivel nacional como provincial.

Abstract

The purpose of this Master's Final Project is to analyse the relationship between daily mortality and exposure to extreme temperatures in Spain during the period 2023-2024, with a national and provincial approach. The main objective is to identify the threshold temperatures at which the risk of death increases significantly and to explore how this risk varies spatially across provinces.

To achieve that, distributed lag non-linear models (DLNM) and its spatial extension (SB-DLNM) will be applied, which allow capturing of both the delayed effects of the temperature over mortality and the dependence between regions. There are included subgroup analyses by age to assess the vulnerability of specific populations and there will be compared the years 2023 and 2024 to identify seasonal patterns.

The data used includes daily deaths by province and group age, obtained from the MoMo application, along with mean, minimum and maximum temperatures provided by AEMET. All the analyses are implemented in R using the *dlnm* and the *INLA* packages, ensuring a flexible modelling which enables to visualize the extreme temperatures effects at both national and provincial levels.

Índice general

Resumen	II
1. Introducción	1
2. Marco Teórico	3
2.1. Modelos Lineales Generalizados (GLM)	3
2.1.1. Regresión de Poisson	4
2.2. Modelos de retardo distribuido (DLM)	5
2.3. Modelos de retardo distribuido no lineales (DLNM)	6
2.4. Modelos DLNM bayesianos espaciales: SB-DLNM	8
2.5. Métodos de estimación de los modelos mediante el paquete <i>dlnm</i>	9
2.5.1. Métodos de inferencia y Software	9
2.5.2. Método Integrated Nested Laplace Approximations	11
3. Modelos DLNM con datos de mortalidad y temperatura	12
3.1. Fuente de datos	12
3.2. Análisis del exceso de mortalidad atribuible a la temperatura en España	13
3.2.1. Análisis descriptivo	13
3.2.2. Ajuste y comparación de modelos	16
3.3. Análisis del exceso de mortalidad atribuible a la temperatura en Sevilla	18
3.3.1. Análisis descriptivo	18
3.3.2. Ajuste y comparación de modelos	21
3.4. Análisis del exceso de mortalidad atribuible a la temperatura por provincias	23
4. Conclusiones	26
A. Material Suplementario	28
A.1. Estaciones meteorológicas por provincia	28
A.2. Datos poblacionales de España	29
A.3. Datos poblacionales de Sevilla	29
A.4. Elección de los modelos DLNM para el análisis estatal	29
A.5. Análisis por subgrupos de edad	32
A.6. Elección de los modelos DLNM para el análisis de Sevilla	34
Bibliografía	36

Capítulo 1

Introducción

El cambio climático constituye uno de los principales desafíos a los que se enfrenta la sociedad actual. En las últimas décadas se ha observado un incremento sostenido de las temperaturas globales, acompañado de olas de calor cada vez más frecuentes, intensas y prolongadas, especialmente durante los meses estivales. Estos fenómenos tienen un impacto directo sobre la salud pública, afectando de manera particular a los grupos más vulnerables, como las personas mayores. Numerosos estudios epidemiológicos han evidenciado la relación existente entre la exposición a altas temperaturas y el aumento de la mortalidad. Un ejemplo destacado es el estudio de Robine et al. (2008), donde analizaron el impacto de la ola de calor del año 2003 en 16 países europeos, considerada una de las más severas registradas en la historia reciente. En el año 2004, el Ministerio de Sanidad del Gobierno de España puso en marcha el sistema de monitorización MoMo (disponible en https://momo.isciii.es/panel_momo/). Su principal objetivo es identificar desviaciones en la mortalidad diaria observada con respecto a la esperada, basándose en el comportamiento histórico de la mortalidad. El sistema MoMo estima los excesos de mortalidad atribuibles a distintos factores, entre ellos las condiciones térmicas extremas, mediante un modelo aditivo generalizado (Generalized Additive Model, GAM) de distribución de Poisson. Este enfoque permite modelizar la relación entre la temperatura y la mortalidad de forma flexible, capturando tanto patrones no lineales como variaciones temporales en la respuesta. Este sistema constituye la fuente principal de datos empleada en el presente estudio.

A medida que se ha acumulado evidencia sobre los efectos de las temperaturas extremas en la salud, se han desarrollado nuevas metodologías que permiten analizar este fenómeno con mayor precisión. En este contexto, diversos trabajos han contribuido a mejorar las herramientas estadísticas empleadas en el estudio del impacto del calor sobre la mortalidad. Por ejemplo, Linares and Díaz (2008) abordaron esta relación mediante modelos ARIMA y regresión de Poisson. Posteriormente, Gasparrini et al. (2010) introdujeron un enfoque metodológico innovador basado en los modelos Distributed Lag Models (DLM) y Distributed Lag Non-Linear Models (DLNM), que será el utilizado en el presente trabajo. Los modelos DLM resultan especialmente útiles para analizar la estructura de retardo de efectos lineales entre una exposición y su consecuencia. Sin embargo, cuando dicha relación no es lineal —como ocurre entre la temperatura extrema y la mortalidad diaria—, los DLM presentan limitaciones. Para superar estas restricciones, los modelos DLNM amplían el enfoque, permitiendo capturar tanto los efectos inmediatos como los retardados de exposiciones no lineales. En el caso del calor, el efecto sobre la mortalidad no suele manifestarse de manera instantánea, sino que puede aparecer varios días después de la exposición. El enfoque DLNM incorpora una dimensión temporal adicional mediante lo que se conoce como base cruzada, una función bidimensional que describe simul-

táneamente la forma de la relación y la estructura temporal del retardo. Esto permite modelar con mayor precisión la dinámica entre la temperatura y la mortalidad atribuible al calor.

Se publicaron varios artículos de Gasparrini (2011) y Gasparrini and Armstrong (2013) en los que describieron en detalle la librería desarrollada en R, diseñada para implementar los modelos propuestos en sus trabajos previos. Esta herramienta ha supuesto un importante avance metodológico, al facilitar la aplicación práctica de los modelos DLNM en el ámbito de la epidemiología ambiental. Gracias a ello, se han llevado a cabo numerosas investigaciones que analizan la relación entre las temperaturas extremas y la mortalidad. Un ejemplo relevante es el estudio de Achebak et al. (2018), quienes aplicaron estos modelos para evaluar la mortalidad asociada al calor en España.

Más recientemente, Quijal-Zamorano et al. (2024) propusieron una metodología innovadora que adapta los modelos DLNM al marco de la estadística bayesiana, añadiendo además la dimensión espacial y llamados SB-DLNM (Spatial Bayesian Distributed Lag Non-Linear Models). Esta extensión no solo permite analizar la relación entre la exposición, el retardo y la respuesta, sino que también incorpora el efecto espacial, ofreciendo una visión más completa de cómo las regiones interaccionan entre sí en el contexto de la exposición a altas temperaturas.

En el ámbito de la monitorización de la mortalidad relacionada con el clima, el Ministerio de Sanidad del Gobierno de España desarrolló en 2004 el sistema de monitorización MoMo (https://momo.isciii.es/panel_momo/), que tiene como objetivo identificar desviaciones de la mortalidad diaria observada respecto a lo esperado según hechos pasados. Este sistema, que se utilizará como fuente principal de datos, calcula la predicción de excesos de mortalidad atribuibles a la temperatura mediante un modelo aditivo generalizado (GAM) de Poisson.

Este trabajo tiene como objetivo principal analizar la mortalidad atribuible a la exposición a calor extremo en distintos grupos de edad para el total de España, y adicionalmente por provincias, con el propósito de identificar las poblaciones más vulnerables a este fenómeno. Para ello, se utilizarán los modelos DLNM así como el modelo SB-DLNM desarrollado por Quijal-Zamorano et al. (2024), empleando los datos proporcionados por el sistema MoMo.

El Trabajo Fin de Máster se estructura de la siguiente manera: en la Sección 2, se presenta el marco teórico, que incluye una descripción detallada de los modelos estadísticos utilizados y de la librería empleada para su implementación. La Sección 3 se centra en la descripción de los datos y el análisis exploratorio, así como en la presentación de los resultados de la modelización. Finalmente, en la Sección 4, se exponen las principales conclusiones del estudio y se proponen posibles líneas futuras de investigación.

Capítulo 2

Marco Teórico

Este capítulo presenta el marco metodológico que sustenta el análisis desarrollado en este trabajo. Comienza con una revisión de los modelos lineales generalizados (GLM), para luego avanzar hacia los modelos de retardo distribuido (DLM) y los modelos de retardo distribuido no lineales (DLNM), los cuales constituyen la base fundamental del estudio. Dado que la exposición a temperaturas extremas no suele generar efectos inmediatos, sino que pueden manifestarse con varios días de retraso, los modelos de retardo distribuido resultan esenciales para capturar esta dinámica temporal. Estos modelos permiten distribuir el efecto de una exposición a lo largo de múltiples días, proporcionando un análisis más preciso de los impactos retardados. Finalmente, se describen modelos DLNM bayesianos espaciales, que incorporan la dimensión espacial para un análisis más profundo cuando el interés reside en estudiar el retardo de la temperatura a nivel de áreas geográficas.

2.1. Modelos Lineales Generalizados (GLM)

En esta sección se revisan los fundamentos de los modelos lineales generalizados (GLM), con especial énfasis en el caso de la regresión de Poisson, dado que este tipo de modelos serán el punto de partida para la modelización. Se comenzará por exponer los modelos lineales generalizados, como base conceptual, para posteriormente avanzar hacia la construcción y desarrollo de los DLM, que constituyen el objetivo principal de este estudio.

Los GLM son una extensión de los modelos de regresión lineal clásicos que permiten estudiar aquellos modelos cuyas variables explicadas no siguen una distribución normal. Los tipos más comunes son los siguientes:

- Regresión Logística: Las variables son binarias, solo toman el éxito o el fracaso como valores.
- Regresión Multinomial y Ordinal: Extensiones de la anterior cuando se tienen variables con más de dos niveles.
- Regresión de Poisson: Se utiliza cuando los datos son conteos. En la siguiente subsección nos centraremos y definiremos más en profundidad estos últimos.

2.1.1. Regresión de Poisson

De forma general, el modelo de regresión de Poisson es un caso específico dentro de los modelos lineales generalizados (GLM), empleado cuando la variable de interés Y representa un recuento, es decir, toma valores enteros no negativos (incluido el cero), y se asume que dicha variable sigue una distribución de Poisson. Este tipo de modelo es especialmente útil para analizar datos discretos que reflejan el número de ocurrencias de un evento en un intervalo de tiempo o espacio determinado.

Así, la función de probabilidad de la distribución de Poisson se define como:

$$P(Y = y) = \frac{e^{-\mu} \cdot \mu^y}{y!}, \quad y = 0, 1, 2, \dots \quad (2.1)$$

donde $\mu = E(Y) = Var(Y)$ es la media y la varianza del del número de casos observados.

En particular, a lo largo de este trabajo, nuestro interés residirá en estudiar el riesgo (riesgo relativo) de morir o enfermar. Esta medida compara el riesgo de un evento, en nuestro caso, la mortalidad asociada a temperaturas extremas, en un grupo expuesto frente a un grupo de referencia. Supongamos ahora que el interés radica en estimar el riesgo (o tasa) r_i de mortalidad o incidencia de una enfermedad en la unidad o estrato i . Condicionado al riesgo, se asume que el número de casos observados Y_i sigue una distribución de Poisson con media $\mu_i = e_i \cdot r_i$, donde e_i representa la exposición, es decir, la cantidad de tiempo-persona o población en riesgo en la unidad i , es decir:

$$Y_i | r_i \sim \text{Poisson}(\mu_i), \quad \text{para } i = 1, \dots, n. \quad (2.2)$$

Aplicando la función de enlace logarítmica, se obtiene la siguiente expresión:

$$\log(\mu_i) = \log(e_i) + \log(r_i) \quad (2.3)$$

En esta formulación, $\log(e_i)$ actúa como offset, es decir, como un término fijo conocido que no se estima, mientras que $\log(r_i)$ puede expresarse mediante un modelo lineal en función de covariables. Cuando se dispone de un conjunto de covariables X_{ji} que buscan explicar el comportamiento de la variable respuesta Y_i (el número observado de muertes o eventos en la unidad de análisis i), estas se relacionan con el valor esperado $\mu_i = E(Y_i)$ mediante una función de enlace logarítmica, la cual asegura que las predicciones del número esperado de muertes sean positivas, y por tanto da lugar al siguiente modelo lineal:

$$\log(\mu_i) = \beta_0 + \beta_1 X_{1i} + \dots + \beta_p X_{pi} \quad (2.4)$$

Los coeficientes β_j representan el cambio relativo en el número esperado de eventos por unidad de aumento de la variable explicativa X_{ji} manteniendo constantes el resto de variables. Por tanto, el modelo completo queda:

$$\log(\mu_i) = \log(e_i) + \beta_0 + \beta_1 X_{1i} + \dots + \beta_p X_{pi} \quad (2.5)$$

Este enfoque permite modelizar tasas/razones de incidencia o mortalidad, teniendo en cuenta tanto posibles factores explicativos como la variación en la exposición entre las unidades de análisis. Además, es posible incluir términos no lineales en el modelo. Para capturar estas relaciones más complejas, comúnmente se emplean interacciones entre variables o transformaciones empleando funciones no lineales de las mismas.

2.2. Modelos de retardo distribuido (DLM)

En la sección anterior se presentó el modelo de regresión de Poisson utilizado como base del análisis. A continuación, este enfoque se extiende mediante los modelos de retardo distribuido (Distributed Lag Models, DLM), que permiten incorporar el efecto retardado que una exposición puede tener sobre la variable respuesta. Este tipo de modelos son especialmente útiles cuando los efectos de una exposición no se manifiestan de forma inmediata, sino que pueden distribuirse a lo largo de varios días. Para ello, se define un vector de exposiciones pasadas en el día t como:

$$q_t = (e_t, e_{t-1}, \dots, e_{t-L})^T \quad (2.6)$$

donde e_{t-l} representa la temperatura observada l días antes (es decir, con un desfase de l días), y L es el número máximo de días de retardo considerados. Un modelo DLM simple puede expresarse de la siguiente manera:

$$\eta_t = \sum_{l=0}^L \delta_l e_{t-l} \quad (2.7)$$

donde δ_l representa el efecto de la temperatura con un retardo de l días.

Sin embargo, este enfoque puede verse afectado por problemas de colinealidad entre las variables e_{t-l} , debido a la alta correlación que suele existir entre las temperaturas de días consecutivos. Para mitigar este inconveniente, se imponen restricciones sobre los coeficientes δ_l . En este punto, conviene aclarar cómo se introducen estas restricciones sobre los coeficientes. Una estrategia habitual consiste en suponer que estos coeficientes no varían libremente con el retardo, sino que siguen una estructura funcional más suave. Para ello, se representan como combinaciones lineales de funciones, como podrían ser polinomios o splines.

De manera general, los modelos DLM se construyen sobre una base que permite representar los efectos distribuidos de la exposición a lo largo de los distintos retardos. En notación matricial, el efecto acumulado de la exposición retardada puede expresarse como:

$$s(e_t; \beta) = q_t^T C \beta \quad (2.8)$$

donde C es la matriz de variables base que se obtienen al aplicar las funciones base a los retardos, y β es el vector de parámetros que no se conocen. La estructura del modelo DLM depende de cómo se defina la matriz C . Si C es la matriz identidad, el modelo corresponde al caso sin restricciones, tal como se definió en la expresión (2.7).

En el contexto de este trabajo, el objetivo es modelizar la relación entre la temperatura y la mortalidad diaria, teniendo en cuenta no solo los valores extremos de temperatura, sino también los efectos que estos pueden ejercer a lo largo de varios días. Para ello, se considera un enfoque bidimensional. Por un lado, se modeliza cómo varía el riesgo en función de los distintos niveles de exposición (temperatura), y por otro, cómo este riesgo se distribuye temporalmente tras la exposición (retardo). Estas dos dimensiones, exposición y retardo, se integran en la modelización como una base cruzada lo que permite representar de manera flexible tanto la forma de la asociación como su evolución temporal.

2.3. Modelos de retardo distribuido no lineales (DLNM)

A continuación, se introduce el modelo de retardo distribuido no lineal (Distributed Lag Non-Linear Model, DLNM) que a diferencia de los modelos de retardo distribuido lineales, los DLNM permiten capturar relaciones no lineales entre la variable de exposición y la respuesta, incorporando al mismo tiempo la estructura temporal de los efectos retardados. Para ello, este enfoque propone explicar de forma conjunta, mediante funciones bidimensionales, tanto la asociación no lineal entre exposición y respuesta como la distribución temporal de dichos efectos.

A lo largo del trabajo se mencionarán constantemente las funciones splines, que resultan muy útiles para estudiar la relación no lineal de las variables. Los splines son funciones matemáticas flexibles. Están constituidos por funciones polinómicas que se unen suavemente en determinados puntos, conocidos como nudos (knots), permitiendo capturar comportamientos o relaciones complejas de los datos sin especificar una función concreta. En los modelos DLNM, los splines son frecuentemente utilizados para estudiar la relación no lineal existente entre la exposición y el efecto retardado. Existen diferentes tipos de funciones spline. Entre las más utilizadas se encuentran los splines cúbicos naturales y los B-splines. Los splines cúbicos naturales son polinomios de tercer grado unidos en los nudos, con la restricción de que fuera del rango definido por dichos nudos la función sea lineal. Por su parte, los B-splines (basis splines) constituyen una representación más general de los splines, basada en un conjunto de funciones base que se combinan linealmente para generar el spline total. Esta formulación proporciona mayor estabilidad numérica y flexibilidad en el ajuste.

En el trabajo de Gasparrini et al. (2010), que mencionamos en la introducción, y donde se explica el funcionamiento de los modelos DLNM, hay un ejemplo de aplicación sobre el efecto de la temperatura en la mortalidad en la ciudad de Nueva York. En él se menciona que se elige un modelo con splines cúbicos naturales para describir la relación en cada dimensión. En particular, el spline que se emplea para definir la temperatura tiene sus nudos igualmente espaciados a lo largo del rango de valores con el fin de dar flexibilidad a los extremos, cuando las temperaturas son más extremas. Por otra parte, el spline que se elige para definir la dimensión de los retardos define sus nodos de manera que se encuentren a la misma distancia en la escala logarítmica para flexibilizar la primera parte de la curva del retardo, que se espera más variable. Además, en ese modelo mencionado se está estudiando lo que ocurre en un retardo máximo de 30 días. Por último, el número de nudos que se eligen para cada spline de cada dimensión, que a su vez definen los grados de libertad, se eligieron según los criterios de información de Akaike y bayesianos modificados.

Tal y como se menciona previamente, una de las principales limitaciones de los modelos DLM es que suponen una relación lineal entre la exposición y la respuesta. No obstante, en el caso de la temperatura, numerosos estudios han demostrado que su relación con la mortalidad es claramente no lineal. Para abordar esta limitación, en este trabajo se adopta la metodología propuesta por Gasparrini et al. (2010), basada en los modelos de retardo distribuido no lineales (DLNM). Estos modelos permiten representar simultáneamente la forma no lineal de la asociación entre temperatura y mortalidad, así como la distribución temporal del efecto de la exposición. En un modelo DLNM, el efecto acumulado de la temperatura sobre la mortalidad en un día dado (t) se calcula como la suma de los efectos individuales correspondientes a las temperaturas registradas en los días anteriores. Esto se expresa mediante la siguiente expresión:

$$\eta_t = \sum_{l=0}^L f(e_{t-l}, l) \quad (2.9)$$

donde:

- η_t es el efecto total estimado de la temperatura sobre la mortalidad en el día t .
- e_{t-l} es la temperatura registrada hace l días.
- L es el máximo número de días de retardo (lag) considerado.
- $f(e, l)$ es una función bivariante que modeliza simultáneamente el efecto no lineal de la temperatura (e) y el efecto no lineal del retardo (l) en el tiempo.

Para construir la función $f(e, l)$, el modelo emplea B-splines (o basis splines). Estas son una técnica de regresión flexible diseñada para modelizar relaciones no lineales sin especificar su forma matemática exacta. Un B-spline se compone de segmentos de polinomios que se unen suavemente en puntos específicos llamados nodos. El objetivo es ajustar los datos de la manera más flexible posible, garantizando la suavidad de la curva de respuesta y evitando el sobreajuste (es decir, capturar ruido en lugar de la tendencia real).

Al definir la función $f(e, l)$ como un producto de B-splines para la temperatura y el retardo, el DLNM logra capturar la forma no lineal de la relación temperatura-mortalidad, es decir, la forma en que ese efecto varía a lo largo del tiempo de retardo.

Esta función se modela como la combinación de dos funciones base, una para la temperatura y otra para el retardo. Se escribe como:

$$f(e_{t-l}, l) = B(e_{t-l})^T \cdot \beta \cdot C(l) = \sum_{i=1}^I \sum_{j=1}^J \beta_{ij} \cdot B_i(e_{t-l}) \cdot C_j(l) \quad (2.10)$$

donde:

- $B(e)^T = (B_1^T(e), \dots, B_I^T(e))$ es la matriz de tamaño $I \times 1$ que contiene las funciones base que representan la forma de la relación en el eje de la temperatura.
- $C(l)^T = (C_1^T(l), \dots, C_J^T(l))$ es la matriz de tamaño $J \times 1$ que contiene las funciones base que describen la distribución del efecto en el eje de los retardos.
- $\beta = \begin{pmatrix} \beta_{11} & \dots & \beta_{1J} \\ \vdots & \ddots & \vdots \\ \beta_{I1} & \dots & \beta_{IJ} \end{pmatrix}$ es la matriz de parámetros a estimar.

Esta formulación permite capturar de manera flexible la relación entre la exposición a temperaturas extremas y la mortalidad, incluyendo patrones de retardo complejos y respuestas no lineales.

Definiendo la matriz C como en la sección anterior, un modelo DLNM se especifica de manera general como:

$$s(e_t; \beta) = r_t^T C \beta = \sum_{i=1}^I \sum_{j=1}^J r_{ti}^T c_j \beta_{ij}, \quad (2.11)$$

donde r_t es el vector de las componentes de la temperatura transformadas según las funciones de base.

2.4. Modelos DLNM bayesianos espaciales: SB-DLNM

Los modelos DLNM pueden extenderse al caso espacial, dando lugar a los modelos SB-DLNM (Spatial Bayesian Distributed Lag Non-linear Models). Estos modelos incorporan una componente espacial que permite capturar la dependencia y la influencia mutua entre regiones geográficamente cercanas. Es razonable esperar que provincias limítrofes con características similares presenten patrones de respuesta análogos al aplicar el modelo DLNM, lo que facilita identificar áreas con efectos comunes. Este enfoque fue introducido recientemente por Quijal-Zamorano et al. (2024), y será empleado específicamente para estudiar el efecto de la temperatura en la mortalidad a nivel provincial en España. En este caso, la implementación de estos modelos se realizará desde el punto de vista bayesiano, empleando INLA como método de estimación de los modelos. Esto se detallará en secciones posteriores.

Los efectos de la temperatura, al igual que los del retardo, se incorporan al modelo con splines, con bases de B-splines, lo que permite modelizar de forma flexible las relaciones no lineales y los efectos retrasados de la temperatura sobre la mortalidad. La implementación mediante R-INLA ofrece una aproximación computacionalmente eficiente, mucho más rápida que los métodos tradicionales como WinBUGS, lo cual es crucial dado el elevado número de parámetros y la complejidad del modelo.

En primer lugar, hay que introducir los modelos DLNM bayesianos (B-DLNM), que generalizaremos más tarde a los SB-DLNM. En ambos casos la implementación se realiza mediante el diseño de caso-cruce. Este diseño se trata de una estrategia de control del sesgo temporal. Su utilidad radica en evaluar si una exposición dada ha podido desencadenar un evento a corto plazo. Se basa en comparar la exposición en el momento en el que ocurre (día caso) con las exposiciones en días semejantes (días de control).

En este trabajo se busca controlar automáticamente las tendencias a largo plazo y estacionales, el efecto del día de la semana y otras variables que cambien lentamente a lo largo del tiempo. Para ello, se estratifican los datos según diversas variables, como el área, el año y el mes, o el día de la semana. Así, las temperaturas y el número de defunciones de un área se comparan con los del mismo área, mes, año y día de la semana. De esta manera, cada estrato se compone de varios días de caso (case-days, en inglés) que tienen en cuenta la evolución de cada área a través del tiempo.

Para los modelos B-DLNM, se analiza cada área individualmente extendiendo el enfoque frecuentista empleado hasta ahora al marco bayesiano. La variable respuesta que indica el número de ocurrencias de un evento ahora es Y_{ij} , y va a depender del día i y del área j . Sigue una distribución de Poisson de media μ_{ij} , es decir:

$$Y_{ij}|\mu_{ij} \sim \text{Poisson}(\mu_{ij}), \text{ para } i = 1, \dots, n, j = 1, \dots, m. \quad (2.12)$$

Al tratarse de una generalización de los DLNM, ajustamos los modelos relacionando μ_{ij} mediante una función de enlace logarítmico con la matriz correspondiente a la base cruzada. El modelo B-DLNM resultante es el siguiente:

$$\log(\mu_{ij}) = \sum_{s=1}^S \alpha_s + \sum_{k=1}^K \beta_{jk} \cdot C_{ijk} \quad (2.13)$$

donde:

- α_s es el intercepto de cada estrato s , que es el mismo entre días en el mismo área, año, mes y día de la semana.

- S es el número total de estratos que se tienen.
- K es el número de predictores de exposición-retardo expresados en sus respectivas bases.
- β_{jk} son los vectores de parámetros desconocidos, dependientes del área.
- C_{ijk} son las matrices de las bases cruzadas de cada día y área.

Generalizamos los modelos B-DLNM anteriores a modelos SB-DLNM incluyendo la dependencia espacial en los coeficientes de la base cruzada, es decir, en los parámetros β_{jk} modificando su distribución previa. Ahora se emplean efectos aleatorios con estructura espacial. En particular:

$$\beta_{jk} = \mu_k + \beta_{jk}^*, \text{ con } \beta_{jk}^* \sim N \left(\frac{\rho}{1 - \rho + \rho \cdot J} \cdot \sum_{j'} \beta_{j',k}^*, \frac{\sigma_k^2}{1 - \rho + \rho \cdot J} \right) \quad (2.14)$$

donde:

- μ_k es el valor medio que describe el efecto entero en cada región.
- β_{jk}^* representa el efecto aleatorio que introduce variabilidad espacial entre las áreas. Este término se modela mediante una distribución normal en la que la dependencia entre áreas vecinas está controlada por un parámetro $\rho \in [0, 1]$ que determina la intensidad de la correlación espacial. Unos valores próximos a 0 implican una estructura espacial débil, o prácticamente independiente, mientras que valores cercanos a 1 reflejan una dependencia espacial fuerte.
- J es el número total de áreas adyacentes que tiene una región. El índice que determina las áreas contiguas es j' .
- σ_k^2 es la varianza de los coeficientes de la base cruzada k .

Notamos que la media y la varianza de la distribución normal depende de la información de las áreas adyacentes. En particular, del número total de regiones contiguas que se posee y de los parámetros de variabilidad espacial para el mismo calor de k y área j' .

2.5. Métodos de estimación de los modelos mediante el paquete *dlnm*

2.5.1. Métodos de inferencia y Software

En la práctica, es necesario disponer de criterios que permitan evaluar y seleccionar los modelos que mejor se ajusten a los datos. A continuación, se describirán los métodos para el ajuste y comparación de modelos. En primer lugar, expondremos métodos clásicos, y en segundo lugar, métodos bayesianos más avanzados que nos permitirán inferir sobre los modelos SB-DLNM, como el método de aproximación de Laplace anidada integrada.

Desde un enfoque frecuentista, los parámetros del modelo se estiman mediante el método de máxima verosimilitud, propio de los modelos lineales generalizados. En particular, para una

regresión de Poisson con función de enlace logarítmico, se maximiza la función de verosimilitud definida por la distribución de Poisson de los conteos observados.

Sea Y_t el número de defunciones en el día t , y $\mu_t = E(Y_t)$ la media condicionada a las covariables y a la exposición retardada. El modelo se expresa como:

$$\log(\mu_t) = \alpha + X_t\beta$$

donde X_t es la matriz de diseño construida a partir de las bases cruzadas y otras covariables, y β el vector de parámetros que se desean estimar. Así, la función de verosimilitud es:

$$L(\beta) = \prod_{t=1}^n \frac{e^{-\mu_t} \mu_t^{Y_t}}{Y_t!}$$

Maximizando el logaritmo de esta función se obtienen las estimaciones de β .

Cuando se han ajustado varios modelos y se desea seleccionar el más adecuado, se pueden utilizar el Criterio de Información de Akaike (AIC) y el Criterio de Información Bayesiano (BIC). Ambos son indicadores que permiten evaluar el equilibrio entre el ajuste del modelo y su complejidad, donde un valor menor indica un mejor ajuste. Se calculan de la siguiente manera:

$$AIC = -2L(\beta) + 2k$$

$$BIC = -2L(\beta) + k \cdot \log(n)$$

siendo $L(\beta)$ la función de verosimilitud anterior, k el número de parámetros del problema, y n el número de observaciones.

Cuando los datos presentan sobredispersión y se utiliza un modelo quasi-Poisson, con $E(X) = \mu$ y $Var(X) = \phi\mu$, $\phi > 1$ (parámetro de sobredispersión), los criterios de información como AIC y BIC deben ajustarse para tener en cuenta la sobredispersión. Se calculan de la siguiente manera:

$$QAIC = -2L(\beta) + 2\phi k$$

$$QBIC = -2L(\beta) + \phi k \log(n)$$

El parámetro de sobredispersión de un modelo se obtiene como la relación entre la desviación residual y los grados de libertad.

Para implementar los modelos descritos en el trabajo utilizaremos el paquete *dlm* (versión 2.4.10) en R (R Core Team, 2024), desarrollado por Gasparrini (2011), Gasparrini and Armstrong (2013), Gasparrini et al. (2013). El paquete facilita la creación de bases de funciones para la variable de exposición y para los retardos, y las combina en lo que se denomina una base cruzada, que modela simultáneamente la no linealidad y el efecto retardado. Para ello, las principales funciones que se utilizan son:

- **onebasis()**: genera una base de funciones para una única dimensión (exposición o retardo). Es empleada para construir manualmente bases cruzadas o para modelos con relación lineal y efectos retardados (DLM).
- **crossbasis()**: construye la base cruzada combinando las bases de exposición y retardo, usada para ajustar modelos DLNM.
- **crosspred()**: calcula predicciones y efectos estimados a partir del modelo ajustado con la base cruzada.

- **crossreduce()**: resume el efecto bidimensional en una sola dimensión, facilitando la interpretación del efecto acumulado sobre la exposición o el retardo.

Los gráficos generados mediante la función **crosspred()** permiten visualizar y evaluar los resultados en términos de Riesgo Relativo (RR), medida que ya se ha introducido anteriormente. En este estudio, se compara el riesgo de mortalidad en días con temperaturas extremas frente a días con temperaturas suaves. En la librería *dlnm*, no se calculan riesgos absolutos (es decir, la probabilidad de fallecer por temperatura en un grupo específico durante un periodo determinado), sino efectos relativos a partir de un modelo de regresión quasi-Poisson. Concretamente, el RR se obtiene como la exponencial de la diferencia entre los valores de la función de respuesta en cada temperatura y la temperatura de referencia, función que se construye mediante la base cruzada.

El paquete también proporciona herramientas de visualización, incluyendo superficies tridimensionales, curvas de efecto acumulado y mapas de calor, lo que facilita la interpretación de los efectos de la exposición a lo largo del tiempo y según los retardos. En conjunto, la librería *dlnm* ofrece una implementación flexible y eficiente para ajustar modelos estadísticos complejos que permiten analizar efectos no lineales y retardados, siendo especialmente útil en epidemiología ambiental y campos relacionados.

2.5.2. Método Integrated Nested Laplace Approximations

Cuando se realice un análisis espacial para evaluar la influencia entre áreas vecinas mediante los SB-DLNM (Quijal-Zamorano et al., 2024), se empleará el método de Aproximaciones de Laplace Anidadas Integradas (INLA, Integrated Nested Laplace Approximations) (Rue et al., 2009). INLA permite realizar inferencia bayesiana en modelos jerárquicos, y en particular en modelos espaciales, de manera eficiente, proporcionando estimaciones precisas de los parámetros y de sus distribuciones a posteriori. En comparación con los métodos basados en cadenas de Markov Monte Carlo (MCMC), INLA reduce considerablemente el coste computacional sin sacrificar exactitud.

Este método es especialmente útil para la modelización de dependencia espacial entre regiones contiguas en estudios de mortalidad atribuible al calor. INLA se aplica dentro del marco de los Modelos Gaussianos Latentes (LGM), que incluyen modelos lineales generalizados y extensiones espaciales y temporales, como los SB-DLNM. Utiliza aproximaciones de Laplace para calcular distribuciones posteriores marginales de los parámetros, permitiendo estimar simultáneamente los efectos retardados en el tiempo y la estructura espacial, de manera eficiente. En R, la función *inla()* del paquete *R-INLA* facilita esta implementación.

Entre las estrategias de modelización de efectos retardados y espaciales se encuentran distintos diseños, siendo los más habituales el caso-cruce, que se empleará en este estudio, y el diseño de series temporales. Este último requiere la estimación de un gran número de parámetros para capturar tendencias y estacionalidad, incrementando la complejidad computacional. Por ello, para el análisis a nivel provincial en España, se ajustará un SB-DLNM mediante *R-INLA* con diseño caso-cruce, enfoque ampliamente usado en estudios sobre el impacto diario de factores ambientales en la salud.

Capítulo 3

Ilustración de los modelos DLNM con datos de mortalidad diaria y temperaturas en España

3.1. Fuente de datos

Para el desarrollo de este Trabajo Fin de Máster se han utilizado datos procedentes del Sistema de Monitorización de la Mortalidad Diaria (MoMo), accesible en https://momo.isciii.es/panel_momo/#section-momo. MoMo es un sistema de vigilancia implementado por la Unidad de Vigilancia de la Mortalidad Diaria del Centro Nacional de Epidemiología (CNE) del Instituto de Salud Carlos III, en el marco del Plan Nacional de Actuaciones Preventivas de los Efectos del Exceso de Temperaturas sobre la Salud (Plan Calor). Desde 2022, este sistema recopila información sobre defunciones diarias por todas las causas a partir de los registros civiles informatizados del Ministerio de Justicia, abarcando 4.128 municipios que representan aproximadamente el 93 % de la población española.

Además de los datos de mortalidad, actualizados diariamente, MoMo incluye el ámbito geográfico (provincia, comunidad autónoma o nacional), su nombre y código, el sexo y grupo de edad quinquenal de los fallecidos (con sus respectivos códigos), la fecha de defunción, el número de defunciones observadas y esperadas (estas últimas sin ajuste por temperatura) junto con sus respectivos intervalos de confianza, y el número de defunciones atribuibles al exceso o defecto de temperatura. Para el trabajo, seleccionaremos solo el ámbito provincial.

Fuentes de Información de MoMo. MoMo integra y procesa datos de diversas fuentes oficiales para generar sus estimaciones:

- Datos de Mortalidad Diaria: Obtenidos del Instituto Nacional de Estadística (INE) y, posteriormente, de los registros civiles informatizados del Ministerio de Justicia.
- Temperaturas: Proporcionadas por la Agencia Estatal de Meteorología (AEMET) a nivel provincial.
- Datos Poblacionales: Población por grupo de edad, sexo y provincia, procedentes del INE.

Los datos relativos a la temperatura se obtuvieron del portal de la AEMET (Agencia Estatal de Meteorología) conocido como AEMET OpenData (<https://opendata.aemet.es/>

centrodedescargas/inicio). Se trata de un API REST (Application Programming Interface. REpresentational State Transfer) que permite descargar de forma gratuita datos de las estaciones meteorológicas españolas. Las fechas de los datos descargados suman un total de 10 años, desde el 1 de enero del 2015 al 31 de diciembre del 2024. Por defecto, se incluyen datos de todas las estaciones meteorológicas, y para evitar tener sobrecarga de información, se eligió únicamente una estación por provincia. Los nombres de las estaciones seleccionadas se incluyen en el Anexo A. Una vez se tienen ambas bases de datos, se unifican en una sola según la fecha y el nombre de la provincia.

Para los análisis que se expondrán a partir de ahora, tanto estatal como provincial, se empleará una base de datos reducida, compuesta únicamente por las observaciones de los años 2023 y 2024. Existirán ciertas partes centradas en lo que ocurre durante los meses de verano e invierno de estos años. Para el análisis a nivel nacional se utilizarán todos los datos de la anterior base. Se describen las observaciones utilizadas con sus principales características, detalladas a continuación.

- La base de datos depurada consta de un total de 904464 personas fallecidas de 21 variables distintas, siendo 454320 relativas al año 2023 y 450144 del año 2024.
- El periodo temporal que se cubre es desde el 1 de enero del 2023 hasta el 31 de diciembre del 2024, ambos incluidos.
- Las variables clave del estudio que se usarán principalmente para el análisis son:
 - *fecha_defuncion*: la fecha en la que han fallecido las personas.
 - *nombre_ambito*: muestra el nombre de la provincia a la que pertenecen los datos.
 - *nombre_sexo*: muestra si los datos son relativos a las mujeres, los hombres, o en general.
 - *cod_gedad*: indica el subgrupo de edad al que pertenecen los datos.
 - *defunciones_observadas*: cuenta el número de fallecimientos que ha habido cada día, de cada grupo de población y en cada sitio.
 - *tmed*: el valor de la temperatura media diaria.

3.2. Análisis del exceso de mortalidad atribuible a la temperatura en España

3.2.1. Análisis descriptivo

En primer lugar, se procede a un análisis descriptivo preliminar de los datos, cuya finalidad es identificar comportamientos entre la temperatura y la mortalidad clave que justifiquen la necesidad de emplear los modelos de retardo distribuido. Para este análisis descriptivo, primero se calculan los valores promedio de la temperatura media y la tasa de mortalidad por 100000 habitantes para cada mes. Para la tasa se utilizaron los datos disponibles acerca de la población total en España del Instituto Nacional de Estadística (INE). Este organismo posee datos trimestrales, que se han incluido en el Anexo A. Los resultados se presentan de manera gráfica en la Figura 3.1.




Figura 3.1: Evolución mensual (2023-2024) de la temperatura media y la tasa de mortalidad estandarizada por 100000 habitantes a nivel nacional.

El análisis revela un patrón estacional marcado en ambos años: la tasa de mortalidad tiende a presentar mayores valores durante los meses fríos. No obstante, es importante destacar que no todos los fallecimientos en invierno son atribuibles a la temperatura, ya que la mortalidad invernal es multifactorial, estando influida en gran medida por enfermedades estacionales como la gripe y otras patologías respiratorias. En contraste, el objetivo específico de este estudio es analizar la mortalidad atribuible al exceso de temperatura durante los meses de verano.

A continuación se seleccionan los meses de verano (julio y agosto) y los de invierno (enero y febrero) del 2023 y el 2024, y se estudia el valor del promedio de las temperaturas medias y la suma de las defunciones observadas por provincias en estos periodos. Se seleccionan solo ciertas provincias. Los resultados se encuentran en las Tablas 3.1 y 3.2.

	Verano 2023	Verano 2024	Invierno 2023	Invierno 2024
Asturias	19.80	19.48	9.00	11.44
Barcelona	26.30	25.97	9.52	12.01
Madrid	27.57	27.82	6.23	8.61
Navarra	23.11	22.95	4.81	7.19
Sevilla	29.62	28.82	11.21	12.89
Zaragoza	27.12	27.47	7.10	9.30

Tabla 3.1: Valores medios de las temperaturas medias diarias en provincias de España durante los meses de verano (julio y agosto) e invierno (enero y febrero) de los años 2023 y 2024.

	Verano 2023	Verano 2024	Invierno 2023	Invierno 2024
Asturias	2005	2142	2466	2602
Barcelona	7696	7815	9515	9699
Madrid	7150	7675	9102	9389
Navarra	908	960	1071	1213
Sevilla	2546	2457	3364	3275
Zaragoza	1675	1710	2010	2125

Tabla 3.2: Suma de las defunciones diarias notificadas en provincias de España durante los meses de verano (julio y agosto) e invierno (enero y febrero) de los años 2023 y 2024.

Se han seleccionado provincias cálidas y frías para comparar. El invierno del año 2024 muestra temperaturas más altas que el año anterior. La diferencia entre las temperaturas de Asturias y de Sevilla implica que España está compuesta por regiones con climas distintos. A la hora de hacer un estudio a nivel estatal hay que tener en cuenta que se mezcla información de muchos lugares con distintos climas en un solo modelo.

Como ya se ha confirmado previamente, en todas las provincias se registran más muertes en invierno que en verano, y muchas se encuentran relacionadas con las enfermedades relativas a la época del año. Se observa también que hay más fallecimientos en estas regiones en 2024 que en 2023.

Para finalizar este análisis descriptivo se presentan las tasas de mortalidad por 100000 habitantes para las provincias seleccionadas y los mismos periodos. Los resultados se muestran en la Tabla 3.3.

	Verano 2023	Verano 2024	Invierno 2023	Invierno 2024
Asturias	198.59	212.21	244.22	257.74
Barcelona	130.94	132.96	161.88	165.02
Madrid	102.01	109.50	129.86	133.95
Navarra	133.83	141.49	157.85	178.86
Sevilla	129.32	124.83	170.87	166.38
Zaragoza	169.55	173.08	203.49	215.16

Tabla 3.3: Tasas de mortalidad por cada 100000 habitantes en las diferentes provincias seleccionadas y durante los meses de verano e invierno de los años 2023 y 2024.

La provincia con las tasas de mortalidad más altas es Asturias, mientras que Madrid presenta las más bajas. Las diferencias en las tasas entre 2023 y 2024, consideradas para la misma época del año, muestran una variabilidad notable. Este análisis pone de relieve la necesidad de evaluar la mortalidad ajustada por población y temporalidad para identificar patrones y regiones más vulnerables.

Los resultados de las tablas anteriores muestran un patrón estacional en el que la mortalidad durante los meses de invierno es notablemente más alta que en los meses de verano. A su vez, se aprecia un aumento de la mortalidad de 2023 a 2024, tanto en verano como en invierno. Aunque el incremento no es uniforme, la tendencia general es ascendente. Esto podría deberse a las temperaturas extremas, tanto frías como cálidas, que se dan durante los meses de invierno y verano. Por último, se aprecian diferencias sustanciales entre regiones. Asturias presenta las tasas más altas en todos los periodos, mientras que Madrid tiene las más bajas.

La forma de estos resultados depende de numerosas variables. Una mayor mortalidad en una región puede ser causada por una población más envejecida, o por un invierno o un verano con un mayor número de días con temperaturas extremas, entre otras. Asimismo, recordemos que la relación entre la temperatura y la mortalidad no es lineal, y que también influyen los días de retardo que tardan los efectos en aparecer. Las tendencias observadas refuerzan la necesidad de aplicar un modelo que capture relaciones complejas y retardadas, luego concluimos que los modelos DLNM son los más adecuados para el estudio, debido a su capacidad para estimar de manera flexible la relación a lo largo del tiempo, captando tanto efectos inmediatos como retardados.

3.2.2. Ajuste y comparación de modelos

Con el objetivo de identificar el modelo que mejor se ajusta a los datos observados sin incurrir en sobreajuste, se procede a modelizar la relación entre temperatura y mortalidad mediante modelos DLNM. El análisis se realiza por separado para los años 2023 y 2024. En primer lugar, se lleva a cabo un análisis de sensibilidad en el que se comparan distintos tipos de modelos DLNM y se evalúan sus valores del QAIC. Esta comparación permite determinar el modelo más adecuado para describir la relación entre las variables de interés. En ambos casos, se consideran bases cruzadas con un máximo de 30 días de retardo. Las dimensiones de temperatura y retardo se modelizan mediante splines naturales y B-splines, alternando diferentes grados de libertad —entre 3 y 7— con el fin de explorar la flexibilidad de los ajustes. Se incluyen como varias explicativas para estudiar las defunciones observadas la base cruzada, el día de la semana y un spline natural de la fecha de defunción, con siete grados de libertad por año analizado. Tras la evaluación de las distintas combinaciones, se seleccionó como modelo óptimo aquel que incorpora B-splines con cuatro grados de libertad tanto en la dimensión de la temperatura como en la de los retardos, al ofrecer el valor más bajo del QAIC y un ajuste estable sin pérdida de parsimonia. Las tablas y los resultados de este análisis pueden ser encontradas en el Anexo A.

El modelo se ajustó de forma independiente para los años 2023 y 2024, permitiendo así comparar las respuestas obtenidas en cada periodo. Los gráficos tridimensionales y los efectos acumulados asociados a cada ajuste se presentan en las Figuras 3.2 y 3.3, respectivamente.




Figura 3.2: Representación de la superficie de riesgo (3D) y del efecto acumulado (2D) del modelo DLNM (B-spline-B-spline, 4-4 GL) en la mortalidad de España, año 2023.




Figura 3.3: Representación de la superficie de riesgo (3D) y del efecto acumulado (2D) del modelo DLNM (B-spline-B-spline, 4-4 GL) en la mortalidad de España, año 2024.

En general, el modelo del 2024 presenta una superficie más suave y un mejor ajuste que el de 2023, probablemente debido a diferencias en las condiciones meteorológicas. Se observa un menor ajuste en los valores extremos, donde el RR tiende a valores cercanos a cero, un comportamiento esperado en los modelos basados en splines, que priorizan relaciones suaves y son menos precisos en los extremos. En términos de respuesta, bajo temperaturas frías el RR máximo se alcanza con un retardo de unos cinco días, mientras que bajo temperaturas cálidas el efecto máximo se produce en los primeros días tras la exposición. Los efectos acumulados muestran que el mayor RR se obtiene alrededor de los 10°C, aumentando considerablemente a partir de los 30°C. En conjunto, los resultados sugieren que los efectos del frío se manifiestan de forma retardada, mientras que los del calor aparecen casi de inmediato, siendo las temperaturas inferiores a 10°C y superiores a 30°C los umbrales que requieren especial atención.

Por último, se realizó un análisis por subgrupos de población basándonos en la edad. El objetivo era encontrar alguna relación que permitiera asociar una mayor mortalidad a un determinado grupo. Se dividieron las observaciones en los siguientes grupos según los años: 0-14, 14-44, 45-64, 65-74, 75-84 y mayores de 85.

Los datos empleados para esta parte consisten en las observaciones de los años 2023 y 2024, juntas. No se pretende hacer un estudio comparativo acerca de lo que ocurrió durante ese tiempo en los distintos grupos de población. Tras un breve análisis, se conoce que el número de fallecimientos notificados relativos a los grupos de las personas de una mayor edad es superior a los de aquellos grupos más jóvenes, como cabía esperar. Se utilizaron los modelos propuestos en los párrafos anteriores. No se observaron grandes diferencias gráficas entre unos grupos y otros, pero a continuación se incluyen los resultados correspondientes al grupo de más de 85 años, puesto que son los que más riesgo tienen de fallecer. Los gráficos se observan en la Figura 3.4. El resto de resultados se pueden encontrar en el Anexo A.




Figura 3.4: Representación de la superficie de riesgo (3D) y del efecto acumulado (2D) del modelo DLNM en la mortalidad del grupo de población de más de 85 años de edad.

Se observa que cuando la temperatura se sitúa entre los 5 y los 30°C, no existe ningún aumento del RR. Sin embargo, temperaturas más frías se asocian con un riesgo de fallecer más alto alrededor del día 5 de retardo, y más cálidas llevan a un mayor RR los primeros días tras la exposición. Al igual que ocurría en el análisis de los datos en general, las temperaturas umbrales a partir de las cuales hay que empezar a tener precaución son los 5 y los 30°C, especialmente en los grupos más vulnerables a las temperaturas extremas. Los efectos provocados por una exposición a temperaturas extremadamente bajas no ocurren de manera inmediata, como sí que pasa bajo una exposición a temperaturas altas.

3.3. Análisis del exceso de mortalidad atribuible a la temperatura en Sevilla

El análisis provincial en Sevilla se plantea con el objetivo de evaluar la consistencia del modelo desarrollado a nivel nacional en una región más pequeña. Sevilla presenta unas condiciones climáticas cálidas, lo que permite analizar si la relación entre temperatura y mortalidad se mantiene estable o presenta diferencias en un entorno menos extremo. Además, el estudio a escala provincial ofrece una perspectiva aplicada de interés para la salud pública local, al posibilitar la identificación de patrones específicos que puedan servir de base para estrategias regionales de prevención y alerta ante temperaturas extremas.

3.3.1. Análisis descriptivo

En esta sección se va a realizar un análisis similar al de la sección anterior, pero centrado en la provincia de Sevilla. Se seleccionarán los datos de MoMo de los años 2023 y 2024 pertenecientes a la región de Sevilla. Se procederá de manera semejante al análisis que se hizo de toda España. En primer lugar, un análisis descriptivo para conocer los datos de los que se disponen y llegar a una motivación para el trabajo. Después, se buscará el modelo que mejor se aproxime y se estudiarán sus predicciones. Los datos de MoMo referentes a la provincia de Sevilla constan de un total de 60264 observaciones. En particular, del año 2023 hay 8664, y del 2024 existen

8688. Notamos que ya no se disponen de datos variados de distintas regiones de España, tanto cálidas como frías. El número de datos también se ha reducido significativamente. No se dispone de las observaciones de las temperaturas y defunciones por municipios de Sevilla, sino que solo se posee la información de la estación meteorológica del aeropuerto de Sevilla para toda la provincia.

A continuación, se llevará a cabo un análisis descriptivo cuyo principal objetivo es explorar, de forma descriptiva, la posible relación entre las defunciones registradas en Sevilla y las temperaturas extremas. En primer lugar, se calculará el promedio de las temperaturas mensuales y la tasa de mortalidad por cada 100000 habitantes, correspondientes a los años 2023 y 2024. Los datos trimestrales sobre la población de Sevilla fueron obtenidos del Instituto Nacional de Estadística (INE) y se encuentran detallados en el Anexo A. Los resultados de este análisis se presentan en la Figura 3.5.




Figura 3.5: Evolución mensual (2023-2024) de la temperatura media y la tasa de mortalidad estandarizada por 100000 habitantes en Sevilla.

En ambos años, la temperatura sigue un patrón estacional típico. Los valores de las temperaturas medias mensuales más bajos se alcanzan en enero y diciembre, superando ligeramente los 10°C. Los más altos llegan en verano, durante los meses de julio y agosto, donde se rozan los 30°C de temperatura media. Con este análisis ya se observa que el clima de Sevilla consta de inviernos suaves y veranos muy calurosos y extremos que influirán en la mortalidad atribuible al exceso de temperatura. De los gráficos de la columna izquierda también se notan unas temperaturas en el 2024 algo más elevadas, sugiriendo que, en general, fue un año más cálido que el anterior.

Las tasas de mortalidad mensuales forman un patrón inverso al de la temperatura. El número de fallecimientos es mayor en invierno que en verano. Los valores que se observan en 2024 son algo más altos en promedio, y el repunte en diciembre es mucho más marcado que en el 2023. Este hecho podría relacionarse con alguna ola de frío. Se destaca el mes de agosto del 2023 debido a un valor de la mortalidad más alto que los meses contiguos, probablemente dado por

un ola de calor muy intensa durante ese tiempo.

En general, en 2024, las temperaturas cálidas y la mortalidad asociada a ellas parecen más extremas, lo que respalda la idea de una relación entre ambas variables.

A continuación se estudiará las tasas de mortalidad de cada año en función del rango de la temperatura. Se realizará la misma división de la temperatura que se hizo en el apartado del análisis de España. Sin embargo, se observan notables diferencias debido a los veranos más extremos que se viven en Sevilla. Los resultados se muestran en la Tabla 3.4.

Rango de temperatura	2023	2024
Menor de 10 °C	98,28	34,84
Entre 10 °C y 20 °C	353,48	444,78
Entre 20 °C y 30 °C	317,86	322,45
Más de 30 °C	67,01	29,64

Tabla 3.4: Tasa de defunciones por año y por rango de temperatura media en 2023 y 2024 en Sevilla.

Se observa que, en ambos años, la mayor parte del exceso de mortalidad atribuible a la temperatura se concentra en los rangos intermedios de temperatura, entre los 10 y los 30°C. Esto ocurre porque la mayoría de los días del año presentan estas temperaturas medias. Los fallecimientos ubicados entre los 10 y los 20°C aumentan en casi 100 unidades de un año a otro, y disminuyen bastante las muertes ocurridas en días con temperatura media inferior a 10°C, lo que sugiere un 2024 más cálido y con un mayor número de días situados por encima de los 10°C.

En general, los valores de los extremos son bastante inferiores, especialmente en el 2024. Esto implica que las defunciones ocurridas en días con temperaturas extremas tienen una menor frecuencia, aunque no significa que exista un menor riesgo de fallecimiento. Por último, comparando ambos años, se observa que en 2024 la mortalidad bajo temperaturas extremas disminuye, pero aumenta en el rango intermedio. Esto significa que las temperaturas moderadas fueron más frecuentes, aunque todavía se puede asociar la mortalidad con clima extremo.

Para terminar con este análisis descriptivo, se procede a la realización de una tabla con información acerca de lo que ocurrió en Sevilla durante los meses más fríos y más cálidos del año. El resumen se encuentra en la Tabla 3.5.

	Verano 2023	Verano 2024	Invierno 2023	Invierno 2024
Media temperaturas medias	29.62	28.82	11.26	12.91
Suma defunciones diarias	2546	2457	3364	3275
Tasa mortalidad	129.69	124.71	171.68	166.38

Tabla 3.5: Tabla descriptiva resumen de los datos de la región de Sevilla en los meses de verano (julio y agosto) e invierno (enero y febrero) de los años 2023 y 2024.

Como se mencionó anteriormente, la mortalidad en invierno, alrededor de 170 fallecimientos por cada 100000 habitantes, es superior a la de verano, entre 125 y 130. Los inviernos fueron suaves, debido a que los valores de las temperaturas medias no bajan de los 10°C, mientras que

los veranos en la región sí son más extremos, alcanzando casi los 30°C de media en verano. Pese a ser Sevilla una región cálida, se confirma que tanto el frío como el calor se asocian con un exceso de mortalidad atribuible a la temperatura.

3.3.2. Ajuste y comparación de modelos

Procederemos a continuación con el apartado de modelización de los datos. Recordemos que el objetivo es encontrar un modelo DLNM que se ajuste correctamente a los datos disponibles, y a partir del cual realizar una predicción. De manera semejante a lo que se hacía en la modelización de todo el país, se realizan dos análisis de sensibilidad, uno para cada año que estamos estudiando, 2023 y 2024, donde se modifica la base cruzada de los modelos, alternando entre el tipo de spline utilizado para aproximar la dimensión de la temperatura y la del retardo, así como la cantidad de grados de libertad que los definen. El retardo máximo se tomará de 30 días. Los modelos estudian las defunciones observadas en función de la base cruzada, el día de la semana y el spline de la fecha del fallecimiento con 7 grados de libertad. Los análisis de sensibilidad se pueden encontrar en el Anexo A.

Los análisis de sensibilidad han mostrado que los mejores modelos para predecir ambos años son aquellos que poseen la menor cantidad de grados de libertad en total. Finalmente se va a utilizar el modelo que emplea un B-spline para la dimensión de la temperatura y un spline natural para la del retardo, ambos con 3 grados de libertad, para los datos de ambos años. Tras ello, se realiza su predicción. Además, se van a dibujar las superficies y los gráficos de efecto acumulado en cada uno de los casos. Estos resultados se encuentran en las Figuras 3.6 y 3.7.




Figura 3.6: Representación de la superficie de riesgo (3D) y del efecto acumulado (2D) del modelo DLNM (B-spline-NS, 3-3 GL) en la mortalidad de Sevilla, año 2023.




Figura 3.7: Representación de la superficie de riesgo (3D) y del efecto acumulado (2D) del modelo DLNM (B-spline-NS, 3-3 GL) en la mortalidad de Sevilla, año 2024.

A la izquierda de las figuras se muestra la superficie tridimensional que relaciona temperatura, retardo y RR. Para los resultados del año 2023, se observa un incremento del RR en los extremos. En particular, con temperaturas elevadas, el efecto del calor se manifiesta de manera inmediata. El mayor RR se alcanza los primeros días de retardo tras la exposición, decreciendo con el paso del tiempo. Por otra parte, las temperaturas frías llegan a un valor del RR menor, que se mantiene por encima del 1 hasta una semana después de la exposición. Este patrón indica que el calor provoca un aumento rápido en la mortalidad, mientras que el frío produce efectos más retardados y sostenidos.

La superficie que explica las observaciones del año 2024 muestra, bajo temperaturas altas, un pico alrededor del día de retardo 15, donde se llega a alcanzar un RR con un valor de 1.04. Este desplazamiento en el día de retardo en el que se alcanza el máximo RR podría ser debido a varios días continuados de calor extremo, posiblemente una ola de calor sucedida durante el verano de ese año. Cuando las temperaturas son bajas, en ambos casos se ha visto que en el retardo 0 el RR aumenta hasta un valor máximo de aproximadamente 1.03 con una temperatura de unos 12°C, decreciendo a la vez que bajan también los grados.

Los otros gráficos representan el efecto acumulado de la temperatura sobre la mortalidad. En ambos casos el valor del RR se sitúa ligeramente por encima del 1 cuando las temperaturas aumentan, y por debajo cuando decrecen. En el año 2024 el RR llega hasta el 0.9 bajo temperaturas inferiores a los 10°C. Las zonas dibujadas en gris representan los intervalos de confianza y se destaca su amplitud. Estos resultados confirman la relación no lineal que existe entre temperatura y mortalidad, donde el calor tiene efectos más inmediatos en la salud que el frío, que posee un impacto más prolongado y menos intenso.

Semejantemente a lo que ocurrió en el análisis estatal, no disponemos de suficientes variables que nos permitan analizar la mortalidad atribuible a la temperatura en Sevilla correctamente. Se han llegado a unos modelos útiles, que explicaban bien el comportamiento del riesgo de fallecer en función de la temperatura y los retardos. Sin embargo, presentaban fallos, como la adaptación de las funciones spline en las esquinas de la superficie.

Pese a ello, se puede concluir que, en Sevilla, ocurren fallecimientos atribuibles tanto al frío como al calor. Las temperaturas umbral a partir de las cuales aumenta el riesgo de defunción en esta región son los 12 y los 28°C, aproximadamente. También se llega a la conclusión de que los veranos son constantes, y el hecho de estar expuesto varios días a temperaturas muy altas resulta en un mayor riesgo de mortalidad dos semanas después. Por último, si la exposición no

es prolongada, sufrir tanto temperaturas altas como bajas tiene efectos nocivos en la salud que se manifiestan de manera casi inmediata, entre el primer y el tercer día de retardo, tardando ligeramente más bajo el frío.

Se ha demostrado con esta sección que la metodología planteada a lo largo del trabajo, y empleada en el análisis estatal, también resulta útil y produce resultados si se restringe a los datos de una sola región. De hecho, de esta manera se logra más información que quedaría enmascarada en un análisis más amplio. En el análisis de España se disponían de numerosas observaciones de distintos lugares con climas diferentes entre sí. Eso resultaba en una mezcla de datos que proporcionaba la relación general entre la mortalidad y el frío y el calor, pero no se obtenían consecuencias particulares en la zona, lo que sí se logra al estudiar solamente una región.

3.4. Análisis del exceso de mortalidad atribuible a la temperatura por provincias

En esta sección se aborda el análisis de mortalidad atribuible a la temperatura a nivel provincial, utilizando un enfoque novedoso y reciente: el método SB-DLNM, (Quijal-Zamorano et al., 2025) implementado mediante un diseño de caso-cruce con R-INLA. Esta metodología permite capturar los efectos térmicos diarios en contextos locales, aportando una perspectiva que va más allá de los análisis nacionales convencionales. Los datos se estratifican por provincia, año, mes y día de la semana, comparando cada día con días equivalentes dentro de su mismo contexto temporal. Se incluyen múltiples días de control por estrato y se excluyen aquellos sin defunciones, asegurando que el efecto del día de la semana quede controlado de forma natural. Esta estrategia permite revelar patrones locales que podrían perderse en un análisis agregado. Para concentrarnos en los períodos climáticos más extremos, se limita el análisis al año 2024, examinando los meses más calurosos y más fríos. Este desglose provincial no solo permite contrastar los resultados con los hallazgos nacionales, sino que también constituye un aporte relevante en sí mismo, mostrando la consistencia o divergencia del modelo en distintos contextos locales. El modelo SB-DLNM, empleado en este trabajo, permite incorporar la dependencia espacial: se asume que la mortalidad en una provincia puede estar correlacionada con la de sus vecinas, lo que mejora la precisión de las estimaciones y captura patrones regionales que no serían evidentes en un análisis aislado. Ceñirnos al análisis de los meses de julio-agosto y enero-febrero de 2024 permitió estudiar los resultados centrándonos en los períodos de mayor interés epidemiológico. Tras la ejecución de los respectivos modelos, se calcularon los valores del RR para cada combinación entre la temperatura y el retardo en cada sitio. En este contexto, el RR representa la razón entre la probabilidad de fallecer debido a una temperatura dada y la probabilidad de fallecer bajo una temperatura de referencia, los 20°C. Así, valores de RR superiores a 1 indican un exceso relativo de mortalidad debido a la temperatura de exposición, mientras que valores inferiores a 1 reflejan un riesgo menor que el esperado.

Tras centrar el valor del RR, se muestran los resultados en las Figuras 3.8 y 3.9, dos mapas de España que muestran con distintos gradientes de colores la distribución espacial del RR en el percentil 99 de temperatura. Los RR representados en los mapas indican el exceso relativo de mortalidad estimado para cada provincia según la tendencia local y la de las provincias vecinas. No se incluyen las ciudades autónomas de Ceuta y Melilla.




Figura 3.8: Mapa provincial con los distintos valores del Riesgo Relativo por provincias en los meses de julio y agosto del año 2024.




Figura 3.9: Mapa provincial con los distintos valores del Riesgo Relativo por provincias en los meses de enero y febrero del año 2024.

En la Figura 3.8 se presenta el riesgo relativo de mortalidad asociado al calor durante el verano de 2024. Los valores de riesgo relativo (RR) oscilan entre 0.74 y 1.38. Gipuzkoa registra el valor más bajo, mientras Barcelona alcanza el más alto. En el sur y este del país, provincias Sevilla, Granada o Castellón, presentan tonalidades azules en el mapa, indicando un RR menor que 1 (aproximadamente 0.91), indicando un riesgo menor que el esperado. Por el contrario, la mayoría de provincias aparece en tonos rojos, mostrando un riesgo superior a 1, lo que refleja una mayor mortalidad atribuible al calor. Los valores más elevados se localizan en A Coruña, Cantabria o Palencia, con un RR entre 1.12 y 1.24. Estas diferencias reflejan la influencia del clima sobre la mortalidad atribuible al calor. Las provincias con RR inferior a 1 se sitúan cerca del Mediterráneo, con un clima más cálido durante todo el año, por lo que un aumento de la temperatura en verano no genera un incremento en la mortalidad. Por el contrario, las provincias del norte, con climas más fríos y húmedos, presentan mayor vulnerabilidad ante olas de calor, registrando un exceso de mortalidad más pronunciado. Los valores extremos en Gipuzkoa y Barcelona pueden deberse a que la selección de datos fue restringida únicamente al verano de 2024.

En cuanto al invierno de 2024, los resultados se muestran en la Figura 3.9. Los valores de RR oscilan entre 0.84 y 1.10. Las provincias con menor RR son Lugo y Cádiz, mientras que Asturias presenta el valor más alto. En la zona norte, provincias como Lugo, Cantabria y Navarra tienen un RR entre 0.84 y 0.90, lo que implica un riesgo de mortalidad entre un 10 % y un 16 % menor que el esperado. En cambio, Asturias, A Coruña, Cantabria y Gipuzkoa muestran valores superiores a 1.05, reflejando un riesgo un 5 % más alto que el esperado. En general, el riesgo de fallecimiento atribuible a las bajas temperaturas es homogéneo en todo el país. Exceptuando ciertas provincias del norte que muestran valores más bajos, la mayoría presentan RR superiores a 1, lo que indica un riesgo moderado y generalizado asociado a las temperaturas de invierno.

Capítulo 4

Conclusiones

En este trabajo se ha explorado el uso de modelos de retardo distribuido no lineales (DLNM) para analizar el exceso de mortalidad atribuible a la temperatura, empleando diferentes escalas geográficas y metodologías recientes. Inicialmente, se presentó la teoría y aplicación de los modelos DLNM y SB-DLNM, los métodos de estimación y la implementación en el software R. A continuación, se analizaron los datos a nivel nacional, evaluando la mortalidad atribuible a la temperatura en toda España y seleccionando el modelo más adecuado mediante distintas pruebas de ajuste. También se llevó a cabo un estudio más detallado para la provincia de Sevilla que permitió estudiar la validez del modelo en regiones geográficas más pequeñas.

Posteriormente, se trasladó el análisis al contexto espacial mediante el novedoso enfoque SB-DLNM, lo que permitió incorporar la dependencia espacial entre provincias. Gracias a ello, se representaron los resultados en mapas de riesgo relativo (RR) por provincia, mostrando patrones espaciales claros: provincias del sur y del Mediterráneo presentaron un riesgo relativo mayor durante olas de calor, mientras que las provincias del norte y del oeste mostraron valores menores.

Los resultados demuestran que los modelos DLNM son herramientas potentes para estudiar efectos temporales diferidos de la temperatura sobre la mortalidad. Sin embargo, su aplicabilidad depende en gran medida de la cantidad y calidad de los datos disponibles. A nivel nacional, la gran cantidad de observaciones permitió seleccionar modelos más complejos y obtener gráficos claros, mientras que en Sevilla, con menos datos, los modelos más sencillos fueron los más adecuados, generando representaciones gráficas que explicaban particularmente el comportamiento de la mortalidad frente al clima en la región.

El estudio mostró que los efectos de temperaturas extremas varían según el tipo de exposición: el exceso de mortalidad por calor se manifiesta en los primeros cinco días tras la exposición, mientras que los efectos del frío tardan más en aparecer, entre 7 y 15 días. Las temperaturas umbral identificadas para un riesgo significativo de fallecimiento se situaron en 5 y 35°C, considerándose seguras las temperaturas intermedias. Además, el análisis por edad confirmó que los grupos mayores de 85 años presentan mayor riesgo.

El uso del modelo SB-DLNM permitió explorar la componente espacial de la mortalidad, aunque la complejidad computacional obligó a reducir el número de datos, pudiendo estudiar únicamente los dos últimos años, y no la totalidad de las observaciones disponibles. A pesar de ello, el número de grados de libertad de los modelos se pudo mantener igual, dando lugar a buenos modelos. Se pudo visualizar la estructura espacial del riesgo, con patrones coherentes con las condiciones climáticas de cada región.

En definitiva, este trabajo demuestra que es posible extraer información relevante sobre los efectos de la temperatura sobre la mortalidad, identificar los periodos críticos de exposición y

los grupos más vulnerables. La incorporación de la dependencia espacial y el uso de metodologías recientes constituyen una base sólida que podrá ser ampliada y perfeccionada en futuros estudios, incorporando más variables explicativas y mayores volúmenes de datos para mejorar la precisión y la interpretación de los resultados.

Apéndice A

Material Suplementario

El código de R empleado durante el trabajo para obtener todos los resultados se encuentra en el repositorio de GitHub: https://github.com/AlonsoPueyo/TFM_Alonso_Pueyo

A.1. Estaciones meteorológicas por provincia

En esta sección se incluirán los nombres de las estaciones meteorológicas a partir de las cuales se obtuvieron los datos de las temperaturas de cada provincia.

- | | | |
|----------------------------------|--|--------------------------------------|
| ■ A Coruña Aeropuerto | ■ Córdoba Aeropuerto | ■ Málaga Aeropuerto |
| ■ Albacete | ■ Cuenca | ■ Melilla |
| ■ Alicante-Elche Aero-
puerto | ■ Donostia/San Sebastián
Aeropuerto | ■ Murcia Aeropuerto |
| ■ Almería Aeropuerto | ■ Girona Aeropuerto | ■ Ourense |
| ■ Asturias Aeropuerto | ■ Gran Canaria Aeropuer-
to | ■ Palencia |
| ■ Ávila | ■ Granada Aeropuerto | ■ Palma de Mallorca, Ae-
ropuerto |
| ■ Badajoz Aeropuerto | ■ Guadalajara | ■ Pamplona, Aeropuerto |
| ■ Barcelona Aeropuerto | ■ Huelva, Ronda Este | ■ Pontevedra |
| ■ Bilbao Aeropuerto | ■ Huesca, Aeropuerto | ■ Reus Aeropuerto |
| ■ Burgos Aeropuerto | ■ Jaén | ■ Salamanca Aeropuerto |
| ■ Cáceres | ■ León Aeropuerto | ■ Santander Aeropuerto |
| ■ Cádiz | ■ Lleida | ■ Segovia |
| ■ Castelló-Almassora | ■ Logroño, Aeropuerto | ■ Sevilla Aeropuerto |
| ■ Ceuta | ■ Lugo Aeropuerto | ■ Soria |
| ■ Ciudad Real | ■ Madrid Aeropuerto | ■ Sta. Cruz de Tenerife |

- Teruel
- Valladolid Aeropuerto
- Zamora
- Toledo
- Vitoria-Gasteiz Aero-
puerto
- Zaragoza, Aeropuerto
- Valencia Aeropuerto

A.2. Datos poblacionales de España

A continuación incluiremos los datos proporcionados por el INE de la población total en España durante los años 2023 y 2024. Los datos son trimestrales.

Fecha (2023)	Población	Fecha (2024)	Población
01/01/2023	48085361	01/01/2024	48619695
01/04/2023	48205962	01/04/2024	48723394
01/07/2023	48320520	01/07/2024	48807474
01/10/2023	48486865	01/10/2024	48966300

Tabla A.1: Datos poblacionales de España en 2023 y 2024.

A.3. Datos poblacionales de Sevilla

En esta sección se incluyen los datos trimestrales del INE de la población en Sevilla durante los años 2023 y 2024.

Fecha (2023)	Población	Fecha (2024)	Población
01/01/2023	1959394	01/01/2024	1968624
01/04/2023	1960628	01/04/2024	1970354
01/07/2023	1963007	01/07/2024	1970469
01/10/2023	1966439	01/10/2024	1973366

Tabla A.2: Datos poblacionales de Sevilla en 2023 y 2024.

A.4. Elección de los modelos DLNM para el análisis estatal

En esta sección se muestra cómo y por qué se eligieron los modelos que finalmente se usaron para la predicción en el análisis del exceso de mortalidad atribuible a la temperatura en España. Se procedió a hacer dos análisis de sensibilidad y estudiar los valores del QAIC. Estos valores son visibles en las Tablas A.3 y A.4.

df (Temperatura)	df (Retardo)	QAIC (ns)	QAIC (bs)	QAIC (ns, bs)	QAIC (bs, ns)
3	3	6266784			6266232
3	4	6265142	6262943	6263567	6264542
3	5	6250039	6247410	6248007	6249456
3	6	6247510	6244791	6245458	6246873
3	7	6245865	6244036	6244706	6245207
4	3	6262117			6260557
4	4	6260089	6256659	6258289	6258470
4	5	6244776	6240911	6242598	6243090
4	6	6241805	6237762	6239409	6240126
4	7	6240052	6236973	6238618	6238375
5	3	6261436			6260149
5	4	6259441	6256280	6257622	6258090
5	5	6244139	6240562	6241954	6242737
5	6	6241143	6237451	6238728	6239817
5	7	6239423	6236691	6237980	6238099
6	3	6260231			6259690
6	4	6258282	6255824	6256457	6257645
6	5	6242935	6240141	6240754	6242328
6	6	6240001	6237006	6237580	6239413
6	7	6238281	6236249	6236844	6237670
7	3	6259867			6259477
7	4	6257888	6255540	6256026	6257402
7	5	6242582	6239908	6240374	6242118
7	6	6239545	6236634	6237118	6239064
7	7	6237841	6235936	6236420	6237350

Tabla A.3: Valores del QAIC de los distintos modelos con los datos del año 2023.

df (Temperatura)	df (Retardo)	QAIC (ns)	QAIC (bs)	QAIC (ns, bs)	QAIC (bs, ns)
3	3	6237023			6237561
3	4	6235627	6234991	6234371	6236235
3	5	6225181	6224228	6223601	6225799
3	6	6223131	6222106	6221485	6223727
3	7	6221835	6221468	6220851	6222437
4	3	6236540			6237252
4	4	6235061	6234538	6233728	6235852
4	5	6224612	6223753	6222971	6225387
4	6	6222362	6221378	6220593	6223133
4	7	6221050	6220751	6219968	6221823
5	3	6236667			6236152
5	4	6235230	6233375	6233914	6234699
5	5	6224809	6222632	6223193	6224248
5	6	6222658	6220370	6220910	6222122
5	7	6221348	6219719	6220259	6220821
6	3	6236206			6235906
6	4	6234786	6233166	6233464	6234496
6	5	6224418	6222467	6222798	6224089
6	6	6222339	6220230	6220585	6221990
6	7	6221023	6219612	6219931	6220720
7	3	6235231			6235304
7	4	6233795	6232607	6232463	6233937
7	5	6223463	6221949	6221839	6223571
7	6	6221422	6219718	6219660	6221492
7	7	6220156	6219140	6219049	6220250

Tabla A.4: Valores del QAIC de los distintos modelos con los datos del año 2024.

Comparando ambas tablas notamos algunas consideraciones a destacar. En primer lugar, los modelos hechos con los datos del año 2024 presentan unos valores del QAIC más bajos. Esto es debido a la diferencia de observaciones entre los dos conjuntos de datos. Recordemos que hay 4000 filas más en el año 2023. Esto ocurre porque el término de la log-verosimilitud crece con el número de observaciones. En segundo lugar, notamos en ambas tablas que los modelos con un menor valor del QAIC son aquellos que son más complejos, con un mayor número de grados de libertad para ambas dimensiones. Esto no necesariamente significa que sean mejores, sino que son los más flexibles en términos de ajuste. De hecho, esos modelos con tantos grados de libertad sobreajustan los datos.

Se procederá a la selección de un modelo más parsimonioso, con menos grados de libertad y menor sobreajuste. Basándonos en los valores de las tablas, se buscaba un modelo con un número no demasiado grande de grados de libertad, y que además tuviera un valor del QAIC que no fuera demasiado alto ni bajo. Finalmente se optó por el modelo que incluye B-splines con 4 grados de libertad tanto para la dimensión de la temperatura como para la de los retardos.

A.5. Análisis por subgrupos de edad

En esta sección se van a incluir los gráficos y resultados del análisis de la mortalidad atribuible al exceso de temperatura por subgrupos de población según la edad. Recordemos que se emplearon los datos de los años 2023 y 2024, y que el análisis del grupo conformado por las personas de más de 85 años está incluido en el documento. En las siguientes Figuras (desde A.1 hasta A.5) se muestran los resultados gráficos.




Figura A.1: Representaciones gráficas del modelo que estudia el grupo de 0-14 años.




Figura A.2: Representaciones gráficas del modelo que estudia el grupo de 15-44 años.




Figura A.3: Representaciones gráficas del modelo que estudia el grupo de 45-64 años.




Figura A.4: Representaciones gráficas del modelo que estudia el grupo de 65-74 años.




Figura A.5: Representaciones gráficas del modelo que estudia el grupo de 75-84 años.

A.6. Elección de los modelos DLNM para el análisis de Sevilla

Análogamente a una de las secciones anteriores, aquí se incluyen los análisis de sensibilidad que fueron utilizados para elegir el modelo que se utilizó en el análisis del exceso de la mortalidad atribuible a la temperatura en la región de Sevilla. Se calcula el valor del QAIC para cada modelo y se comparan los resultados obtenidos en las Tablas A.5 y A.6. A partir de este valor se elige el modelo más pertinente.

df (Temperatura)	df (Retardo)	QAIC (ns)	QAIC (bs)	QAIC (ns, bs)	QAIC (bs, ns)
3	3	141234.1			141230.8
3	4	141299.6	141299.6	141303.2	141297.8
3	5	141269.8	141252.3	141269.6	141245.5
3	6	141338.5	141330.1	141341.1	141318.8
3	7	141415.9	141382.4	141410.0	141381.6
4	3	141267.5			141241.7
4	4	141317.6	141302.0	141302.4	141313.4
4	5	141310.0	141280.2	141298.1	141282.3
4	6	141350.7	141326.1	141331.7	141336.5
4	7	141440.3	141396.4	141415.4	141418.9
5	3	141336.6			141317.3
5	4	141426.3	141412.1	141416.1	141419.5
5	5	141441.5	141414.2	141427.3	141414.7
5	6	141519.6	141496.3	141499.0	141504.7
5	7	141557.9	141570.6	141582.3	141572.4
6	3	141407.4			141387.6
6	4	141497.2	141474.0	141475.1	141487.9
6	5	141487.1	141436.8	141479.1	141446.2
6	6	141565.1	141531.4	141546.5	141545.6
6	7	141634.4	141640.8	141646.3	141653.6
7	3	141429.1			141451.3
7	4	141526.2	141582.5	141511.5	141591.2
7	5	141449.7	141532.7	141427.4	141551.5
7	6	141547.1	141654.9	141520.6	141675.2
7	7	141630.3	141787.8	141647.3	141761.3

Tabla A.5: Valores del QAIC de los distintos modelos con los datos de Sevilla del año 2023.

df (Temperatura)	df (Retardo)	QAIC (ns)	QAIC (bs)	QAIC (ns, bs)	QAIC (bs, ns)
3	3	140612.2			140604.9
3	4	140681.3	140667.8	140674.0	140672.2
3	5	140733.3	140731.9	140736.8	140727.0
3	6	140761.1	140750.5	140752.7	140740.4
3	7	140796.3	140800.5	140786.4	1400777.5
4	3	140674.2			140683.8
4	4	140765.6	140773.5	140760.3	140777.1
4	5	140844.6	140851.4	140847.6	140850.6
4	6	140894.0	140893.9	140884.9	140889.8
4	7	140950.7	140962.9	140941.1	140947.2
5	3	140751.6			140764.3
5	4	140847.3	140869.2	140845.9	140874.8
5	5	140955.1	140963.5	140959.2	140964.8
5	6	141014.0	141033.3	141020.2	141031.7
5	7	141101.8	141115.3	141111.1	141119.4
6	3	140806.4			140809.4
6	4	140932.1	140943.8	140929.5	140949.4
6	5	141060.7	141060.9	141063.6	141060.0
6	6	141158.8	141155.2	141157.3	141156.0
6	7	141268.4	141259.6	141269.6	141271.0
7	3	140889.7			140887.7
7	4	141047.2	141036.7	141045.6	141037.7
7	5	141149.8	141177.3	141145.7	141171.0
7	6	141240.1	141280.6	141238.1	141285.9
7	7	141371.4	141402.9	141380.9	141427.5

Tabla A.6: Valores del QAIC de los distintos modelos con los datos de Sevilla del año 2024.

Fijándonos en los resultados de las tablas, el mejor modelo tanto para los datos del año 2023 como para los del 2024, es el que emplea un B-spline con 3 grados de libertad para la dimensión de la temperatura, y un spline natural, también con 3 grados de libertad, para el retardo. Posee un valor del QAIC de 141230.8 para el año 2023 y de 140604.9 para el 2024.

Bibliografía

- Achebak, H., Devolder, D., and Ballester, J. (2018). Heat-related mortality trends under recent climate warming in spain: A 36-year observational study. *PLoS medicine*, 15(7):e1002617.
- Gasparrini, A. (2011). Distributed lag linear and non-linear models in r: the package dlnm. *Journal of statistical software*, 43:1–20.
- Gasparrini, A. and Armstrong, B. (2013). Distributed lag non-linear models in r: the package dlnm. *London School of Hygiene and Tropical Medicine, UK. dlnm version*, 1(7):05–16.
- Gasparrini, A., Armstrong, B., and Gasparrini, M. A. (2013). Package ‘dlnm’.
- Gasparrini, A., Armstrong, B., and Kenward, M. G. (2010). Distributed lag non-linear models. *Statistics in medicine*, 29(21):2224–2234.
- Linares, C. and Díaz, J. (2008). Temperaturas extremadamente elevadas y su impacto sobre la mortalidad diaria según diferentes grupos de edad. *Gaceta Sanitaria*, 22(2):115–119.
- Quijal-Zamorano, M., Martinez-Beneito, M. A., Ballester, J., and Marí-Dell’Olmo, M. (2024). Spatial bayesian distributed lag non-linear models (sb-dlnm) for small-area exposure-lag-response epidemiological modelling. *International journal of epidemiology*, 53(3):dyae061.
- Quijal-Zamorano, M., Martinez-Beneito, M. A., Ballester, J., and Marí-Dell’Olmo, M. (2025). Spatial bayesian distributed lag non-linear models with r-inla. *International Journal of Epidemiology*, 54(4):dyaf120.
- R Core Team (2020). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria.
- Robine, J.-M., Cheung, S. L. K., Le Roy, S., Van Oyen, H., Griffiths, C., Michel, J.-P., and Herrmann, F. R. (2008). Death toll exceeded 70,000 in europe during the summer of 2003. *Comptes Rendus. Biologies*, 331(2):171–178.
- Rue, H., Martino, S., and Chopin, N. (2009). Approximate bayesian inference for latent gaussian models by using integrated nested laplace approximations. *Journal of the Royal Statistical Society Series B: Statistical Methodology*, 71(2):319–392.