

Estudio del impacto de las altas temperaturas en la mortalidad diaria en España

Máster Universitario en Modelización e
Investigación Matemática, Estadística y
Computación



Universidad
Zaragoza

Alonso Pueyo Gómez
Trabajo de Fin de Máster
Universidad de Zaragoza
Tutora: Jaione Etxeberria

27 de octubre de 2025

Resumen

El presente Trabajo Fin de Máster tiene por objeto estudiar la posible relación existente entre la mortalidad de diferentes grupos de población y la exposición a días con temperaturas extremas, tanto frías como cálidas, en España en general, y más tarde en Navarra en particular. Se pretende dar con unos límites máximos y mínimos a partir de los cuales el riesgo de fallecimiento por la temperatura aumenta considerablemente, tanto en la población en general, como en varios grupos de edad. También se va a estudiar la influencia que tienen las provincias españolas entre sí en cuestión de mortalidad atribuible a la temperatura.

Se describirán los métodos estadísticos más utilizados para modelizar el riesgo de fallecer en función de la temperatura de exposición y de los días de retardo que han pasado, y se buscará el mejor modelo que ajuste los datos. En cierto punto, para el estudio provincial, se aplicará una metodología que también estudia la componente espacial entre varias regiones.

Los métodos mencionados se aplicarán al conjunto de datos reales formado por observaciones de las defunciones notificadas en cada grupo de población de cada provincia (obtenidas de la aplicación MoMo https://momo.isciii.es/panel_momo/) y las temperaturas medias, mínimas y máximas diarias de cada sitio (conseguidas de la AEMET) desde el 1 de enero del 2015 al 31 de diciembre del año 2024.

Todo lo descrito anteriormente se realizará con el software de R. En particular, se utilizarán los paquetes *dlnm* e *INLA*.

Abstract

The purpose of this Master's Final Project is the study of the possible existing relationship between the mortality of different population groups and the exposition of days with an extreme temperature, both cold and warm, in Spain in general, and later on, in Navarra in particular. It is intended to obtain some maximum and minimum limits from which the risk of mortality by the temperature increases considerably, both in the population in general, and within some age groups. It is also going to be studied the influence that some spanish regions have between themselves in the matter of mortality attributable to temperature.

There will be described the most used statistical methods in order to model the risk of death depending on the temperature of the exposition and the lag days that have passed, and the best model that adjusts the data will be searched. At some point, for the provincial study, a methodology that also studies the spatial component between regions will be applied.

The methods mentioned above will be applied to the set of real data formed by the observations of the notified deaths in each population group of each region (obtained from the application MoMo https://momo.isciii.es/panel_momo/) and the mean, minimum and maximum daily temperatures of each place (obtained from the AEMET) from the 1st of January of 2015 until the 31st of December of 2024.

Everything that was described before will be carried out with the software R. In particular, we will be using the packages *dlnm* and *INLA*.

Índice general

Resumen	III
1. Introducción	1
2. Marco Teórico	3
2.1. Modelos Lineales Generalizados (GLM)	3
2.1.1. Regresión de Poisson	4
2.2. Modelos de retardo distribuido (DLM)	5
2.3. Modelos de retardo distribuido no lineales (DLNM)	6
2.4. Modelos DLNM bayesianos espaciales	7
2.5. Métodos de estimación de los modelos mediante el paquete <i>dlnm</i>	8
2.5.1. Métodos de inferencia y Software	9
2.5.2. Método Integrated Nested Laplace Approximations	10
3. Ilustración de los modelos DLNM con datos de mortalidad diaria y temperaturas en España	13
3.1. Fuente de datos	13
3.2. Análisis del exceso de mortalidad atribuible a la temperatura en España	14
3.2.1. Análisis descriptivo	14
3.2.2. Modelización	17
3.3. Análisis del exceso de mortalidad atribuible a la temperatura en Navarra	20
3.3.1. Análisis descriptivo	20
3.3.2. Modelización	22
3.4. Análisis del exceso de mortalidad atribuible a la temperatura por provincias . .	24
4. Conclusiones	29
A. Material Suplementario	31
A.1. Estaciones meteorológicas por provincia	31
A.2. Elección de los modelos DLNM para el análisis estatal	32
A.3. Elección de los modelos DLNM para el análisis de Navarra	34
Bibliografía	37

Capítulo 1

Introducción

El cambio climático es un problema que preocupa a la sociedad desde hace varios años. Cada vez se registran estaciones más calurosas, con olas de calor más frecuentes e intensas en verano, lo que repercute directamente en la salud de la población. Algunos grupos son especialmente vulnerables a estos efectos, como es el caso de las personas mayores. Diversos estudios epidemiológicos han evidenciado la relación entre la exposición a altas temperaturas y el aumento de la mortalidad. Por ejemplo, en el artículo de Robine et al. (2008) [16], se analiza el impacto que tuvo la ola de calor del año 2003 en 16 países europeos.

Con la creciente evidencia sobre la relación entre temperaturas extremas y mortalidad, el desarrollo de nuevas metodologías ha permitido analizar este fenómeno con mayor profundidad. En este contexto, diversos trabajos han contribuido también a la mejora de las herramientas estadísticas utilizadas en el estudio del impacto del calor sobre la salud pública. Por ejemplo, en el trabajo de Linares y Díaz (2008) [2] se abordó la relación entre temperatura y mortalidad utilizando una metodología basada en modelos ARIMA y regresión de Poisson. Posteriormente, en 2010, Gasparrini, junto a Armstrong y Kenward [3], introdujo un nuevo enfoque metodológico que se utilizará a lo largo de este trabajo, los que se conocen como modelos DLM y DLNM.

Cuando se está estudiando la relación entre un efecto y sus consecuencias, se pueden emplear los modelos DLM (Distributed Lag Models, en inglés). Resultan muy útiles cuando se está estudiando la estructura de retardo de efectos lineales. Cuando no existe tal linealidad, poseen limitaciones. Una solución consiste en relajar los supuestos y extenderlos a unos modelos más complejos, los DLNM (Distributed Lag Non-Linear Models). Por ejemplo, la relación que existe entre la exposición a una temperatura extremadamente alta y la mortalidad diaria no es lineal. El efecto que el exceso de temperatura provoca tras una exposición prolongada no tiene por qué presentarse de forma inmediata. Al contrario, los efectos suceden con cierto retardo, tardando varios días después de la exposición en aparecer. Es por ello que van a ser útiles los modelos que tienen en cuenta tanto los efectos inmediatos como los retardados de la temperatura sobre la mortalidad, como los DLNM. Lo que hacen es definir una dimensión temporal adicional a través de lo que se conoce como base cruzada, un espacio bidimensional de funciones que describe tanto la forma de la relación como la dimensión del retardo, y que determina la estructura temporal del efecto estudiado, que en el caso de este trabajo, es la mortalidad que se atribuye a la exposición a una alta temperatura.

Entre 2011 y 2013, Gasparrini y Armstrong publicaron varios artículos [4, 5] en los que detallaron la librería desarrollada en RStudio, diseñada para implementar los modelos propuestos en su trabajo anterior. Esta herramienta ha facilitado nuevas investigaciones en el campo, como la realizada por Achebak, Devolder y Ballester (2018) [1], quienes aplicaron estos modelos para

estudiar la mortalidad asociada al calor en España.

Recientemente, Quijal-Zamorano et al. (2024) [14], publicaron una metodología con la cual adaptaban los modelos DLNM a la estadística bayesiana de manera que, aparte de la relación entre la exposición, el retardo y la respuesta provocada, también se podía estudiar el efecto espacial que las regiones tienen entre sí.

En el año 2004, el Ministerio de Sanidad del Gobierno de España desarrolló el sistema de monitorización MoMo (https://momo.isciii.es/panel_momo/), que tiene el objetivo de identificar desviaciones de mortalidad diaria observada respecto a lo esperado según hechos pasados. Esta será la fuente principal de los datos. Este sistema calcula la predicción de excesos de mortalidad atribuibles a la temperatura mediante un modelo aditivo generalizado (GAM) de Poisson. Las variables empleadas para ajustarlo son:

- Un spline cúbico por provincia para modelar la tendencia.
- Un spline cíclico por provincia para la estacionalidad anual de la mortalidad.
- El ATO con efecto aleatorizado entre las provincias, mediante modelos mixtos.
- El F-ATO con efecto aleatorizado entre las provincias, mediante modelos mixtos.
- La tasa de defunción se ajusta como 'offset'.

El ATO (Accumulated Thermal Overcharge) es una variable sintética que mide el efecto del exceso de temperatura máxima. Cada provincia posee una temperatura máxima crítica a partir de la que se observa una mayor mortalidad. La formulación que emplea MoMo es la siguiente:

$$ATO_d = \sqrt{\sum_{i=1}^7 ATO_{d-i} \cdot 0,8^{(i-1)}}$$

Análogamente, el F-ATO (Accumulated Thermal Overcharge for cold) es una variable sintética que mide el efecto del exceso de temperatura mínima. Se construye como el ATO pero tomando temperaturas mínimas.

El objetivo principal de este trabajo es analizar la mortalidad atribuible al calor extremo en diferentes grupos de edad y regiones de España, con el fin de identificar qué poblaciones presentan una mayor vulnerabilidad.

El TFM se organiza de la siguiente manera: en la sección 2 se presenta el marco teórico y la descripción de los modelos utilizados, así como la librería empleada. Las secciones 3 y 4 describen los datos y el análisis exploratorio realizado, así como la exposición de los resultados obtenidos a partir de la aplicación de los modelos y sus correspondientes predicciones. Finalmente, en la sección 5 se discuten las principales conclusiones y líneas futuras de investigación.

Capítulo 2

Marco Teórico

Este capítulo presenta el marco metodológico que sustenta el análisis desarrollado en este trabajo. Comienza con una revisión de los modelos lineales generalizados (GLM), para luego avanzar hacia los modelos de retardo distribuido (DLM) y los modelos de retardo distribuido no lineales (DLNM), los cuales constituyen la base fundamental del estudio. Dado que la exposición a temperaturas extremas no suele generar efectos inmediatos, sino que pueden manifestarse con varios días de retraso, los modelos de retardo distribuido resultan esenciales para capturar esta dinámica temporal. Estos modelos permiten distribuir el efecto de una exposición a lo largo de múltiples días, proporcionando un análisis más preciso de los impactos retardados. Finalmente, se describen modelos DLNM bayesianos espaciales, que incorporan la dimensión espacial para un análisis más profundo cuando el interés reside en estudiar el retardo de la temperatura a nivel de áreas geográficas.

2.1. Modelos Lineales Generalizados (GLM)

En esta sección se revisan los fundamentos de los modelos lineales generalizados (GLM), con especial énfasis en el caso de la regresión de Poisson, dado que este tipo de modelos serán el punto de partida para la modelización. Se comenzará por exponer los modelos lineales generalizados, como base conceptual, para posteriormente avanzar hacia la construcción y desarrollo de los modelos de retardo distribuido (DLM), que constituyen el objetivo principal de este estudio.

Los modelos lineales generalizados (GLM) son una extensión de los modelos de regresión lineal clásicos que permiten estudiar aquellos modelos cuyas variables explicadas no siguen una distribución normal. Los tipos más comunes son los siguientes:

- Regresión Logística: Las variables son binarias, solo toman el éxito o el fracaso como valores.
- Regresión Multinomial y Ordinal: Extensiones de la anterior cuando se tienen variables con más de dos niveles, ya sean ordenados o desordenados.
- Regresión de Poisson: Se utiliza cuando los datos son conteos. En la siguiente subsección nos centraremos y definiremos más en profundidad estos últimos.

2.1.1. Regresión de Poisson

De forma general, el modelo de regresión de Poisson es un caso específico dentro de los modelos lineales generalizados (GLM), empleado cuando la variable de interés Y representa un recuento, es decir, toma valores enteros no negativos (incluido el cero), y se asume que dicha variable sigue una distribución de Poisson. Este tipo de modelo es especialmente útil para analizar datos discretos que reflejan el número de ocurrencias de un evento en un intervalo de tiempo o espacio determinado.

Así, la función de probabilidad de la distribución de Poisson se define como:

$$P(Y = y) = \frac{e^{-\mu} \cdot \mu^y}{y!}, \quad y = 0, 1, 2, \dots \quad (2.1)$$

donde $\mu = E(Y) = Var(Y)$ es la media y la varianza del del número de casos observados.

Cuando se dispone de un conjunto de covariables X_{ji} que buscan explicar el comportamiento de la variable respuesta Y_i , estas se relacionan con el valor esperado $\mu_i = E(Y_i)$ mediante una función de enlace logarítmica, la cual asegura que las predicciones del número esperado de muertes sean positivas, y por tanto da lugar al siguiente modelo lineal:

$$\log(\mu_i) = \beta_0 + \beta_1 X_{1i} + \dots + \beta_p X_{pi} \quad (2.2)$$

Los coeficientes β_i representan el cambio relativo en el número esperado de eventos por unidad de aumento de la variable explicativa X_{ji} manteniendo constantes el resto de variables.

Supongamos que el interés radica ahora en estimar el riesgo (o tasa) r_i de mortalidad o incidencia de una enfermedad en la unidad o estrato i . Condicionado al riesgo, se asume que el número de casos observados Y_i sigue una distribución de Poisson con media $\mu_i = e_i \cdot r_i$, siendo e_i la exposición, es decir:

$$Y_i | r_i \sim \text{Poisson}(\mu_i), \quad \text{para } i = 1, \dots, n. \quad (2.3)$$

Aplicando la función de enlace logarítmica, se obtiene la siguiente expresión:

$$\log(\mu_i) = \log(e_i) + \log(r_i) \quad (2.4)$$

En esta formulación, $\log(e_i)$ actúa como offset, es decir, como un término fijo conocido que no se estima, mientras que $\log(r_i)$ puede expresarse mediante un modelo lineal en función de covariables. Por tanto, el modelo completo queda:

$$\log(\mu_i) = \log(e_i) + \beta_0 + \beta_1 X_{1i} + \dots + \beta_p X_{pi} \quad (2.5)$$

Este enfoque permite modelar tasas/razones de incidencia o mortalidad, teniendo en cuenta tanto posibles factores explicativos como la variación en la exposición entre las unidades de análisis. Además, es posible incluir términos no lineales en el modelo. Para capturar estas relaciones más complejas, comúnmente se emplean interacciones entre variables o transformaciones empleando funciones no lineales de las mismas.

En particular, a lo largo de este trabajo, nuestro interés residirá en estudiar el riesgo (riesgo relativo) de morir o enfermar. Esta medida compara el riesgo de un evento, en nuestro caso, la mortalidad asociada a temperaturas extremas, en un grupo expuesto frente a un grupo de referencia.

2.2. Modelos de retardo distribuido (DLM)

En la sección anterior se presentó el modelo de regresión de Poisson utilizado como base del análisis. A continuación, este enfoque se extiende mediante los modelos de retardo distribuido (Distributed Lag Models, DLM), que permiten incorporar el efecto retardado que una exposición puede tener sobre la variable respuesta. Este tipo de modelos son especialmente útiles cuando los efectos de una exposición no se manifiestan de forma inmediata, sino que pueden distribuirse a lo largo de varios días. Para ello, se define un vector de exposiciones pasadas en el día t como:

$$q_t = (e_t, e_{t-1}, \dots, e_{t-L})^T \quad (2.6)$$

donde e_{t-l} representa la temperatura observada l días antes (es decir, con un desfase de l días), y L es el número máximo de días de retardo considerados. Un modelo DLM simple puede expresarse de la siguiente manera:

$$\eta_t = \sum_{l=0}^L \delta_l e_{t-l} \quad (2.7)$$

donde δ_l representa el efecto de la temperatura con un retardo de l días.

Sin embargo, este enfoque puede verse afectado por problemas de colinealidad entre las variables e_{t-l} , debido a la alta correlación que suele existir entre las temperaturas de días consecutivos. Para mitigar este inconveniente, se imponen restricciones sobre los coeficientes δ_l . En este punto, conviene aclarar cómo se introducen estas restricciones sobre los coeficientes. Una estrategia habitual consiste en suponer que estos coeficientes no varían libremente con el retardo, sino que siguen una estructura funcional más suave. Para ello, se representan como combinaciones lineales de funciones, como podrían ser polinomios o splines.

De manera general, los modelos DLM se construyen sobre una base que permite representar los efectos distribuidos de la exposición a lo largo de los distintos retardos. En notación matricial, el efecto acumulado de la exposición retardada puede expresarse como:

$$s(e_t; \beta) = q_t^T C \beta \quad (2.8)$$

donde C es la matriz de variables base que se obtienen al aplicar las funciones base a los retardos, y β es el vector de parámetros que no se conocen. La estructura del modelo DLM depende de cómo se defina la matriz C . Si C es la matriz identidad, el modelo corresponde al caso sin restricciones, tal como se definió en la ecuación (2.7).

En el contexto de este trabajo, el objetivo es modelizar la relación entre la temperatura y la mortalidad diaria, teniendo en cuenta no solo los valores extremos de temperatura, sino también los efectos que estos pueden ejercer a lo largo de varios días. Para ello, se considera un enfoque bidimensional. Por un lado, se modela cómo varía el riesgo en función de los distintos niveles de exposición (temperatura), y por otro, cómo este riesgo se distribuye temporalmente tras la exposición (retardo). Estas dos dimensiones, exposición y retardo, se integran en la modelización como una base cruzada lo que permite representar de manera flexible tanto la forma de la asociación como su evolución temporal.

2.3. Modelos de retardo distribuido no lineales (DLNM)

A continuación, se presenta el modelo de retardo distribuido no lineal (DLNM). A diferencia de los modelos de retardo distribuido lineales (DLM), los DLNM permiten que la relación entre el predictor lineal y las covariables sea no lineal. Para ello, construyen un espacio bidimensional de funciones que modeliza simultáneamente la asociación no lineal entre la exposición y la respuesta, así como la distribución temporal de los efectos retardados.

Tal y como se menciona previamente, una de las principales limitaciones de los modelos DLM es que suponen una relación lineal entre la exposición y la respuesta. No obstante, en el caso de la temperatura, numerosos estudios han demostrado que su relación con la mortalidad es claramente no lineal. Para abordar esta limitación, en este trabajo se adopta la metodología propuesta por Gasparrini et al. (2010) [3], basada en los modelos de retardo distribuido no lineales (DLNM). Estos modelos permiten representar simultáneamente la forma no lineal de la asociación entre temperatura y mortalidad, así como la distribución temporal del efecto de la exposición. En un modelo DLNM, el efecto total de la temperatura sobre la mortalidad en un día t se expresa como la suma de los efectos correspondientes a las temperaturas registradas en los días anteriores, es decir:

$$\eta_t = \sum_{l=0}^L f(e_{t-l}, l) \quad (2.9)$$

donde $f(e, l)$ es una función bivalente que representa el efecto de la temperatura e con un retardo de l días. Se trata de un B-spline. Estas funciones están constituidas por fragmentos de polinomios unidos de una cierta manera. Supongamos que se tienen un conjunto de observaciones que se quieren adecuar de la mejor manera posible, sin que haya un sobreajuste de los datos. Dados dos nodos a y b , un B-spline de grado q toma valores nulos fuera del intervalo $[a, b]$ y consiste en $q + 1$ fragmentos polinómicos, cada uno de orden q . El objetivo es ajustar los datos mediante funciones suaves utilizando una cierta cantidad de nodos.

Esta función se modela como la combinación de dos funciones base, una para la temperatura y otra para el retardo. Se escribe como:

$$f(e_{t-l}, l) = B(e_{t-l})^T \cdot \beta \cdot C(l) = \sum_{i=1}^I \sum_{j=1}^J \beta_{ij} \cdot B_i(e_{t-l}) \cdot C_j(l) \quad (2.10)$$

donde:

- $B(e)^T = (B_1^T(e), \dots, B_I^T(e))$ es la matriz de tamaño $I \times 1$ que contiene las funciones base que representan la forma de la relación en el eje de la temperatura.
- $C(l)^T = (C_1^T(l), \dots, C_J^T(l))$ es la matriz de tamaño $J \times 1$ que contiene las funciones base que describen la distribución del efecto en el eje de los retardos.
- $\beta = \begin{pmatrix} \beta_{11} & \dots & \beta_{1J} \\ \vdots & \ddots & \vdots \\ \beta_{I1} & \dots & \beta_{IJ} \end{pmatrix}$ es la matriz de parámetros a estimar.

Esta formulación permite capturar de manera flexible la relación entre la exposición a temperaturas extremas y la mortalidad, incluyendo patrones de retardo complejos y respuestas no lineales.

Definiendo la matriz C como en la sección anterior, un modelo DLNM se especifica de manera general como:

$$s(e_t; \beta) = r_t^T C \beta = \sum_{i=1}^I \sum_{j=1}^J r_{ti}^T c_j \beta_{ij}, \quad (2.11)$$

donde r_t es el vector de las componentes de la temperatura transformadas según las funciones de base.

2.4. Modelos DLNM bayesianos espaciales

Los modelos DLNM pueden extenderse al caso espacial, dando lugar a los modelos SB-DLNM (Spatial Bayesian Distributed Lag Non-linear Models). Estos modelos incorporan una componente espacial que permite capturar la dependencia y la influencia mutua entre regiones geográficamente cercanas. Es razonable esperar que provincias limítrofes con características similares presenten patrones de respuesta análogos al aplicar el modelo DLNM, lo que facilita identificar áreas con efectos comunes. Este enfoque fue introducido recientemente por Quijal-Zamorano et al. (2024) [14], y será empleado específicamente para estudiar el efecto de la temperatura en la mortalidad a nivel provincial en España. En este caso, la implementación de estos modelos se realizará desde el punto de vista bayesiano, empleando INLA como método de estimación de los modelos. Esto se detallará en secciones posteriores.

En primer lugar, hay que introducir los modelos DLNM bayesianos (B-DLNM), que generalizaremos más tarde a los SB-DLNM. En ambos casos la implementación se realiza mediante el diseño de caso-cruce. Se busca controlar automáticamente las tendencias a largo plazo y estacionales, el efecto del día de la semana y otras variables que cambien lentamente a lo largo del tiempo. Para ello, se estratifican los datos según diversas variables, como el área, el año y el mes, o el día de la semana. Así, las temperaturas y el número de defunciones de un área se comparan con los del mismo área, mes, año y día de la semana. De esta manera, cada estrato se compone de varios días de caso (case-days, en inglés) que tienen en cuenta la evolución de cada área a través del tiempo.

Para los modelos independientes B-DLNM, se analiza cada área individualmente extendiendo el enfoque frecuentista empleado hasta ahora al marco bayesiano. La variable respuesta que indica el número de ocurrencias de un evento ahora es Y_{ij} , y va a depender del día i y del área j . Sigue una distribución de Poisson de media μ_{ij} , es decir:

$$Y_{ij} \sim \text{Poisson}(\mu_{ij}), \text{ para } i = 1, \dots, n, j = 1, \dots, m. \quad (2.12)$$

Al tratarse de una generalización de los DLNM, ajustamos los modelos relacionando μ_{ij} mediante una función de enlace logarítmico con la matriz correspondiente a la base cruzada. El modelo B-DLNM resultante es el siguiente:

$$\log(\mu_{ij}) = \sum_{s=1}^S \alpha_s + \sum_{k=1}^K \beta_{jk} \cdot C_{ijk} \quad (2.13)$$

donde:

- α_s es el intercepto de cada estrato s , que es el mismo entre días en el mismo área, año, mes y día de la semana.
- S es el número total de estratos que se tienen.

- K es el número de predictores de exposición-retardo expresados en sus respectivas bases.
- β_{jk} son los vectores de parámetros desconocidos, dependientes del área.
- C_{ijk} son las matrices de las bases cruzadas de cada día y área.

Generalizamos los modelos B-DLNM independientes anteriores a modelos SB-DLNM incluyendo la dependencia espacial en los coeficientes de la base cruzada, es decir, en los parámetros β_{jk} modificando su distribución previa. Ahora se emplean efectos aleatorios con estructura espacial. En particular:

$$\beta_{jk} = \mu_k + \beta_{jk}^*, \text{ con } \beta_{jk}^* \sim N \left(\frac{\rho}{1 - \rho + \rho \cdot J} \cdot \sum_{j'} \beta_{j',k}^*, \frac{\sigma_k^2}{1 - \rho + \rho \cdot J} \right) \quad (2.14)$$

donde:

- μ_k es el valor medio que describe el efecto entero en cada región.
- β_{jk}^* es el efecto aleatorio que introduce variabilidad espacial entre las áreas, y sigue una distribución normal donde tanto la media como la varianza dependen de un factor ρ que define la fuerza de la componente espacial en los modelos de Leroux, variando entre 0 y 1.
- J es el número total de áreas adyacentes que tiene una región. El índice que determina las áreas contiguas es j' .
- σ_k^2 es la varianza de los coeficientes de la base cruzada k .

Notamos que la media y la varianza de la distribución normal depende de la información de las áreas adyacentes. En particular, del número total de regiones contiguas que se posee y de los parámetros de variabilidad espacial para el mismo calor de k y área j' .

2.5. Métodos de estimación de los modelos mediante el paquete *dlnm*

En el trabajo de Gasparrini et al. (2010) [3], que mencionamos en la introducción, y donde se explica el funcionamiento de los modelos DLNM, hay un ejemplo de aplicación sobre el efecto de la temperatura en la mortalidad en la ciudad de Nueva York. En él se menciona que se elige un modelo con splines cúbicos naturales para describir la relación en cada dimensión. En particular, el spline que se emplea para definir la temperatura tiene sus nodos igualmente espaciados a lo largo del rango de valores con el fin de dar flexibilidad a los extremos, cuando las temperaturas son más extremas. Por otra parte, el spline que se elige para definir la dimensión de los retardos define sus nodos de manera que se encuentren a la misma distancia en la escala logarítmica para flexibilizar la primera parte de la curva del retardo, que se espera más variable. Además, en ese modelo mencionado se está estudiando lo que ocurre en un retardo máximo de 30 días. Por último, el número de nodos que se eligen para cada spline de cada dimensión, que a su vez definen los grados de libertad, se eligieron según los criterios de información de Akaike y bayesianos modificados.

2.5.1. Métodos de inferencia y Software

En la práctica, es necesario disponer de criterios que permitan evaluar y seleccionar los modelos que mejor se ajusten a los datos. A continuación, se describirán los métodos para el ajuste y comparación de modelos. En primer lugar, expondremos métodos clásicos, y en segundo lugar, métodos más avanzados, como el método de aproximación de Laplace anidada integrada.

Los parámetros del modelo se estiman mediante el método de máxima verosimilitud, propio de los modelos lineales generalizados. En particular, para una regresión de Poisson con función de enlace logarítmico, se maximiza la función de verosimilitud definida por la distribución de Poisson de los conteos observados.

Sea Y_t el número de defunciones en el día t , y $\mu_t = E(Y_t)$ la media condicionada a las covariables y a la exposición retardada. El modelo se expresa como:

$$\log(\mu_t) = \alpha + X_t\beta$$

donde X_t es la matriz de diseño construida a partir de las bases cruzadas y otras covariables, y β el vector de parámetros que se desean estimar. Así, la función de verosimilitud es:

$$L(\beta) = \prod_{t=1}^n \frac{e^{-\mu_t} \mu_t^{Y_t}}{Y_t!}$$

Maximizando el logaritmo de esta función se obtienen las estimaciones de β .

Cuando se han realizado varios modelos diferentes y se quiere seleccionar el que mejor se ajusta a los parámetros del problema, se calcula el valor del Criterio de Información de Akaike (AIC) o el Criterio de Información Bayesiano (BIC). Ambas son medidas estadísticas útiles para la evaluación del equilibrio entre el ajuste y la complejidad del modelo. Un valor menor indica un mejor ajuste. Se calculan como sigue:

$$AIC = -2L(\beta) + 2k$$

$$BIC = -2L(\beta) + k \cdot \log(n)$$

siendo $L(\beta)$ la función de verosimilitud anterior, k el número de parámetros del problema, y n el número de observaciones.

Cuando se presenta un modelo de Poisson sobredisperso (quasi-Poisson), donde $E(X) = \mu$ y $Var(X) = \phi\mu$, con $\phi > 1$ el parámetro de sobredispersión, se han de modificar los criterios anteriores, que ahora se calculan:

$$QAIC = -2L(\beta) + 2\phi k$$

$$QBIC = -2L(\beta) + \phi k \log(n)$$

El parámetro de sobredispersión de un modelo se obtiene como la relación entre la desviación residual y los grados de libertad.

Para implementar los modelos descritos en el trabajo utilizaremos el paquete *dlnm* (versión 2.4.10) en R, desarrollado por Gasparini et al. [4, 5, 6]. Este paquete permite construir y ajustar modelos de regresión con bases cruzadas para analizar efectos no lineales y con retardos distribuidos en series temporales, principalmente en el contexto de regresiones de Poisson para datos de conteos.

El paquete facilita la creación de bases de funciones para la variable de exposición y para los retardos, y las combina en lo que se denomina una base cruzada, que modela simultáneamente la no linealidad y el efecto retardado. Para ello, las principales funciones que se utilizan son:

- **onebasis()**: genera una base de funciones para una única dimensión (exposición o retardo). Es empleada para construir manualmente bases cruzadas o para modelos con relación lineal y efectos retardados (DLM).
- **crossbasis()**: construye la base cruzada combinando las bases de exposición y retardo, usada para ajustar modelos DLNM.
- **crosspred()**: calcula predicciones y efectos estimados a partir del modelo ajustado con la base cruzada.
- **crossreduce()**: resume el efecto bidimensional en una sola dimensión, facilitando la interpretación del efecto acumulado sobre la exposición o el retardo.

Los gráficos formados al aplicar la función **crosspred** muestran y evalúan constantemente los resultados obtenidos en función del Riesgo Relativo (RR), una medida que ya se ha introducido en el pasado. En nuestro estudio se está comparando el riesgo de la población en días con temperaturas extremas frente a días con temperaturas suaves.

En el caso de la librería *dlm*, no se calculan directamente riesgos absolutos, que es la probabilidad de fallecer debido a la temperatura de un grupo específico en un periodo de tiempo dado, sino que se estiman efectos relativos a partir de un modelo de regresión de quasipoisson. Por consiguiente, el RR se calcula como la exponencial de la diferencia entre los valores de la función de respuesta en cada temperatura y la de referencia. Dicha función respuesta se construye con la base cruzada.

Visualización. El paquete también ofrece funciones para visualizar la relación entre la exposición y los retardos mediante superficies tridimensionales, curvas de efecto acumulado o mapas de calor, entre otros, facilitando la interpretación del impacto de la exposición sobre la respuesta a lo largo del tiempo.

En resumen, el paquete *dlm* ofrece una implementación flexible y eficiente para ajustar modelos estadísticos complejos que permiten estudiar los efectos retardados y no lineales en epidemiología ambiental y otros campos relacionados.

2.5.2. Método Integrated Nested Laplace Approximations

Cuando se llegue a realizar el estudio por provincias, y se quiera visualizar la influencia de unas provincias con otras que sean vecinas, se empleará el método de las Aproximaciones de Laplace Anidadas Integradas (INLA, integrated Nested Laplace Approximations, en inglés) [12]. El método INLA permite realizar inferencia Bayesiana. Es más rápido y exacto que los métodos de Montecarlo basados en cadenas de Markov (MCMC) que se suelen emplear. Tal y como afirman Quijal-Zamorano et al. (2024, 2025) [12, 14], de esta manera se reducen significativamente los costes computacionales y el tiempo requerido al modelizar.

El método INLA es útil para los LGMs (Modelos Gaussianos Latentes), que incluyen muchos modelos que son usados típicamente, como los modelos lineales generalizados. Lo que se

hace es utilizar la aproximación de integrales de Laplace en densidades cercanas a la gaussiana con el fin de encontrar la distribución posterior marginal de cada variable del modelo. Si esto no es posible, en el caso de los LGM, se puede reformular el problema en otros subproblemas en los que sí se puede aplicar la aproximación de Laplace.

Existe una librería de R conocida como *R-INLA*. En ella se encuentra la función *inla()* que permite implementar este método.

Una de las ventajas que tiene es la capacidad de estudiar modelos con retardo y con componente espacial, es decir, los SB-DLNM que hemos explicado anteriormente. El método que emplearemos para estimar este tipo de modelos se encargará de estimar los efectos retardados en el tiempo a corto plazo provocados por exposiciones medioambientales en áreas pequeñas, teniendo en cuenta también su estructura espacial y geográfica, y cómo se afectan unos a otros.

Existen diversas formas de implementar los modelos de retardo distribuido espaciales, conocidas como diseños. Entre los más comunes se encuentran el diseño de caso-cruce, que será el utilizado en este estudio, y el diseño de series temporales.

El diseño de series temporales se basa en el uso de splines temporales para modelar tanto la tendencia a largo plazo como la estacionalidad de la serie. Esta aproximación implica la estimación de un elevado número de parámetros y coeficientes, lo que conlleva una mayor complejidad computacional y un coste computacional más elevado en comparación con otros enfoques.

Para el análisis a nivel provincial en España, se empleará el paquete *R-INLA* para ajustar un modelo SB-DLNM con un diseño de caso-cruce. Este diseño es ampliamente utilizado en estudios que evalúan el impacto diario de factores medioambientales sobre la salud humana.

Capítulo 3

Ilustración de los modelos DLNM con datos de mortalidad diaria y temperaturas en España

3.1. Fuente de datos

Para el desarrollo de este Trabajo Fin de Máster se han utilizado datos procedentes del Sistema de Monitorización de la Mortalidad Diaria (MoMo), accesible en https://momo.isciii.es/panel_momo/#section-momo. MoMo es un sistema de vigilancia implementado por la Unidad de Vigilancia de la Mortalidad Diaria del Centro Nacional de Epidemiología (CNE) del Instituto de Salud Carlos III, en el marco del Plan Nacional de Actuaciones Preventivas de los Efectos del Exceso de Temperaturas sobre la Salud (Plan Calor). Desde 2022, este sistema recopila información sobre defunciones diarias por todas las causas a partir de los registros civiles informatizados del Ministerio de Justicia, abarcando 4.128 municipios que representan aproximadamente el 93 % de la población española.

Además de los datos de mortalidad, actualizados diariamente, MoMo incluye el ámbito geográfico (provincia, comunidad autónoma o nacional), su nombre y código, el sexo y grupo de edad quinquenal de los fallecidos (con sus respectivos códigos), la fecha de defunción, el número de defunciones observadas y esperadas (estas últimas sin ajuste por temperatura) junto con sus respectivos intervalos de confianza, y el número de defunciones atribuibles al exceso o defecto de temperatura. Para el trabajo, seleccionaremos solo el ámbito provincial.

Fuentes de Información de MoMo. MoMo integra y procesa datos de diversas fuentes oficiales para generar sus estimaciones:

- Datos de Mortalidad Diaria: Obtenidos del Instituto Nacional de Estadística (INE) y, posteriormente, de los registros civiles informatizados del Ministerio de Justicia.
- Temperaturas: Proporcionadas por la Agencia Estatal de Meteorología (AEMET) a nivel provincial.
- Datos Poblacionales: Población por grupo de edad, sexo y provincia, procedentes del INE.

Los datos relativos a la temperatura se obtuvieron del portal de la AEMET (Agencia Estatal de Meteorología) conocido como AEMET OpenData (<https://opendata.aemet.es/>

centrodedescargas/inicio). Se trata de un API REST (Application Programming Interface. REpresentational State Transfer) que permite descargar de forma gratuita datos de las estaciones meteorológicas españolas. Las fechas de los datos descargados suman un total de 10 años, desde el 1 de enero del 2015 al 31 de diciembre del 2024. Por defecto, se incluyen datos de todas las estaciones meteorológicas, y para evitar tener sobrecarga de información, se eligió únicamente una estación por provincia. Los nombres de las estaciones seleccionadas se incluyen en el anexo. Una vez se tienen ambas bases de datos, se unifican en una sola según la fecha y el nombre de la provincia.

Para los análisis que se expondrán a partir de ahora, tanto estatal como provincial, se empleará una base de datos reducida, compuesta únicamente por las observaciones de los años 2023 y 2024. Existirán ciertas partes centradas en lo que ocurre durante los meses de verano e invierno de estos años. Para el análisis a nivel nacional se utilizarán todos los datos de la anterior base, sin importar la provincia procedente. Se describen las observaciones utilizadas con sus principales características, detalladas a continuación.

- La base de datos depurada consta de un total de 904464 observaciones de 21 variables distintas, siendo 454320 relativas al año 2023 y 450144 del año 2024.
- El periodo temporal que se cubre es desde el 1 de enero del 2023 hasta el 31 de diciembre del 2024, ambos incluidos.
- Las variables clave del estudio que se usarán principalmente para el análisis son:
 - *fecha_defuncion*: la fecha en la que han fallecido las personas.
 - *nombre_ambito*: muestra el nombre de la provincia a la que pertenecen los datos.
 - *nombre_sexo*: muestra si los datos son relativos a las mujeres, los hombres, o en general.
 - *cod_gedad*: indica el subgrupo de edad al que pertenecen los datos.
 - *defunciones_observadas*: cuenta el número de fallecimientos que ha habido cada día, de cada grupo de población y en cada sitio.
 - *tmed*: el valor de la temperatura media diaria.

3.2. Análisis del exceso de mortalidad atribuible a la temperatura en España

3.2.1. Análisis descriptivo

En primer lugar, se procede a un análisis descriptivo preliminar de los datos, cuya finalidad es identificar patrones estacionales clave que justifiquen la necesidad de emplear los modelos de retardo distribuido. Para este análisis descriptivo, primero se calculan los valores promedio de la temperatura media y la suma total de defunciones observadas para cada mes. Los resultados de este cálculo se presentan en las Tablas 3.1 y 3.2 y sus correspondientes representaciones gráficas se observan en la Figura 3.1.

Mes	Media temperaturas medias (2023)	Media temperaturas medias (2024)
Enero	8.33	10.29
Febrero	8.71	11.61
Marzo	13.43	12.49
Abril	16.16	14.85
Mayo	17.82	17.32
Junio	22.50	21.23
Julio	25.27	25.14
Agosto	25.68	25.79
Septiembre	21.87	20.28
Octubre	19.16	17.62
Noviembre	13.69	14.35
Diciembre	9.53	9.59

Tabla 3.1: Media de las temperaturas medias por mes en 2023 y 2024 en toda España.

Mes	Suma defunciones diarias (2023)	Suma defunciones diarias (2024)
Enero	43929	48835
Febrero	39806	35854
Marzo	40061	38036
Abril	34814	35045
Mayo	33871	35109
Junio	32629	33059
Julio	33664	34816
Agosto	35250	34234
Septiembre	32062	30871
Octubre	34069	33879
Noviembre	35059	33839
Diciembre	40828	39060

Tabla 3.2: Suma de las defunciones observadas por mes en 2023 y 2024 en toda España.




Figura 3.1: Gráficos que muestran las medias de las temperaturas medias y la suma de las defunciones observadas por mes en 2023 y 2024 en toda España.

El análisis de estos elementos revela un patrón estacional marcado ambos años: la suma de las defunciones observadas presenta una tendencia inversa al promedio de las temperaturas medias, mostrando una mayor tasa de mortalidad durante los meses más fríos y un descenso en los meses cálidos. No obstante, es fundamental reconocer que no la totalidad de los fallecimientos en invierno son directamente atribuibles a la temperatura. La alta mortalidad invernal es multifactorial, estando provocada en gran parte por enfermedades estacionales como la gripe y otras patologías respiratorias comunes en esa época del año. Sin embargo, el interés específico de este estudio es estudiar la mortalidad atribuible al exceso de temperatura durante los meses de verano.

Para continuar con el análisis descriptivo, se estudia y compara el número de fallecimientos según el rango de temperatura. Cabe resaltar que el interés reside en los días con temperaturas extremas, que son menos comunes que el resto. Los resultados se observan en la Tabla 3.3, y muestran que se registraron más fallecimientos los días del 2024 que tuvieron temperaturas extremas.

Rango de temperaturas	2023	2024
Menor de 10°C	79458	58688
Entre 10°C y 20°C	195384	230272
Entre 20°C y 30°C	151944	136765
Más de 30°C	9257	6913

Tabla 3.3: Número total de defunciones por año según los distintos valores de las temperaturas medias diarias.

A continuación se seleccionan los meses de verano (julio y agosto) y los de invierno (enero y febrero) del 2023 y el 2024, y se estudia el valor del promedio de las temperaturas medias y la suma de las defunciones observadas por provincias en estos periodos. Se seleccionan solo ciertas provincias. Los resultados se encuentran en las Tablas 3.4 y 3.5.

	Verano 2023	Verano 2024	Invierno 2023	Invierno 2024
Asturias	19.80	19.48	9.00	11.44
Barcelona	26.30	25.97	9.52	12.01
Madrid	27.57	27.82	6.23	8.61
Navarra	23.11	22.95	4.81	7.19
Sevilla	29.62	28.82	11.21	12.89
Zaragoza	27.12	27.47	7.10	9.30

Tabla 3.4: Medias de las temperaturas medias diarias en algunas provincias de España durante los veranos (julio y agosto) y los inviernos (enero y febrero) de los años 2023 y 2024.

	Verano 2023	Verano 2024	Invierno 2023	Invierno 2024
Asturias	2005	2142	2466	2602
Barcelona	7696	7815	9515	9699
Madrid	7150	7675	9102	9389
Navarra	908	960	1071	1213
Sevilla	2546	2457	3364	3275
Zaragoza	1675	1710	2010	2125

Tabla 3.5: Suma de las defunciones diarias notificadas en algunas provincias de España durante los veranos (julio y agosto) y los inviernos (enero y febrero) de los años 2023 y 2024.

Se han seleccionado provincias cálidas y frías para comparar. No se visualiza una diferencia significativa entre las temperaturas de los meses de verano. El invierno del año 2024 muestra temperaturas más altas que el año anterior. La diferencia entre las temperaturas de Asturias y de Sevilla implica que España está compuesta por regiones con climas distintos. A la hora de hacer un estudio a nivel estatal hay que tener en cuenta que se mezcla información de muchos lugares con distintos climas en un solo modelo.

Como ya se ha confirmado previamente, en todas las provincias se registran más muertes en invierno que en verano, y muchas se encuentran relacionadas con las enfermedades relativas a la época del año. Se observa también que hay más fallecimientos en estas regiones en 2024 que en 2023.

Para finalizar este análisis descriptivo se van a calcular las tasas de mortalidad por cada 100000 habitantes para las provincias seleccionadas previamente y para los mismos periodos de tiempo. El resultado se visualiza en la Tabla 3.6.

	Verano 2023	Verano 2024	Invierno 2023	Invierno 2024
Asturias	198.59	212.21	244.22	257.74
Barcelona	130.94	132.96	161.88	165.02
Madrid	102.01	109.50	129.86	133.95
Navarra	133.83	141.49	157.85	178.86
Sevilla	129.32	124.83	170.87	166.38
Zaragoza	169.55	173.08	203.49	215.16

Tabla 3.6: Tasas de mortalidad por cada 100000 habitantes en las diferentes provincias seleccionadas y en las épocas de verano e invierno de los años 2023 y 2024.

La provincia con las mayores tasas de mortalidad es Asturias y las menores las posee Madrid. La diferencia de las tasas relativas a la misma época del año entre 2023 y 2024 es bastante variable. Este análisis motiva el estudio que desea conocer por qué unas provincias tienen una tasa mayor que otras.

3.2.2. Modelización

A continuación vamos a realizar la modelización. Se tomarán los datos pertenecientes a los años 2023 y 2024, por separado. Lo primero que se va a hacer van a ser dos análisis de sensibilidad entre distintos tipos de modelos, estudiando los valores del QAIC, con el fin de encontrar aquel que se adapte de una mejor manera a las observaciones disponibles, sin llegar

a un sobreajuste. El primer análisis se corresponderá con la información del año 2023, y el segundo con la del 2024, de manera que se puede realizar una comparación entre ambos, y así observar sus diferencias. En los dos análisis se compararán los modelos DLNM cuyas bases cruzadas toman 30 días de retardo máximo, y modelan la dimensión de la temperatura y la de los retardos alternando splines naturales y B-splines con distintos grados de libertad, entre 3 y 7. Las variables que se toman para explicar las defunciones observadas son la base cruzada, el día de la semana y un spline natural de la fecha de defunción con 7 grados de libertad por año estudiado. Los resultados de estos análisis se encuentran en el Anexo.

Finalmente se decidió utilizar el modelo que incluye B-splines con 4 grados de libertad tanto para la dimensión de la temperatura como para la de los retardos. Se realiza el mencionado modelo por separado para ambos años y se muestran los gráficos tridimensionales y de efecto acumulado en cada caso, visualizables en las Figuras 3.2 y 3.3.




Figura 3.2: Gráficos del modelo que incluye B-splines con 4 grados de libertad con los datos del año 2023.




Figura 3.3: Gráficos del modelo que incluye B-splines con 4 grados de libertad con los datos del año 2024.

Los gráficos realizados con los datos del año 2024 son más suaves. Este ajuste aparentemente mejor para un conjunto de datos que para el otro sugiere una diferencia entre las observaciones de ambos años. En este caso, los registros indican que en el 2023 se sufrieron 4 olas de calor y 2 de frío, mientras que el año siguiente no hubo ninguna ola de frío significativa, pero sí que se experimentaron 3 olas de calor. Durante el 2023 se llegaron a unas temperaturas más extremas que provocan una peor aproximación del modelo.

Se observa también un mal ajuste en las esquinas, donde se llega a valores del RR muy cercanos al 0. Los splines resultan útiles para modelar curvas suaves pero se ajustan de peor manera a los valores extremos de las variables. Por otro lado, cuando las temperaturas son frías, el mayor valor del RR se alcanza tras un retardo de 5 días. Bajo temperaturas cálidas, el máximo se dibuja durante los primeros días de retardo. Los gráficos de efecto acumulado muestran que el mayor valor del RR se obtiene cuando la temperatura es de 10°C. A partir de los 30°C el riesgo aumenta considerablemente.

En resumen, teniendo en cuenta las limitaciones que posee el modelo en los extremos y de las diferencias de temperatura que hubo entre los dos años, se puede concluir que los síntomas de una exposición al frío no se manifiestan de forma inmediata, sino que aparecen unos 5 días después. Al contrario ocurre con la exposición al calor, cuyos efectos aparecen poco tiempo después. Además, también es señalable que las temperaturas a partir de las cuales aumenta considerablemente el riesgo y bajo las que hay que tener precaución son los 10 y los 30°C.

Mes	Media temperaturas medias (2023)	Media temperaturas medias (2024)
Enero	4.47	6.03
Febrero	5.17	8.43
Marzo	10.71	10.08
Abril	12.87	12.01
Mayo	15.06	14.42
Junio	20.74	19.11
Julio	22.41	22.80
Agosto	23.83	23.11
Septiembre	20.58	16.70
Octubre	17.19	14.85
Noviembre	11.10	10.78
Diciembre	6.68	6.10

Tabla 3.7: Media de las temperaturas medias por mes en 2023 y 2024 en la región de Navarra.

3.3. Análisis del exceso de mortalidad atribuible a la temperatura en Navarra

3.3.1. Análisis descriptivo

En esta sección se va a realizar un análisis similar al de la sección anterior, pero centrado en la provincia de Navarra. Se seleccionarán los datos de MoMo de los años 2023 y 2024 pertenecientes a la región de Navarra. Se procederá de manera semejante al análisis que se hizo de toda España. En primer lugar, un análisis descriptivo para conocer los datos de los que se disponen y llegar a una motivación para el trabajo. Después, se buscará el modelo que mejor se aproxime y se estudiarán sus predicciones.

Los datos de MoMo referentes a la provincia de Navarra constan de un total de 59616 observaciones. En particular, del año 2023 hay 8616, y del 2024 existen 8784. Notamos que ya no se disponen de datos variados de distintas regiones de España, tanto cálidas como frías. El número de datos también se ha reducido significativamente. No se dispone de las observaciones de las temperaturas y defunciones por municipios de Navarra, sino que solo se posee la información de la estación meteorológica de Pamplona Aeropuerto para toda la provincia.

Se procederá a continuación con el análisis descriptivo. El principal objetivo es conocer los datos y encontrar las primeras relaciones que pueden existir entre las defunciones observadas en Navarra y las excesivas temperaturas. En primer lugar, se calcula el promedio de las temperaturas medias y la suma de las muertes observadas por mes en los años 2023 y 2024. Los resultados se encuentran en las Tablas 3.7 y 3.8. En la Figura 3.4 se ha dibujado la información de las tablas de manera gráfica.

Se observa que el invierno del 2023 fue más frío que en 2024. Los veranos en Navarra fueron similares. Las temperaturas de esta provincia son más extremas que la media de España. Muchos de los días más calurosos no superan los 30°C de temperatura media, y en invierno se llega a estar por debajo de los 5°C. Este clima más frío y extremo tiene influencia en la mortalidad atribuible a la temperatura.

Al igual que ocurre de forma general en España, la suma total de las defunciones observadas durante los meses fríos es superior a la de los cálidos. El valor más alto se alcanza en enero del

Mes	Suma defunciones diarias (2023)	Suma defunciones diarias (2024)
Enero	557	691
Febrero	514	522
Marzo	533	519
Abril	479	498
Mayo	468	521
Junio	433	476
Julio	441	472
Agosto	467	487
Septiembre	422	423
Octubre	445	511
Noviembre	452	446
Diciembre	573	548

Tabla 3.8: Suma total de las defunciones observadas diarias por mes en 2023 y 2024 en la región de Navarra.




Figura 3.4: Gráficos que muestran las medias de las temperaturas medias y la suma de las defunciones observadas por mes en 2023 y 2024 en Navarra.

2024. Las temperaturas de esta región son más suavizadas que las del país en general, y los veranos no registran temperaturas tan altas, pero sí temperaturas muy bajas. De aquí se explica la diferencia que existe entre el número de defunciones de una época del año y otra.

A continuación se estudiará la suma total de muertes observadas cada año en función del rango de la temperatura. Se realizará la misma división de la temperatura que se hizo en el apartado del análisis de España. Sin embargo, se observan notables diferencias debido a los veranos más suaves que se viven en Navarra. Los resultados son visibles en la Tabla 3.9.

Rango de temperaturas	2023	2024
Menor de 10°C	1911	2241
Entre 10°C y 20°C	2419	2895
Entre 20°C y 30°C	1413	979
Más de 30°C	41	0

Tabla 3.9: Número total de defunciones por año según los distintos valores de las temperaturas medias diarias en Navarra.

La suma de las defunciones de los días del 2024 que superaron los 30°C es 0 porque no hubo ningún día cuya temperatura media superara esa cifra. En 2023 se registraron 2 días que satisfacían lo anterior. Los mayores números de la tabla se alcanzan bajo los días cuya temperatura media se situó entre los 10°C y los 20°C. De estos datos se concluye que en Navarra la mayor parte de las defunciones ocurren cuando las temperaturas son frías.

Para terminar con este análisis descriptivo, se procede a la realización de una tabla con información acerca de lo que ocurrió en Navarra durante los meses más fríos y más cálidos del año. El resumen se encuentra en la Tabla 3.10. De él se deduce lo que se ha comentado anteriormente.

	Verano 2023	Verano 2024	Invierno 2023	Invierno 2024
Media temperaturas medias	23.11	22.95	4.81	7.19
Suma defunciones diarias	908	960	1071	1213
Tasa mortalidad	133.83	141.49	157.85	178.86

Tabla 3.10: Tabla descriptiva resumen de los datos de la región de Navarra en los meses de verano (julio y agosto) e invierno (enero y febrero) de los años 2023 y 2024.

3.3.2. Modelización

Procederemos a continuación con el apartado de modelización de los datos. Recordemos que el objetivo es encontrar un modelo DLNM que se ajuste correctamente a los datos disponibles, y a partir del cual realizar una predicción. De manera semejante a lo que se hacía en la modelización de todo el país, se realizan dos análisis de sensibilidad, uno para cada año que estamos estudiando, 2023 y 2024, donde se modifica la base cruzada de los modelos, alternando entre el tipo de spline utilizado para aproximar la dimensión de la temperatura y la del retardo, así como la cantidad de grados de libertad que los definen. El retardo máximo se tomará de 30 días. Los modelos se encargan de estudiar las defunciones observadas en función de la base

cruzada, el día de la semana y el spline natural de la fecha del fallecimiento con 7 grados de libertad. Los análisis de sensibilidad se pueden encontrar en los Anexos.

Finalmente se va a utilizar el modelo que emplea splines naturales con 4 grados de libertad tanto para la dimensión de la temperatura como la de los retardos para los datos de ambos años. Tras ello, se realiza su predicción. Además, se van a dibujar los gráficos tridimensionales y de efecto acumulado en cada uno de los casos. Estos resultados se encuentran en las Figuras 3.5 y 3.6.




Figura 3.5: Gráficos del modelo que incluye splines naturales con 4 grados de libertad con los datos de Navarra del año 2023.




Figura 3.6: Gráficos del modelo que incluye splines naturales con 4 grados de libertad con los datos de Navarra del año 2024.

Se observa una superficie tridimensional para los datos del año 2023 con ciertos altibajos. Para temperaturas frías, el mayor valor del RR se logra tras un retardo de 5 días. Para temperaturas cálidas, la superficie es más plana. Esto vuelve a sugerir que en la provincia de Navarra se sufre una mayor mortalidad con el frío, alrededor de los 5°C. El calor afecta únicamente cuando las temperaturas son muy extremas. Una causa es el hecho de que en esta provincia los veranos han resultado ser suaves y que los inviernos son duros.

Con respecto a los datos del año 2024, la superficie presenta menos subidas y bajadas. El RR asociado a las altas temperaturas no aumenta a lo largo de los retardos. Bajo efectos del frío, ocurre lo mismo que lo mencionado en el párrafo anterior, llegando a la misma conclusión que antes.

El gráfico de efecto acumulado del año 2023 muestra, a partir de los 30°C, un incremento muy grande del RR. Las defunciones provocadas por el defecto del calor no ocurren de forma inmediata, como sí ocurre con el calor extremo. El gráfico del 2024 no aporta información. El RR se encuentra por debajo de 1 en todo momento, y el intervalo de confianza es demasiado amplio.

Semejantemente a lo que ocurrió en el análisis estatal, no disponemos de suficientes variables que nos permitan analizar la mortalidad atribuible a la temperatura en Navarra correctamente. Se han llegado a ciertos modelos útiles, que explicaban bien el comportamiento del riesgo de fallecer en función de la temperatura y los retardos, pero presentaban sus fallos. Un ejemplo es la mala adaptación de los splines en las esquinas, cuando tanto la temperatura como el retardo es un extremo.

Sin embargo, sí que se puede concluir que, en la región de Navarra, los fallecimientos ocurren sobretodo en invierno, por el exceso de frío, cuando la temperatura ronda los 5°C. Además, no afecta de manera inmediata, sino que los efectos causados por la exposición al frío aparecen unos 5 días después.

3.4. Análisis del exceso de mortalidad atribuible a la temperatura por provincias

Mostraremos a continuación un análisis más desagregado, por provincias. Recordemos que se empleará el método R-INLA en un modelo SB-DLNM mediante el diseño de caso-cruce. En particular, para este trabajo, estratificamos los datos según la provincia, el año, el mes y el día de la semana. De esta manera, se están comparando las temperaturas y las defunciones diarias de una misma provincia con lo que ha ocurrido en el mismo día de la semana, mes y año. Cada estrato consta de varios días de control. Se excluyen aquellos estratos que no contienen ninguna muerte. Ejecutándolo de esta manera, ya se tiene en cuenta el efecto provocado por el día de la semana, que recordemos que se tuvo que incluir como variable explicativa en los modelos de la sección anterior. Como en las secciones anteriores, no se realizará el análisis al conjunto completo de los datos disponibles del 2015 al 2024, sino que esta vez se tomarán las filas correspondientes únicamente al año 2024 y se estudiará lo que ocurre provincialmente durante los meses más calurosos y más fríos del año.

Dada una provincia, se definió el conjunto de sus vecinos como aquellas otras provincias adyacentes, con las que comparte frontera. En las secciones anteriores se seleccionó como base

cruzada para el modelo la que emplea B-splines con 4 grados de libertad tanto para la dimensión de la temperatura como la del retardo. Se utilizó el método de aproximación R-INLA, considerablemente más rápido que usar WinBUGS, que era lo que se solía emplear. Se trata de un modelo bastante complejo, con muchos parámetros y que requiere un alto valor de tiempo y coste computacional. Sin embargo, este novedoso método y el hecho de reducir los datos solo a unos meses hicieron que se pudiera ejecutar de forma rápida.

En primer lugar se tomaron los meses de julio y agosto del año 2024, por una parte, y los meses de enero y febrero del mismo año, por otra. Se pretende estudiar cómo afectó el calor y el frío, respectivamente, durante ese tiempo, a la mortalidad de la población de las distintas provincias del país. Para ello, tras la ejecución de los respectivos modelos, se calcularon los valores del RR para cada combinación entre la temperatura y el retardo en cada sitio. Se centra el valor del RR y se muestran los resultados en las Figuras 3.7 y 3.8, dos mapas de España que muestran con distintos gradientes de colores la distribución espacial del RR en el percentil 99 de temperatura. Lo que se hace es comparar, dentro de cada provincia, lo que ocurre cuando la temperatura se aleja de la temperatura óptima que se tiene como referencia, que definimos como la mediana de las temperaturas en cada sitio. Así, una provincia con un color más frío indica un bajo exceso de la mortalidad atribuible a la temperatura, y al contrario ocurrirá en provincias con colores cálidos. No se incluyen las ciudades autónomas de Ceuta y Melilla.




Figura 3.7: Mapa político de España con los distintos valores del Riesgo Relativo por provincias en los meses de julio y agosto del año 2024.




Figura 3.8: Mapa político de España con los distintos valores del Riesgo Relativo por provincias en los meses de enero y febrero del año 2024.

En la leyenda del mapa de la Figura 3.7, que estudia la influencia del calor por provincias, se observa que los valores del RR oscilan entre 0.74 y 1.38. El menor valor se alcanza en Gipuzkoa, mientras que la provincia con mayor riesgo es Barcelona. Se observa también que por la parte sur y este del país existen ciertos lugares con una tonalidad azul, indicando un riesgo menor que 1, tales como Sevilla, Granada o Castellón, con un RR alrededor de 0.91. Por otra parte, el resto de provincias presentan colores rojos, luego poseen un riesgo mayor que 1. Los valores más altos se pueden encontrar en la parte norte de España, en sitios como A Coruña, Cantabria o Palencia, cuyo RR se sitúa entre el 1.12 y el 1.24.

Notar que aquellas provincias con un RR menor que 1, a excepción de Gipuzkoa, se encuentran situadas cerca del Mediterráneo, luego tienen un clima cálido a lo largo del año. Por otro lado, también se observa que las provincias con más RR están cerca del Cantábrico y tienen un clima más frío y lluvioso. Esa diferencia climática entre unos sitios y otros es lo que lleva a los distintos valores del RR y a los distintos datos de mortalidad atribuible al calor que se encuentran. En las provincias con clima cálido, más acostumbradas a los veranos intensos y a las olas de calor, un exceso de la temperatura ese año no supone un incremento notable de fallecimientos por calor. Sin embargo, la población de las provincias más frías sufre más con las olas de calor y el aumento significativo de las temperaturas, dando lugar a una mayor mortalidad atribuible al calor. Por último, el hecho de que Gipuzkoa posea un RR tan bajo o Barcelona uno tan alto es debido a que solo se toman los datos de verano del 2024. Es posible que durante ese tiempo, en Gipuzkoa, no haya habido ninguna ola de calor, o no haya afectado en gran medida. En Barcelona, al contrario, es posible que durante ese verano haya ocurrido una ola de calor extremo, notificando un mayor número de defunciones.

Observemos a continuación los resultados que hablan del invierno del 2024, presentados en la Figura 3.8. El rango de los valores del RR no es tan amplio como antes. Ahora se sitúa entre 0.84 y 1.1. El menor valor se encuentra en la provincia de Lugo y en Cádiz, y el más alto en Asturias. La parte norte de la península es la que presenta los colores más vivos, tanto azules como rojos. Lugo, Cantabria y Navarra tienen un RR que vale entre 0.84 y 0.90, aproximadamente, lo que significa que existe poco riesgo de fallecer debido a las bajas temperaturas de invierno en estos sitios. En esa misma zona, Asturias, A Coruña, Cantabria o Gipuzkoa poseen valores altos

del RR, situados por encima del 1.05. Por tanto, el riesgo de fallecer por el frío es ligeramente mayor. Otras provincias de otras partes de España también tienen valores semejantes a estos últimos, como ocurre con Madrid, Barcelona o Murcia.

En general, en todas las provincias del país no existe un riesgo demasiado excesivo de morir debido a las temperaturas frías. Hemos comprobado que los sitios que tienen un mayor RR no son demasiados, y los que lo son, presentan valores ligeramente mayores que 1. Esto significa que muchas de las defunciones que se contabilizaron y estudiaron en análisis anteriores durante los meses de invierno no fueron directamente provocadas debido a una exposición a temperaturas muy bajas, sino que son más propias de las enfermedades relacionadas con esa época del año.

Capítulo 4

Conclusiones

Antes de comenzar a hablar sobre las conclusiones del trabajo, hagamos un breve resumen de lo que se ha tratado a lo largo de este. En primer lugar se presentó y se habló de los modelos de retardo distribuido, de su método de estimación y de su aplicación en el software R. Después, se introdujo el conjunto de los datos que se iban a estudiar y se procedió a analizar el exceso de mortalidad atribuible a la temperatura a nivel estatal, en toda España en su conjunto. Se hicieron varias pruebas y análisis para llegar al modelo que parecía mejor y más adecuado.

Posteriormente, ese análisis del exceso de mortalidad se trasladó a nivel provincial. Para ello se empleó el novedoso método de aplicar el método R-INLA a un modelo SB-DLNM. Tras estratificar y preparar los datos, y ejecutar el modelo, se plasmaron los resultados en un mapa de España dividido por provincias y coloreado según el valor del riesgo relativo.

Por último, se realizó un análisis de mortalidad atribuible a la temperatura únicamente en la región de Navarra por el mismo método.

Se ha conseguido probar que los modelos no lineales de retardo distribuido son una poderosa herramienta si se quiere estudiar un resultado a lo largo del tiempo provocado por un determinado factor, y que no se produce de manera inminente. Sin embargo, también se ha podido comprobar la necesidad que existe de poseer muchos y buenos datos. Cuando se estaba realizando el estudio nacional, se disponía de una base de datos con millones de observaciones entre todas las provincias. A la hora de elegir el modelo, el QAIC tendía a premiar aquellos con un mayor número de grados de libertad. Por otra parte, en el análisis provincial de Navarra, donde se disponían de menos de 100000 datos, los modelos que parecían mejores eran aquellos más sencillos. El resultado gráfico obtenido en ambos casos variaba mucho. En el caso de España, las observaciones se veían de una manera más clara que en el caso de Navarra.

Otro aspecto a tener en cuenta y que se podría mejorar en un proyecto futuro son las variables necesarias para explicar el modelo. Vimos que en otros trabajos parecidos (Gasparrini et al. (2010) [3]) se incluyen más variables explicativas en el modelo, tales como factores medioambientales, entre otros, que son datos de los que no disponíamos en este trabajo. Esa es la causa de que la modelización realizada posea un amplio margen de mejora, y de que se hayan obtenido gráficos y superficies extraños en ciertos puntos, como por ejemplo en las esquinas, es decir, bajo temperaturas muy altas o muy bajas, o en los primeros y últimos días de retardo, donde al modelo le resulta complicado aproximar los datos. Pese a ello, se ha sido capaz de obtener un resultado. Tanto a nivel estatal como provincial, los efectos provocados por una exposición a una temperatura muy calurosa ocurren durante los 5 primeros días de retardo desde la exposición. Los efectos provocados por una temperatura muy fría tardan más en manifestarse, más o menos entre el día 7 y 15 de retardo. Las temperaturas umbrales a partir de las cuales se ha

visto que aumenta considerablemente el riesgo de fallecimiento son los 5 y los 35 grados. Un día en el que la temperatura se sitúe entre esos dos valores se considera sin riesgo.

A la hora de hacer el análisis por subgrupos de población en función de la edad, se ha visto que los hechos del párrafo anterior ocurren para cualquier persona, independientemente de la edad. Sin embargo, sí que se demostró que los grupos más mayores tienen un mayor riesgo de fallecer debido a las temperaturas. Se considera que hay que incrementar la seguridad y el cuidado a partir de los 65 años. Cuando se realizó este tipo de análisis para España en su totalidad, no hubo ningún problema al realizar la modelización y los gráficos correspondientes dada la gran cantidad de datos de cada grupo de los que se disponía, pero realizando el mismo análisis para la provincia de Navarra, no se pudo obtener nada en claro de los resultados logrados para los grupos de menor edad. Esto pasó porque no había prácticamente registros de muertes en la base de datos para estos subgrupos. Finalmente, la conclusión es que conforme se tiene más edad, más fallecimientos hay, y por tanto, más muertes atribuibles al exceso de temperatura.

Se dedicó una sección entera de la ilustración para analizar el exceso de mortalidad atribuible a la temperatura en las diferentes provincias de España. Aplicar el método R-INLA a un modelo SB-DLNM es algo que a día de hoy apenas se ha empleado. En proyectos semejantes (Quijal-Zamorano et al. (2025) [12]) se ilustra que un modelo igual, con más de 70 regiones y 12 parámetros, al que se aplicó la misma metodología tardó apenas unos minutos en ser resuelto con un ordenador muy potente. En nuestro trabajo, tras varios intentos, se trató de resolver un modelo con 50 provincias y 16 parámetros con el fin de explicar la componente espacial en su totalidad, pero finalmente no se pudo debido al alto coste de tiempo y cálculo computacional requerido. En cambio, para lograr algún resultado se simplificó el modelo reduciendo el número de grados de libertad a 2 en la dimensión de la temperatura y en la del retardo, luego obteniéndose 4 parámetros en total. En este caso tardó 27 minutos en ejecutarse completamente.

Dado que no se pudo ejecutar el modelo completo, los valores del riesgo relativo obtenidos son todos muy próximos al 1. Al colorear el mapa de España por provincias según estos números se visualizaba la estructura espacial formada. Las provincias del sur y las más próximas al mar Mediterráneo presentaban riesgos relativos altos. Por otro lado, la parte más norte y al oeste del país se veían más frías, y por ende con un menor riesgo relativo. Se comparó la provincia con el menor valor del RR obtenido, Lugo, con otra con uno de los valores del RR más grandes, Huelva. Ocurre lo mismo que con Navarra, dada la escasez de los datos y de las variables explicativas del modelo, los gráficos obtenidos eran planos y semejantes. Se concluyó que no existía una diferencia demasiado grande entre ellas, lo que está provocado por la simplicidad con la que se tuvo que hacer el modelo SB-DLNM.

Para finalizar, recalcar que en muchas partes del trabajo se ha tenido que optar por simplificar los modelos y la manera de realizar el estudio debido a diversos factores. Aun así, pese a la aparente simplicidad, se han logrado ciertos resultados útiles, como los valores de las temperaturas a partir de los cuales hay que empezar a tener cuidado, o con cuántos días de retardo aparecen los síntomas de una exposición al frío o al calor. En este proyecto también se han utilizado métodos novedosos para tener en cuenta el efecto espacial que tienen las provincias entre ellas. Esto prueba la utilidad y la potencia de los métodos y los modelos empleados, que solo se pueden mejorar en proyectos futuros con las variables y los datos, y sus cantidades, adecuadas.

Apéndice A

Material Suplementario

El código de R empleado durante el trabajo para obtener todos los resultados se encuentra en el repositorio de GitHub: https://github.com/AlonsoPueyo/TFM_Alonso_Pueyo

A.1. Estaciones meteorológicas por provincia

En esta sección se incluirán los nombres de las estaciones meteorológicas a partir de las cuales se obtuvieron los datos de las temperaturas de cada provincia.

- | | | |
|----------------------------------|--|--------------------------------------|
| ■ A Coruña Aeropuerto | ■ Córdoba Aeropuerto | ■ Málaga Aeropuerto |
| ■ Albacete | ■ Cuenca | ■ Melilla |
| ■ Alicante-Elche Aero-
puerto | ■ Donostia/San Sebastián
Aeropuerto | ■ Murcia Aeropuerto |
| ■ Almería Aeropuerto | ■ Girona Aeropuerto | ■ Ourense |
| ■ Asturias Aeropuerto | ■ Gran Canaria Aeropuer-
to | ■ Palencia |
| ■ Ávila | ■ Granada Aeropuerto | ■ Palma de Mallorca, Ae-
ropuerto |
| ■ Badajoz Aeropuerto | ■ Guadalajara | ■ Pamplona, Aeropuerto |
| ■ Barcelona Aeropuerto | ■ Huelva, Ronda Este | ■ Pontevedra |
| ■ Bilbao Aeropuerto | ■ Huesca, Aeropuerto | ■ Reus Aeropuerto |
| ■ Burgos Aeropuerto | ■ Jaén | ■ Salamanca Aeropuerto |
| ■ Cáceres | ■ León Aeropuerto | ■ Santander Aeropuerto |
| ■ Cádiz | ■ Lleida | ■ Segovia |
| ■ Castelló-Almassora | ■ Logroño, Aeropuerto | ■ Sevilla Aeropuerto |
| ■ Ceuta | ■ Lugo Aeropuerto | ■ Soria |
| ■ Ciudad Real | ■ Madrid Aeropuerto | ■ Sta. Cruz de Tenerife |

- Teruel
- Toledo
- Valencia Aeropuerto
- Valladolid Aeropuerto
- Vitoria-Gasteiz Aero-
puerto
- Zamora
- Zaragoza, Aeropuerto

A.2. Elección de los modelos DLNM para el análisis estatal

En esta sección se muestra cómo y por qué se eligieron los modelos que finalmente se usaron para la predicción en el análisis del exceso de mortalidad atribuible a la temperatura en España. Se procedió a hacer dos análisis de sensibilidad y estudiar los valores del QAIC. Estos valores son visibles en las Tablas A.1 y A.2.

df (Temperatura)	df (Retardo)	QAIC (ns)	QAIC (bs)	QAIC (ns, bs)	QAIC (bs, ns)
3	3	6266784			6266232
3	4	6265142	6262943	6263567	6264542
3	5	6250039	6247410	6248007	6249456
3	6	6247510	6244791	6245458	6246873
3	7	6245865	6244036	6244706	6245207
4	3	6262117			6260557
4	4	6260089	6256659	6258289	6258470
4	5	6244776	6240911	6242598	6243090
4	6	6241805	6237762	6239409	6240126
4	7	6240052	6236973	6238618	6238375
5	3	6261436			6260149
5	4	6259441	6256280	6257622	6258090
5	5	6244139	6240562	6241954	6242737
5	6	6241143	6237451	6238728	6239817
5	7	6239423	6236691	6237980	6238099
6	3	6260231			6259690
6	4	6258282	6255824	6256457	6257645
6	5	6242935	6240141	6240754	6242328
6	6	6240001	6237006	6237580	6239413
6	7	6238281	6236249	6236844	6237670
7	3	6259867			6259477
7	4	6257888	6255540	6256026	6257402
7	5	6242582	6239908	6240374	6242118
7	6	6239545	6236634	6237118	6239064
7	7	6237841	6235936	6236420	6237350

Tabla A.1: Valores del QAIC de los distintos modelos con los datos del año 2023.

df (Temperatura)	df (Retardo)	QAIC (ns)	QAIC (bs)	QAIC (ns, bs)	QAIC (bs, ns)
3	3	6237023			6237561
3	4	6235627	6234991	6234371	6236235
3	5	6225181	6224228	6223601	6225799
3	6	6223131	6222106	6221485	6223727
3	7	6221835	6221468	6220851	6222437
4	3	6236540			6237252
4	4	6235061	6234538	6233728	6235852
4	5	6224612	6223753	6222971	6225387
4	6	6222362	6221378	6220593	6223133
4	7	6221050	6220751	6219968	6221823
5	3	6236667			6236152
5	4	6235230	6233375	6233914	6234699
5	5	6224809	6222632	6223193	6224248
5	6	6222658	6220370	6220910	6222122
5	7	6221348	6219719	6220259	6220821
6	3	6236206			6235906
6	4	6234786	6233166	6233464	6234496
6	5	6224418	6222467	6222798	6224089
6	6	6222339	6220230	6220585	6221990
6	7	6221023	6219612	6219931	6220720
7	3	6235231			6235304
7	4	6233795	6232607	6232463	6233937
7	5	6223463	6221949	6221839	6223571
7	6	6221422	6219718	6219660	6221492
7	7	6220156	6219140	6219049	6220250

Tabla A.2: Valores del QAIC de los distintos modelos con los datos del año 2024.

Comparando ambas tablas notamos algunas consideraciones a destacar. En primer lugar, los modelos hechos con los datos del año 2024 presentan unos valores del QAIC más bajos. Esto es debido a la diferencia de observaciones entre los dos conjuntos de datos. Recordemos que hay 4000 filas más en el año 2023. Esto ocurre porque el término de la log-verosimilitud crece con el número de observaciones. En segundo lugar, notamos en ambas tablas que los modelos con un menor valor del QAIC son aquellos que son más complejos, con un mayor número de grados de libertad para ambas dimensiones. Esto no necesariamente significa que sean mejores, sino que son los más flexibles en términos de ajuste. De hecho, esos modelos con tantos grados de libertad sobreajustan los datos.

Se procederá a la selección de un modelo más parsimonioso, con menos grados de libertad y menor sobreajuste. Basándonos en los valores de las tablas, se buscaba un modelo con un número no demasiado grande de grados de libertad, y que además tuviera un valor del QAIC que no fuera demasiado alto ni bajo. Finalmente se optó por el modelo que incluye B-splines con 4 grados de libertad tanto para la dimensión de la temperatura como para la de los retardos.

A.3. Elección de los modelos DLNM para el análisis de Navarra

Análogamente a la sección anterior, aquí se incluyen los análisis de sensibilidad que fueron utilizados para elegir el modelo que se utilizó en el análisis del exceso de la mortalidad atribuible a la temperatura en la región de Navarra. Se calcula el valor del QAIC para cada modelo y se comparan los resultados obtenidos en las Tablas A.3 y A.4. A partir de este valor se elige el modelo más pertinente.

df (Temperatura)	df (Retardo)	QAIC (ns)	QAIC (bs)	QAIC (ns, bs)	QAIC (bs, ns)
3	3	66776.81			66781.86
3	4	66778.62	66785.20	66780.37	66783.45
3	5	66802.71	66788.65	66799.14	66796.15
3	6	66823.95	66803.34	66815.31	66813.94
3	7	66804.23	66811.03	66826.18	66791.90
4	3	66761.51			66770.80
4	4	66760.57	66777.72	66768.94	66771.34
4	5	66796.65	66792.47	66797.01	66795.90
4	6	66803.26	66796.31	66774.53	66818.09
4	7	66779.94	66804.49	66782.10	66798.08
5	3	66796.34			66805.30
5	4	66801.20	66824.23	66814.25	66819.35
5	5	66848.49	66836.26	66841.79	66843.05
5	6	66862.81	66855.99	66821.67	66882.08
5	7	66862.81	66871.57	66802.80	66873.43
6	3	66831.46			66826.49
6	4	66854.27	66856.71	66860.31	66849.01
6	5	66900.83	66877.66	66893.75	66880.51
6	6	66894.45	66872.40	66846.73	66906.02
6	7	66875.32	66893.22	66851.38	66902.47
7	3	66866.59			66856.28
7	4	66901.07	66897.85	66907.61	66890.50
7	5	66947.17	66930.28	66945.42	66931.75
7	6	66960.75	66931.09	66924.79	66963.57
7	7	66926.05	66911.66	66910.68	66936.33

Tabla A.3: Valores del QAIC de los distintos modelos con los datos de Navarra del año 2023.

df (Temperatura)	df (Retardo)	QAIC (ns)	QAIC (bs)	QAIC (ns, bs)	QAIC (bs, ns)
3	3	69612.82			69614.70
3	4	69616.04	69624.40	69619.79	69621.06
3	5	69629.90	69623.55	69625.27	69630.07
3	6	69657.13	69652.49	69654.06	69657.45
3	7	69692.10	68682.12	69686.05	69689.98
4	3	69645.82			69637.85
4	4	69659.37	69650.22	69662.54	69646.46
4	5	69681.28	69661.67	69679.58	69667.06
4	6	69721.40	69703.59	69716.14	69706.44
4	7	69759.36	69738.24	69755.46	69735.66
5	3	69675.61			69666.79
5	4	69695.92	69689.06	69698.99	69684.72
5	5	69727.87	69710.60	69723.16	69716.78
5	6	69780.41	69761.63	69775.11	69766.24
5	7	69826.00	69804.27	69816.02	69805.28
6	3	69700.90			69700.78
6	4	69731.77	69731.06	69735.78	69724.32
6	5	69776.53	69760.11	69772.78	69765.72
6	6	69839.43	69804.10	69835.12	69814.03
6	7	69895.76	69859.47	69884.82	69862.04
7	3	69732.86			69722.41
7	4	69763.93	69744.92	69769.16	69737.58
7	5	69822.52	69770.14	69818.30	69774.36
7	6	69893.41	69824.94	69888.21	69834.49
7	7	69962.02	69887.19	69951.41	69891.25

Tabla A.4: Valores del QAIC de los distintos modelos con los datos de Navarra del año 2024.

Fijándonos en los resultados de las tablas, el mejor modelo para los datos del año 2023 es el que emplea splines naturales con 4 grados de libertad para la dimensión de la temperatura y para la de los retardos, que posee un valor del QAIC de 66760.57. Otros modelos con un QAIC similar son aquellos que tienen en torno a los 4 grados de libertad para los splines de ambas dimensiones. Por otra parte, respecto a los datos pertenecientes al año 2024, los modelos con un menor QAIC han sido aquellos que poseen 3 grados de libertad independientemente del tipo de spline que se use en cada dimensión. Sin embargo, esta elección produce un subajuste de los datos, generando predicciones poco útiles. Por ello, finalmente se va a seleccionar el mismo modelo que se ha utilizado para las observaciones del año 2023 que, para el año 2024, dicho modelo toma un valor del QAIC de 69659.37.

Bibliografía

- [1] ACHEBAK H, DEVOLDER D, BALLESTER J (2018), *Heat-related mortality trends under recent climate warming in Spain: A 36-year observational study*. *PLoS Med*15(7): e1002617, <https://doi.org/10.1371/journal.pmed.1002617>
- [2] LINARES, C., DÍAZ, J. (2008), *Temperaturas extremadamente elevadas y su impacto sobre la mortalidad diaria según diferentes grupos de edad*. *Gaceta Sanitaria*, 22(2), 115-119.
- [3] GASPARRINI, A., ARMSTRONG, B. AND KENWARD, M.G. (2010), *Distributed lag non-linear models*. *Statist. Med.*, 29: 2224-2234, <https://doi.org/10.1002/sim.3940>
- [4] GASPARRINI A. (2011), *Distributed Lag Linear and Non-Linear Models in R: The Package dlnm*. *Journal of statistical software*, 43(8), 1–20.
- [5] GASPARRINI, A., ARMSTRONG, B. (2013), *Distributed lag non-linear models in R: the package dlnm*. *London School of Hygiene and Tropical Medicine, UK. dlnm version*, 1(7), 05-16.
- [6] GASPARRINI, A., ARMSTRONG, B., GASPARRINI, M. A. (2013), *Package ‘dlnm’*. 2017-01-16)[2017-10-05] <http://cran.r-project.org/web/packages/dlnm/dlnm.pdf>
- [7] BODEGAS DÍEZ, A. (2022), *Modelos Espaciales y Espaciotemporales en Disease Mapping*, UPV/EHU, MÁSTER UNIVERSITARIO EN MODELIZACIÓN E INVESTIGACIÓN MATEMÁTICA, ESTADÍSTICA Y COMPUTACIÓN, LEIOA
- [8] GOYENA BAROJA, H. (2021), *Predicciones a corto plazo en series temporales de alta frecuencia*, UNIVERSIDAD PÚBLICA DE NAVARRA, MÁSTER UNIVERSITARIO EN MODELIZACIÓN E INVESTIGACIÓN MATEMÁTICA, ESTADÍSTICA Y COMPUTACIÓN
- [9] BERGARA MARTÍNEZ, M. (2024), *Validación de modelos predictivos espacio-temporales de la incidencia y mortalidad por cáncer*, UPV/EHU, MÁSTER UNIVERSITARIO EN MODELIZACIÓN E INVESTIGACIÓN MATEMÁTICA, ESTADÍSTICA Y COMPUTACIÓN, LEIOA
- [10] RUTTEN, S., ESPINASSE, M., DUARTE, E., NEYENS, T., FAES, C. (2025), *On the lagged non-linear association between air pollution and COVID-19 cases in Belgium*. *Spatial and Spatio-temporal Epidemiology*, 52, 100709.
- [11] GONZÁLEZ DÍAZ, E. (2017), *Funciones Spline*, UNIVERSIDAD DE LA LAGUNA, GRADO EN MATEMÁTICAS, LA LAGUNA

- [12] QUIJAL-ZAMORANO, M., MARTINEZ-BENEITO, M. A., BALLESTER, J., MARÍ-DELL'OLMO, M. (2025), *Spatial Bayesian distributed lag non-linear models with R-INLA. International Journal of Epidemiology*, 54(4), dyaf120
- [13] RUE, H., RIEBLER, A., SØRBYE, S. H., ILLIAN, J. B., SIMPSON, D. P., LINDGREN, F. K. (2017), *Bayesian computing with INLA: a review. Annual Review of Statistics and Its Application*, 4(1), 395-421
- [14] QUIJAL-ZAMORANO, M., MARTINEZ-BENEITO, M. A., BALLESTER, J., MARÍ-DELL'OLMO, M. (2024), *Spatial Bayesian distributed lag non-linear models (SB-DLNM) for small-area exposure-lag-response epidemiological modelling. International journal of epidemiology*, 53(3), dyae061
- [15] WU, Y., LI, S., GUO, Y. (2021), *Space-time-stratified case-crossover design in environmental epidemiology study. Health Data Science*, 2021, 9870798
- [16] ROBINE, J. M., CHEUNG, S. L. K., LE ROY, S., VAN OYEN, H., GRIFFITHS, C., MICHEL, J. P., HERRMANN, F. R. (2008), *Death toll exceeded 70,000 in Europe during the summer of 2003. Comptes Rendus. Biologies*, 331(2), 171-178
- [17] EILERS, P. H., MARX, B. D. (1996), *Flexible smoothing with B-splines and penalties. Statistical science*, 11(2), 89-121