

Estudio del impacto de las altas temperaturas en la mortalidad diaria en España

Máster Universitario en Modelización e
Investigación Matemática, Estadística y
Computación



Universidad
Zaragoza

Alonso Pueyo Gómez
Trabajo de fin de máster
Universidad de Zaragoza
Tutora: Jaione Etxeberria

21 de julio de 2025

Resumen

Índice general

Resumen	III
1. Introducción	1
2. Marco Teórico	3
2.1. El paquete 'dlm'	5
3. Aplicación	7
3.1. Fuente de datos y Análisis Descriptivo	7
3.2. Modelización	10
4. Conclusiones	13
Bibliografía	15

Capítulo 1

Introducción

El cambio climático es un problema que lleva preocupando a la población varios años. Cada año, las estaciones son más calurosas, las olas de calor son más frecuentes e intensas, y las altas temperaturas afectan a la salud de los ciudadanos, existiendo grupos con más vulnerabilidad a este efecto que otros, como por ejemplo las personas mayores. Esta es la razón que nos lleva a estudiar este hecho en distintos grupos de población de diferentes regiones del país. Existen varios estudios que muestran la relación entre la mortalidad y la exposición a altas temperaturas. El estudio de Linares y Díaz (2008) [2] se encargó de estudiar eso, con otra metodología, la modelización ARIMA y la regresión de Poisson. Más tarde, en el 2010, Gasparrini, junto a Armstrong y Kenward [3], presentó el tipo de modelos que serán usados a lo largo de la memoria, con un ejemplo en la ciudad de Nueva York. Entre el 2011 y el 2013, Gasparrini y Armstrong publicaron un par de artículos [4, 5] en los que se explica la librería de RStudio que crearon, con el fin de utilizar los modelos que explicaron en el 2010. Gracias a ellos, otros autores, como Achebak, Devolder y Ballester, en el 2018 [1], pudieron hacer un estudio de la mortalidad asociada al calor en España.

La relación que existe entre la exposición a una temperatura extremadamente alta y la mortalidad diaria no es lineal. El efecto que el exceso de temperatura provoca tras una exposición prolongada no tiene por qué presentarse de forma inmediata. Al contrario, los efectos se presentan con cierto retardo, tardando varios días después de la exposición en aparecer. Es por ello que van a ser útiles los modelos que tienen en cuenta tanto los efectos inmediatos como los retardados de la temperatura sobre la mortalidad. Este tipo de modelos se conocen como *dlnm* según sus siglas en inglés (Distributed Lag Non-Linear Models). Lo que hacen es definir una dimensión temporal adicional a través de lo que se conoce como base cruzada, un espacio bidimensional de funciones que describe tanto la forma de la relación como la dimensión del retardo, y que determina la estructura temporal del efecto estudiado, que en el caso de este trabajo, es la mortalidad que se atribuye a la exposición a una alta temperatura.

Existe otro método más sencillo que el que se va a utilizar, y se trata del empleo de los modelos *dlnm* (Distributed Lag Models). La principal diferencia es que estos modelos no estudian la no linealidad que hay entre el efecto y las consiguientes consecuencias. Sin embargo, resultan muy útiles cuando se está estudiando la estructura de retardo de efectos lineales. Cuando no existe tal linealidad, poseen limitaciones. Una solución consiste en relajar los supuestos y extender la metodología a los *dlnm*. Queremos emplear este tipo de métodos cuando la relación es no lineal. Los modelos no lineales de retardo distribuido a los que queremos llegar estos modelos anteriores más sencillos y sus variantes en un único tipo de modelización.

El objetivo es, con este tipo de modelos, dividir a la población de distintas regiones de España () en grupos por su edad, y estudiar la mortalidad atribuible al exceso de calor en ellos realizando al mismo tiempo una comparación con el fin de identificar qué grupos y de qué regiones presentan una mayor vulnerabilidad al calor, para planificar estrategias de salud pública para el futuro.

El trabajo se estructura en cinco capítulos. En el segundo se hablará sobre el contenido teórico que rodea al problema, cómo se construyen los modelos y las predicciones que se usarán más tarde. Además, explicaremos la librería que se emplea a lo largo del proyecto, junto a sus funciones más destacadas. El tercer capítulo presenta la base de datos utilizada y un análisis descriptivo de las variables, así como los modelos ejecutados y las predicciones que resultan de ellos, además de las gráficas o dibujos que se obtienen. Finalmente, el último capítulo expone las conclusiones que se desprenden después de todo el análisis y el trabajo.

Capítulo 2

Marco Teórico

A continuación, se presenta el modelo general empleado en este proyecto. Se trata de un modelo jerárquico que estudia las muertes diarias producidas por un exceso de calor. Decimos que sigue una jerarquía porque se definen unos elementos iniciales, que luego se combinan en un objeto predictor. En particular, se siguen los siguientes pasos. Primero se define la dimensión de la exposición, que en nuestro caso es la temperatura. Se define cómo responde la variable de la mortalidad frente a los diferentes valores de la temperatura. Después, se precisa cómo el riesgo de fallecer se distribuye a lo largo del tiempo. Esta es la dimensión del retardo, donde se modela cómo varía el efecto conforme van pasando los días tras la exposición. Finalmente, las dos dimensiones anteriores se combinan de forma jerárquica generando una matriz de diseño, la base cruzada, que funciona como predictor en el modelo.

Expliquemos matemáticamente lo que ocurre. El efecto total de la temperatura sobre la mortalidad en el día t se expresa como la suma de los efectos de las temperaturas de días anteriores:

$$\eta_t = \sum_{l=0}^L f(x_{t-l}, l),$$

donde x_{t-l} es la temperatura registrada l días antes, $f(x, l)$ es la función que modela el efecto de la temperatura x con un retardo de l días, y L es el retardo máximo que se considera. Por defecto, este último valor suele ser de 30 días.

Ahora es cuando entra en juego la jerarquía. El efecto que antes denotábamos como $f(x, l)$ se descompone en dos funciones base, correspondientes a la temperatura y al retardo, respectivamente. Matemáticamente se escribe como:

$$f(x, l) = \sum_{i=1}^I \sum_{j=1}^J \beta_{ij} \cdot B_i(x) \cdot C_j(l),$$

donde los β_{ij} son los coeficientes a estimar, $B_i(x)$ y $C_j(l)$ son las funciones base para la temperatura y el retardo, respectivamente, e I y J es el número de funciones base que se tienen en cada dimensión.

Notemos que queremos estudiar la evolución de las defunciones atribuibles al exceso de calor a lo largo del tiempo, y que esto es, en esencia, un análisis de series temporales. Por ello, lo primero que se va a realizar, es la presentación de un modelo general empleado para series

temporales. Después, introduciremos el concepto de efecto retardado para llegar a lo que son los *dlnm*. Por último, haremos la transición a los modelos más generales *dlnm* para modelizar efectos retardados y no lineales.

Sean Y_t los datos de la serie temporal que se pretende estudiar, para $t = 1, \dots, n$. En nuestro caso, el número de defunciones observadas en el tiempo t . Un método general que se utiliza para este tipo de análisis es la regresión lineal generalizada con función de enlace logarítmica y distribución de Poisson. Se emplea la regresión de Poisson porque se están modelando conteos de eventos. En particular, se cuentan las defunciones que ocurren cada día. Recordemos que este tipo de modelización posee a la media de los datos como variable explicada. Además, lo de enlace logarítmico se usa para que la predicción del número esperado de muertes sea siempre positiva. Con todo esto, la representación del modelo es la siguiente:

$$\log(\mu_t) = \alpha + \sum_{j=1}^J s_j(x_{tj}; \beta_j) + \sum_{k=1}^K \gamma_k u_{tk}, \quad (2.1)$$

donde $\mu_t = E(Y_t)$ es la media de las defunciones observadas en el tiempo t , $s_j(x_{tj}; \beta_j)$ son las funciones suavizadas que representan las relaciones no lineales entre las variables explicativas x_{tj} y la respuesta, que están dadas por los parámetros β_j . Las variables u_{tk} son otros predictores con efectos lineales especificados por los coeficientes γ_k , como por ejemplo el día de la semana, o la tendencia temporal. Por último, J es el número total de variables que se modelan de manera no lineal, y K es el número de variables explicativas lineales del modelo.

Introduciremos ahora los efectos retardados. Recordemos que el impacto de la temperatura no es instantáneo, sino que se manifiesta un tiempo después. Ante la presencia de estos, el resultado del tiempo t se puede explicar en función de las exposiciones pasadas x_{t-l} , donde l es el desfase, el tiempo que transcurre entre la exposición al calor y el efecto que provoca. Se genera una matriz Q que posee la temperatura del día actual y los L días anteriores, siendo L el desfase máximo que se introduce en el modelo. Así, para un tiempo t , la columna de la matriz Q es la siguiente:

$$q_t = (x_t, x_{t-1}, \dots, x_{t-L})^T \quad (2.2)$$

Esto crea la dimensión adicional de los retardos, que nos servirá para estudiar cómo se distribuye a lo largo del tiempo la mortalidad tras una exposición a altas temperaturas.

Cuando asumimos una relación lineal entre la exposición y la respuesta, los efectos retardados se pueden modelar mediante los modelos de retardo distribuido (*dlnm*). Este tipo de metodología distribuye el efecto de un evento de exposición a lo largo del tiempo, mediante parámetros que estudian lo que ocurre en los diferentes retardos. El método más simple es un *dlnm* sin ninguna restricción, donde hay un parámetro para cada retardo. Sin embargo, estos modelos no son muy utilizados debido a su falta de precisión, ya que las exposiciones de un día y de sus sucesivos son muy similares entre sí, dando lugar a una alta correlación. El resultado de la colinealidad de las variables es lo que daña el modelo. Para evitar esto, se imponen ciertas restricciones, como por ejemplo, modelizando mediante la descripción de curvas suaves empleando polinomios o splines.

Vamos a formular de una manera general los modelos *dlnm*. Sobre una base se especifican los efectos distribuidos a lo largo de los retardos. En notación matricial, los efectos retardados se modelan como sigue:

$$s(x_t; \beta) = q_t^T C \beta, \quad (2.3)$$

donde C es la matriz de variables base que se obtiene al aplicar las funciones base a los retardos, y β es el vector de parámetros que no se conocen. Dependiendo de cómo esté definida la matriz C , se habla de un tipo de *dlnm* u otro. Si C es la matriz identidad, entonces se trata del modelo sin restricciones que hemos comentado antes. Por otra parte, si la matriz viene dada por polinomios o splines, se describe el efecto como una curva suavizada a lo largo de los retardos.

Una vez hemos visto los modelos que analizan los efectos lineales distribuidos en el tiempo, pasamos a ver qué ocurre cuando la relación es no lineal. Introducimos el concepto de base cruzada, un espacio bidimensional de funciones que describen al mismo tiempo la forma de la relación entre la exposición y la respuesta, y los efectos de retardo distribuidos. Una base cruzada se elige mediante la selección de dos conjuntos de funciones de base, uno para la exposición, en nuestro caso la temperatura, y otro para el retardo. Estos se combinarán para generar lo que se conoce como funciones de base cruzada.

Definiendo la matriz C como se ha hecho en el párrafo anterior, y siendo β el vector de parámetros desconocidos, un modelo *dlnm* se especifica de manera general como:

$$s(x_t; \beta) = r_t^T C \beta = \sum_{i=1}^I \sum_{j=1}^J r_{ti}^T c_j \beta_{ij}, \quad (2.4)$$

donde r_t es el vector de las componentes de la temperatura transformadas según las funciones de base, I es el número de funciones base en la dimensión de la temperatura, y J el número de funciones base en la dimensión de los retardos.

2.1. El paquete 'dlnm'

A lo largo del trabajo, para poner en práctica lo visto en este capítulo, utilizaremos la librería *dlnm* del programa RStudio. Este paquete contiene funciones para crear y modificar tanto modelos *dlnm* como *dlnm*. Esencialmente, lo que se hace es construir bases y bases cruzadas, que más tarde se emplearán para predecir y dibujar gráficos que serán útiles para visualizar de una manera más sencilla lo que va a ocurrir. Esta librería fue creada por Antonio Gasparrini y Ben Armstrong, con contribuciones de Fabian Scheipl. Actualmente es Gasparrini el que se encarga de mantenerla actualizada. Las principales funciones que tiene son: *crossbasis*, *crosspred*, *crossreduce* y *onebasis*. En este trabajo, al tratarse específicamente de modelos *dlnm*, utilizaremos las dos primeras.

La función *onebasis* genera una base de funciones para una sola dimensión. Puede ser para la exposición o para el retardo, pero no las combina. Solamente se emplea si se quiere construir manualmente la base cruzada a partir de esta, en el caso de un *dlnm*, o cuando nos encontramos ante un *dlnm*, donde hay retardo pero la relación entre la exposición y la respuesta es lineal. Desde la versión 1.5.0 de la librería, esta función ha reemplazado a otras dos que existían antes, *mkbasis* y *mklagbasis*. Lo que hacían era crear la base de funciones para la dimensión de la exposición y para la dimensión del retardo, respectivamente. Los argumentos que se tienen que incluir en *onebasis* son la variable exposición a estudiar, y la función de base que se quiere emplear para modelizar, aparte de otros que dependen de la función seleccionada, tales como los grados de libertad, el grado del polinomio si se utiliza, o la posición de los nodos para los

splines. Las posibles funciones que se suelen emplear son los splines cúbicos o de otros grados (*ns* y *bs*), los polinomios (*poly*) y las funciones lineales (*lin*), entre otros menos empleados.

La función *crossbasis* es la función principal de todo el paquete. Es la que construye la base cruzada que combina las dos dimensiones. Lo que hace es generar la base de funciones tanto para la exposición como para el retardo y las combina. Se emplea cuando se trata de un modelo *dlnm*, donde la relación es no lineal y los retardos se distribuyen por el tiempo. Los argumentos de esta función son la variable exposición, el número máximo de días de retardo y las listas con los argumentos asociados a la dimensión de la exposición y a la de los retardos, es decir, como con *onebasis*, las funciones de base que se van a utilizar y sus respectivos parámetros (grados de libertad, posición de los nodos, etc.).

Una vez se define la base y se ajusta el modelo, la función *crosspred* calcula y predice los efectos estimados. Entre otros, se puede obtener la superficie de riesgo relativo, el efecto acumulado de la temperatura en todos los días de retardo, o los intervalos de confianza. Como argumentos se tienen que incluir la base cruzada generada anteriormente con *crossbasis*, el modelo que se ha ajustado incluyendo dicha base, y otros valores opcionales tales como un valor para centrar la referencia, o los valores exactos de los que se quiere una predicción. Con la función *plot* se dibuja una superficie tridimensional que relaciona el riesgo de mortalidad según la temperatura y el retardo. Si además añadimos el argumento *overall*, se muestra una curva que indica el riesgo total acumulado a lo largo de todos los días de retardo. Con el argumento *slices* se pueden dibujar curvas para valores fijos de la temperatura o de los retardos, según se indique. Lo que hace es cortar la superficie tridimensional en un valor dado. Por último, con el argumento *contour* se muestra lo mismo que la superficie tridimensional pero con un mapa de calor.

Después de ajustar un modelo bidimensional, que puede ser un *dlnm* o un *dlnm*, con la función *crossreduce* se puede resumir esa información en una sola dimensión, la de la exposición o la de los retardos. Con esto se obtiene el efecto acumulado de una temperatura concreta que se quiera estudiar en particular, o puede ser útil para comparar distintos valores de las temperaturas. Al igual que con la función anterior, los argumentos principales que hay que incluir son la base cruzada y el modelo ajustado con ella. Además, se pueden añadir argumentos adicionales, como un valor central de referencia.

Capítulo 3

Aplicación

3.1. Fuente de datos y Análisis Descriptivo

En primer lugar, antes de comenzar a modelizar, vamos a indicar de dónde han sido sacados los datos que emplearemos, y haremos un primer análisis descriptivo de las variables. Los datos de mortalidad y defunciones diarias según las distintas comunidades autónomas o grupos de edad son sacados de la página web del Sistema de Monitorización de la Mortalidad Diaria (MoMo)[https://momo.isciii.es/panel_momo/#section-momo]. Las variables que se incluyen en esta base de datos son el ámbito (provincia, comunidad autónoma o nacional), y su respectivo código; su nombre, además del código; el sexo y el grupo de edad a los que pertenece cada persona, y sus códigos; la fecha de defunción, las defunciones observadas ese día, las defunciones estimadas base (sin el efecto de la temperatura) junto a los límites inferior y superior del intervalo de confianza, y las defunciones que son atribuibles al exceso y al defecto de temperatura.

Notar que estos datos no contienen las temperaturas diarias, así que se consiguen de otras fuentes. En particular, para la región de Navarra, los datos fueron extraídos de la página web de Meteo Navarra [<https://meteo.navarra.es/>]. De aquí se obtuvieron, aparte de la fecha, los valores de las temperaturas máximas, mínimas y medias de cada día, desde el 1 de enero del 2015 hasta el 31 de diciembre del 2024, ambos incluidos. En concreto, los datos son de la estación automática de Pamplona GN. Esta estación no incluye los valores del 2021, y es por ello que los datos de ese año fueron sacados de la estación manual Pamplona MAN.

Después de leer todos los datos, evaluamos la existencia de observaciones faltantes, y nos damos cuenta de que los datos de la temperatura media del año 2020 no están. Por tanto, después de pasar todas las columnas de la base de datos a variables numéricas, calculamos la temperatura media de cada uno de esos días como el promedio de la temperatura máxima y mínima que hizo. Aún así, notamos que hay una totalidad de 7 días de los cuales no conocemos ninguno de sus valores. Para terminar, unificamos la base de datos de MoMo y la de Meteo Navarra en una sola. Para ello, de la primera solo seleccionamos aquellas observaciones relativas a Navarra, es decir, filtramos las que tengan un código INE igual a 31. Después, hacemos que las columnas de fechas sean de tipo 'Date', y las juntamos en una sola base de datos.

A continuación, procedemos a analizar los datos que se tienen. Veremos si las temperaturas y las defunciones observadas se distribuyen de manera lógica, o cuántas observaciones se tienen para cada grupo de población, entre otras cosas. Para comenzar, las variables de la base de datos que se refieren a los grupos de edad y los del sexo, se pasan a tipo factor para obtener

T_max	T_media	T_min
Min. : -1.38	Min. : -2.76	Min. : -5.280
1st Qu.: 12.59	1st Qu.: 8.47	1st Qu.: 4.550
Median : 18.25	Median : 13.19	Median : 8.900
Mean : 18.89	Mean : 13.63	Mean : 9.004
3rd Qu.: 25.04	3rd Qu.: 18.80	3rd Qu.: 13.560
Max. : 40.45	Max. : 31.38	Max. : 24.350

Figura 3.1: Resumen de los datos de temperatura




Figura 3.2: Histogramas de frecuencias de temperaturas

todos los subgrupos. Después, realizamos un resumen de los datos, donde se observa que se dividen de igual manera entre todos los grupos de edad y de sexo, es decir, que de las 89040 observaciones, hay 29680 hombres, mujeres y pertenecientes al subgrupo de 'todos', y 11130 para cada subgrupo de edad. Esto ocurre debido a que los datos de MoMo están estructurados de manera que cada fila es un día por cada grupo de edad y de sexo. Es por ello que a veces hay defunciones nulas, donde no se ha observado ninguna muerte para un grupo de un día en concreto.

Si continuamos analizando los datos, ahora nos fijamos en los valores de las temperaturas, tanto la máxima como la mínima y la media. Observamos sobretudo la media y la mediana de cada variable. Que no haya mucha diferencia entre las dos nos indica lo bien distribuidos que se encuentran los datos relativos a la temperatura. La mayoría se encuentran entorno al centro, y cada vez hay menos observaciones conforme vamos alcanzando los extremos. Lo normal son días con temperaturas medias, mientras que también hay días con temperaturas extremas, pero en menor cantidad. No existe ningún dato demasiado alto ni demasiado bajo que altere la media. De hecho, esto lo podemos visualizar con los siguientes histogramas:

```
defunciones_observadas
Min.   : 0.000
1st Qu.: 0.000
Median : 2.040
Mean   : 3.959
3rd Qu.: 6.130
Max.   : 56.170
```

Figura 3.3: Resumen de la variable de defunciones observadas




Figura 3.4: Histograma de frecuencia de las defunciones observadas

Vamos a realizar la misma observación pero con la variable relativa a las defunciones observadas. Esta vez, se ve esto: Nótese que ahora la diferencia es abismal. El valor mínimo es 0, de los días que no se ha contabilizado ninguna muerte. Por el contrario, el valor máximo alcanza 56.17. Por otra parte, el valor de la media es casi el doble que el de la mediana. Esto significa que los datos se acumulan cerca del 0, y que los días con más defunciones son menos comunes. El histograma confirma esto:

Por último, para terminar este análisis, dado que pretendemos estudiar lo que ocurre en los distintos grupos de edad, vemos el número de defunciones correspondientes a cada uno, lo que ya nos dará una primera idea. La fila de arriba corresponde a los distintos grupos, y la de abajo se trata de la suma de todas las defunciones observadas para cada grupo. Notar que a medida que va aumentando la edad, más defunciones se observan. Para el grupo de niños entre 0 y 14 años apenas hay 400 muertes, mientras que los grupos que más mortalidad tienen son los que tienen a partir de 65 años.

+65	+85	0-14	15-44	45-64	65-74	75-84	all
107708.21	62612.43	403.72	2010.13	12302.83	15298.40	29776.21	122381.66

Figura 3.5: Número de defunciones observadas para cada subgrupo de edad

3.2. Modelización

En esta sección se presentará el estudio de los modelos que se han empleado para el análisis de la mortalidad atribuible al exceso de calor. En primer lugar, se estudiará el tipo de modelos que han utilizado otros autores en otros trabajos semejantes, para basarnos en ellos a la hora de hacer el primer modelo, y una vez adaptado al problema relativo a este proyecto, se hará una evaluación de lo que sucede.

En el trabajo de Gasparrini, Armstrong y Kenward [3], que mencionamos en la introducción, y donde se explica el funcionamiento de los modelos *dlnm*, hay un ejemplo de aplicación sobre el efecto de la temperatura en la mortalidad en la ciudad de Nueva York. En él se menciona que se elige un modelo con splines cúbicos naturales para describir la relación en cada dimensión, con nudos igualmente espaciados para la temperatura con el fin de dar flexibilidad a los extremos, y con intervalos iguales en la escala logarítmica para los retardos, para flexibilizar la primera parte de la curva del retardo distribuido, que se espera más variable. Además, se toma un retardo máximo de 30 días, y los grados de libertad se eligen según los criterios de información de Akaike y bayesianos modificados.

Por otro lado, en el trabajo de Achekbak, Devolder y Ballester [1], donde recordemos que se estudia la mortalidad relacionada con el calor en España, se modela la curva relativa a la temperatura con un B-spline cúbico natural, con un nudo en el percentil 15 de la distribución de la temperatura diaria, y para la curva de los retardos se emplea otro B-spline cúbico natural con una intersección y dos nudos igualmente espaciados en la escala logarítmica. El retardo máximo que se considera es de 10 días.

Por último nos vamos a fijar en el proyecto realizado por Rutten, Espinasse, Duarte, Neyens y Faes [10]. En él se estudia las asociaciones retardadas y no lineales entre la contaminación del aire y los casos del virus COVID-19 en Bélgica. También se utiliza un *dlnm*, donde se emplea un spline natural con 2 nudos igualmente espaciados y 3 grados de libertad para la dimensión de la exposición, y un nudo y un intercepto con 3 grados de libertad para la dimensión de los retardos.

Nos damos cuenta con estas observaciones que los splines cúbicos son adecuados para nuestro análisis. Esto se debe a su flexibilidad, que permite modelizar bien las curvas suaves, como son las que se esperan que resulten al aplicar un modelo *dlnm*.

Recordemos brevemente lo que es una función spline cúbica. Dados $n + 1$ puntos distintos $t_0 < t_1 < \dots < t_n$ que son una partición del intervalo $[t_0, t_n]$, un spline cúbico (de grado 3) con nudos en $t_0, t_1, \dots, t_n$ es un polinomio a trozos de grado a lo sumo 3 continuo en $[t_0, t_n]$, y con derivadas continuas hasta orden 2. Además, se dice que un spline cúbico es natural si satisface que su segunda derivada en los extremos, es decir, en los puntos t_0 y t_n es nula. Las funciones B-spline son la base de los splines generales. Se tratan de funciones no negativas que se anulan en toda la recta real excepto en intervalos contiguos $[t_i, t_{i+1}]$ tal y como afirma González en su trabajo sobre splines [11].

Después de dedicar unas líneas a comprender lo que otros autores han hecho para abordar el problema y de definir teóricamente lo que se va a emplear, pasaremos a plantear nuestro modelo. Lo primero que se tiene que realizar es hallar las funciones base que mejor describan la dimensión de la temperatura y la de los retardos. Ya me hemos mencionado anteriormente que,




Figura 3.6: Gráficos de predicciones del modelo con 3 grados de libertad para cada dimensión. A la izquierda la superficie y a la derecha el gráfico de efecto acumulado

debido a las curvas suaves que se describen, una buena aproximación se realiza con funciones spline o B-spline. Los grados de libertad los vamos a calcular mediante la evaluación del QAIC, el criterio de información de Akaike modificado para modelos sobredispersos como el nuestro. Recordemos que se calcula como sigue:

$$QAIC = -2L(\hat{\theta}) + 2\hat{\phi}k \quad (3.1)$$

donde L es la función de log-verosimilitud del modelo ajustado con parámetros $\hat{\theta}$, $\hat{\phi}$ es el parámetro estimado de sobredispersión, y k el número de parámetros. Como ya veremos, se obtendrán valores del QAIC muy grandes. Esto es totalmente normal debido a la gran cantidad de observaciones se tienen.

Hacemos un análisis de sensibilidad donde creamos varios modelos usando splines (tanto naturales como B-splines) para la temperatura y el retardo con distintos valores para los grados de libertad de cada uno, y estudiamos los valores QAIC. Seleccionaremos el de menor valor. Como es necesario calcular la verosimilitud, para evitar errores, redondeamos los valores de la variable correspondiente a las defunciones observadas. Otra observación que tenemos que hacer es que en el modelo de regresión solo estamos incluyendo a la base cruzada creada anteriormente como variable explicativa. Más adelante compararemos lo que ocurre si se introduce alguna variable más.

Después de formar distintas bases cruzadas, crear los modelos y calcular su QAIC, llegamos a la conclusión de que, según este criterio, la mejor forma de modelizar las defunciones según la temperatura y los retardos es emplear un B-spline con 3 grados de libertad para la dimensión de la temperatura y un spline natural también con 3 grados de libertad para el retardo. De esta manera se ha alcanzado el menor valor del QAIC, que es igual a 690782.2. Le aplicamos la función de predicción y se obtiene lo siguiente:

En la izquierda se tiene el gráfico tridimensional, la superficie que denota el valor de RR para cada valor de la temperatura y de retardo. El eje de RR muestra el riesgo relativo de mortalidad en cada momento. Un valor mayor que 1 indica que aumenta el riesgo de muerte, mientras que un valor menor que 1 significa lo contrario. El gráfico de la derecha es el gráfico de efecto




Figura 3.7: Gráficos de predicciones del nuevo modelo al que se ha incluido un spline natural cúbico para la fecha en el modelo de regresión

acumulado, que dibuja una línea que indica la influencia de la temperatura en la mortalidad en los días posteriores a la exposición.

Nos damos cuenta que para los valores más centrales no hay ningún inconveniente, ya que temperaturas suaves entre los 15 y los 25 grados Celsius no son perjudiciales para la salud, ni provocan muertes. Por el contrario, a medida que nos acercamos a las esquinas y a los extremos, el valor del riesgo relativo se dispara.

Observemos que, según Gasparrini et al., 2010, cuando se realiza el modelo de regresión, aparte de incluir la base cruzada como variable explicativa, se añaden otras variables tales como el día de la semana o el promedio de ozono y monóxido de carbono en la atmósfera cada día. De esta manera se puede modelizar efectos que poseen las series temporales. En particular, se incluye un spline cúbico con 7 grados de libertad por cada año analizado con el fin de describir la tendencia a largo plazo y la estacionalidad.

En nuestro caso, carecemos de alguna de estas variables, pero puede resultar útil incluir en el modelo el spline cúbico que se menciona en el párrafo anterior. Así, volveremos a hacer el análisis de sensibilidad y a analizar los valores del QAIC con la diferencia de incluir en el modelo de regresión un spline cúbico natural con 70 grados de libertad (7 por cada uno de los 10 años de los que tenemos observaciones).

Bajo este cambio, se tiene que el mejor modelo va a seguir siendo el que tenga un B-spline para la temperatura y un spline natural para el retardo, ambos con 3 grados de libertad. Esta vez el valor del QAIC que se ha obtenido es 686365.2, que es menor que el que habíamos logrado antes. En general, en todos los casos se ha llegado a un valor del QAIC menor, lo que ya quiere sugerir que este modelo es mejor que el anterior. Dibujamos a continuación los gráficos:

Se observan claras diferencias. Para empezar, en la superficie, las esquinas que muestran lo que ocurre con una temperatura cercana al 0 se han suavizado. Lo mismo ocurre con el gráfico de efecto acumulado, que afirma que con temperaturas frías, el riesgo a fallecer es menor.

Notamos que el modelo puede ser objeto de mejora. Como ya hemos mencionado anteriormente, por falta de disponibilidad, no se han podido incluir más variables en el modelo de regresión como la contaminación o la humedad. Posiblemente esto hubiera hecho que en los gráficos se vieran otras cosas, como un mayor riesgo relativo unos días después de una exposi-

ción a una alta temperatura, y no inmediatamente en el retardo 0.

Capítulo 4

Conclusiones

4.1. Material Suplementario

El código de R empleado durante el trabajo para obtener todos los resultados se encuentra en el repositorio de GitHub: https://github.com/AlonsoPueyo/TFM_Alonso_Pueyo

Bibliografía

- [1] ACHEBAK H, DEVOLDER D, BALLESTER J (2018), *Heat-related mortality trends under recent climate warming in Spain: A 36-year observational study*. *PLoS Med*15(7): e1002617, <https://doi.org/10.1371/journal.pmed.1002617>
- [2] LINARES, C., DÍAZ, J. (2008), *Temperaturas extremadamente elevadas y su impacto sobre la mortalidad diaria según diferentes grupos de edad*. *Gaceta Sanitaria*, 22(2), 115-119.
- [3] GASPARRINI, A., ARMSTRONG, B. AND KENWARD, M.G. (2010), *Distributed lag non-linear models*. *Statist. Med.*, 29: 2224-2234, <https://doi.org/10.1002/sim.3940>
- [4] GASPARRINI A. (2011), *Distributed Lag Linear and Non-Linear Models in R: The Package dlnm*. *Journal of statistical software*, 43(8), 1–20.
- [5] GASPARRINI, A., ARMSTRONG, B. (2013), *Distributed lag non-linear models in R: the package dlnm*. *London School of Hygiene and Tropical Medicine, UK. dlnm version*, 1(7), 05-16.
- [6] GASPARRINI, A., ARMSTRONG, B., GASPARRINI, M. A. (2013), *Package ‘dlnm’*. 2017-01-16)[2017-10-05] <http://cran.r-project.org/web/packages/dlnm/dlnm.pdf>
- [7] BODEGAS DÍEZ, A. (2022), *Modelos Espaciales y Espaciotemporales en Disease Mapping*, UPV/EHU, MÁSTER UNIVERSITARIO EN MODELIZACIÓN E INVESTIGACIÓN MATEMÁTICA, ESTADÍSTICA Y COMPUTACIÓN, LEIOA
- [8] GOYENA BAROJA, H. (2021), *Predicciones a corto plazo en series temporales de alta frecuencia*, UNIVERSIDAD PÚBLICA DE NAVARRA, MÁSTER UNIVERSITARIO EN MODELIZACIÓN E INVESTIGACIÓN MATEMÁTICA, ESTADÍSTICA Y COMPUTACIÓN
- [9] BERGARA MARTÍNEZ, M. (2024), *Validación de modelos predictivos espaciotemporales de la incidencia y mortalidad por cáncer*, UPV/EHU, MÁSTER UNIVERSITARIO EN MODELIZACIÓN E INVESTIGACIÓN MATEMÁTICA, ESTADÍSTICA Y COMPUTACIÓN, LEIOA
- [10] RUTTEN, S., ESPINASSE, M., DUARTE, E., NEYENS, T., FAES, C. (2025), *On the lagged non-linear association between air pollution and COVID-19 cases in Belgium*. *Spatial and Spatio-temporal Epidemiology*, 52, 100709.
- [11] GONZÁLEZ DÍAZ, E. (2017), *Funciones Spline*, UNIVERSIDAD DE LA LAGUNA, GRADO EN MATEMÁTICAS, LA LAGUNA

